Regressão supervisionada de porosidade a partir de perfis convencionais: diagnóstico de colinearidade e leitura crí tica das métricas

15 de abril de 2026

Resumo

Trata-se do registro analí tico de um ensaio de regressão para estimar porosidade a partir de curvas de perfilagem: intervalo de trânsito sônico (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade da onda de compressão P (V_p), raio gama (GR) e variável associada à fração argilosa (V_c). O ajuste emprega um modelo GBDT (*Gradient Boosting Decision Trees*, conjunto de árvores de decisão com reforço por gradiente, aqui na variante baseada em histogramas). A avaliação usa partição treino–teste ao longo da profundidade, ablações de preditores e diagnóstico multivariado: correlações de Pearson e de Spearman e fator de inflação da variância (VIF) no treino; informação mútua (MI) entre cada preditor e a porosidade também no treino; importância por permutação do coeficiente de determinação (R^2) no teste, e valores SHAP (*SHapley Additive exPlanations*, decomposição aditiva do efeito de cada preditor com base em Shapley). Complementam o quadro, no conjunto de teste profundo, o erro absoluto médio (MAE, do inglês *mean absolute error*) e a raiz do erro quadrático médio (RMSE, *root mean squared error*). No **recorte principal**, sob partição treino–teste ao longo da profundidade e com as curvas tal como exportadas, V_p e a impedância acústica (AI) não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já entram no modelo: o R^2 no teste profundo permanece praticamente inalterado após retirá-los. Isto documenta redundância preditiva **local** nesse protocolo, não irrelevância fí sica universal dessas grandezas. Os resultados devem ser lidos como evidência de colinearidade e redundância no recorte analisado, **não** como demonstração de generalização entre poços ou entre contextos geológicos distintos.

1 Introdução

A porosidade controla, com mineralogia e fluido, a resposta elástica efetiva da rocha. Em colunas perfiladas, relações empí ricas entre porosidade e grandezas sônicas ou de densidade são esperadas; o mesmo vale para grandezas derivadas da combinação massa–rigidez, como a impedância acústica (AI) e a velocidade da onda de compressão P (V_p). Daí decorre um risco metodológico: modelos supervisionados podem atingir erros baixos no teste sem que isso signifique, por si só, que cada preditor contribua com informação independente.

Os achados de ablação não implicam irrelevância fí sica de V_p ou de AI, mas sim **ausência de contribuição preditiva marginal detectável** no recorte considerado, dado o forte acoplamento dessas grandezas com AC e ρ_b e a qualidade relativa das curvas usadas como entrada.

O objetivo deste texto é documentar, com rigor modesto porém explí cito, um baseline de regressão e o diagnóstico que o acompanha. Pretende-se responder, com base em números e figuras, se a retirada isolada de V_p ou da impedância acústica (AI) altera o desempenho, e se correlações e o fator de inflação da variância (VIF) sustentam a leitura de redundância entre preditores. Inclui-se ainda um contraste entre dois recortes verticais distintos, para lembrar que a generalização entre contextos não se infere apenas de R^2 alto num único intervalo.

2 Quadro teórico sucinto

Em meio efetivo, a impedância acústica Z relaciona massa volumétrica ρ e velocidade V segundo

$$Z = \rho V. \tag{1}$$

Quando ρ e V são estimados a partir das mesmas observações que alimentam o intervalo de trânsito, a informação trazida por Z tende a sobrepor-se à de V e à de ρ, em vez de acrescentar graus de liberdade estatí sticos novos.

Para avaliar o ajuste global no teste, utilizou-se o coeficiente de determinação

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}, \tag{2}$$

onde y_i é a porosidade observada, $\hat{y}_i$ a predição e $\bar{y}$ a média amostral no conjunto de teste de cardinalidade n. O erro absoluto médio (MAE) foi

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{3}$$

isto é, o erro absoluto médio (MAE, do inglês *mean absolute error*). A raiz do erro quadrático médio (RMSE, *root mean squared error*) foi

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}\,. \tag{4}$$

Estas grandezas resumem o encaixe, mas não distinguem, por si só, contribuição marginal de preditores correlacionados.

3 Questões de trabalho

Colocam-se as seguintes questões, respondidas na Secção 7 com apoio nas Figuras 2–12 e na Tabela 1:

1. O erro de generalização no bloco de teste profundo muda de forma relevante quando se retira V_p, quando se retira a impedância, ou ambas?

2. As estruturas de correlação e o fator de inflação da variância (VIF, medida clássica de colinearidade em regressão linear auxiliar) indicam colinearidade forte o suficiente para explicar a estabilidade de R^2 sob ablação?

3. A importância por permutação do R^2 e o resumo SHAP (*SHapley Additive exPlanations*) apontam para um preditor dominante entre os elásticos?

4. O mesmo protocolo, aplicado a um segundo recorte vertical, produz R^2 sensivelmente diferente?

4 Metodologia

4.1 Dados e variáveis

Utilizou-se um perfil tabular com sete preditores: intervalo de trânsito (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade V_p, raio gama (GR), variável associada à argila (V_c) e porosidade como alvo.

Neste relatório, **recorte** designa um **trecho vertical** da coluna perfilada analisado através de um **conjunto tabular 7logs completo** (preditor + alvo), com amostragem regular ao longo da profundidade e **identificador de amostra** próprio (nome de exportação do arquivo de dados). O **recorte principal** corresponde ao identificador F03-4; o **recorte de contraste**, ao F06-1. Trata-se de duas séries distintas para confrontar o mesmo protocolo computacional. O vocabulário *recorte* não implica, por si só, que se trate do mesmo poço em duas profundidades ou da mesma litologia dominante.

Adotou-se o recorte F03-4 como estudo principal e o F06-1 como contraste qualitativo.

4.2 Fluxo de processamento

O procedimento computacional segue a cadeia ilustrada na Figura 1, lida de cima para baixo: primeiro consolidam-se tabela de preditores e alvo; em seguida remove-se linhas incompletas; depois separa-se o trecho mais profundo para teste, mantendo o trecho mais raso para treino; estima-se o *Gradient Boosting* em histogramas (GBDT) **sem** padronização *z-score* nas features, por coerência com modelos baseados em árvores (a padronização permanece disponível no código apenas para comparações opcionais com modelos lineares); calculam-se MAE (3), RMSE (4) e R^2 (2) no teste, com variantes por ablação; por fim, executa-se o bloco de diagnóstico multivariado (correlações e VIF no treino, MI no treino, permutação e SHAP no teste profundo). A avaliação por permutação insere-se nesse último bloco, pois reutiliza o modelo ajustado e as partições fixas.

Na prática, cada retângulo corresponde a uma etapa documentável. O primeiro bloco fixa o universo de variáveis e o alvo; o segundo evita lacunas artificiais que distorceriam correlações; o terceiro impõe que o teste seja geograficamente contí nuo na profundidade, o que aproxima o protocolo de um cenário em que se prevê porosidade abaixo de uma profundidade de corte usando apenas informação mais rasa. O quarto bloco estima o GBDT diretamente nas features físicas (sem escalonamento obrigatório); as predições nesse bloco alimentam as curvas da Secção 6. O quinto bloco calcula MAE, RMSE e R^2 no teste profundo e registra variantes sem V_p ou sem AI. O sexto bloco quantifica redundância e sensibilidade: as matrizes de correlação (treino) resumem acoplamento linear ou monótono; o VIF mede quasi-colinearidade num sistema linear auxiliar ajustado ao treino; a MI mede dependência estatí stica (não necessariamente linear) de cada preditor com a porosidade

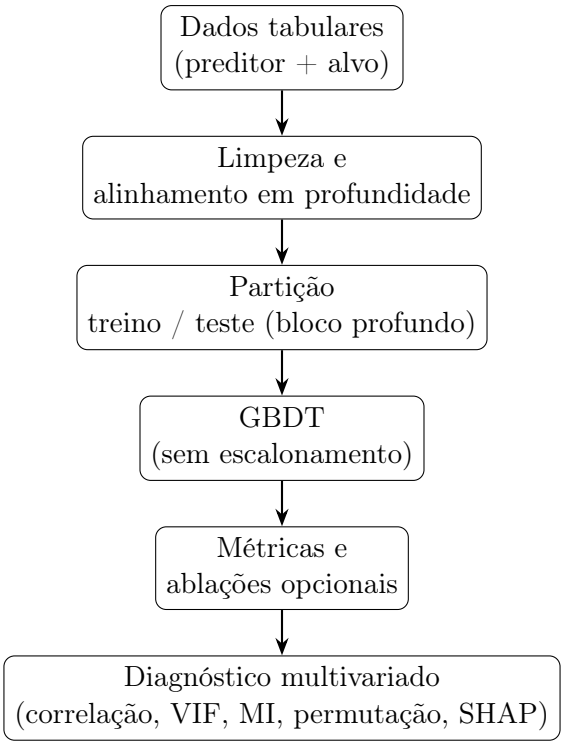

Figura 1: Sequência metodológica adotada neste ensaio.

no treino; a permutação mede o quanto o R^2 degrada ao destruir informação de um preditor de cada vez; o SHAP decompõe predições em contribuições aditivas locais no **espaço de entrada do modelo** (coincidente com as features originais neste protocolo). Assim, a Figura 1 não dispensa a narração: orienta a ordem em que os resultados das Secções 6 e 7 devem ser lidos.

4.3 Avaliação e ablação

A partição por profundidade reduz o vazamento espacial inerente a sorteios independentes em perfil quase contí nuo: o teste corresponde ao trecho mais profundo (20% das observações), onde a extrapolação a partir de padrões rasos é mais exigente do que numa partição aleatória i.i.d. (independentes e identicamente distribuí das entre observações).

Foram treinadas variantes do mesmo modelo com subconjuntos de preditores: todas as variáveis elásticas disponí veis; sem V_p; sem impedância; sem V_p e sem impedância conjuntamente. A comparação direta das métricas no teste responde à primeira questão levantada na Secção 3.

4.3.1 Bootstrap pareado no conjunto de teste

Para quantificar a incerteza amostral das métricas no bloco de teste profundo, mantendo o modelo GBDT já ajustado no treino e as predições $\hat{y}_i$ fixas, aplicou-se **bootstrap pareado**: sorteiam-se n í ndices do teste com reposição, recalculam-se MAE, RMSE e R^2 sobre o par $(y, \hat{y})$ reamostrado e repetem-se $B = 2000$ réplicas com semente pseudoaleatória fixa (`numpy`, semente 0). Os quantis empí ricos 2,5% e 97,5% definem intervalos bilaterais aproximados a 95%. Esta incerteza refere-se à variação das métricas sob reamostragem das observações de teste, **não** à variância de retreino do estimador nem à transferência

entre poços.

4.4 Diagnóstico multivariado

Para cada preditor j do conjunto elástico, o fator de inflação da variância (VIF) foi calculado a partir de uma regressão auxiliar linear de x_j face aos demais preditores **no conjunto de treino** (bloco raso), com

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{5}$$

em que R_j^2 é o coeficiente de determinação dessa regressão auxiliar. Valores muito elevados indicam que x_j é quase combinação linear dos outros preditores. Complementarmente, calcularam-se matrizes de correlação de Pearson e de Spearman **no treino** (figuras do recorte principal), a informação mútua (MI, *mutual information*) entre cada preditor e a porosidade **também no treino**, a importância por permutação da queda de R^2 no teste e um resumo SHAP (*SHapley Additive exPlanations*) obtido com explicador de árvore aplicado ao modelo GBDT ajustado. As correlações no conjunto completo (antes do corte) são exportadas como ficheiro auxiliar para EDA, mas não substituem as matrizes do treino nas figuras reportadas. A permutação e o SHAP reutilizam o mesmo modelo e o mesmo teste profundo. Sobre as features standardizadas do treino, uma PCA sintética indica que as duas primeiras componentes explicam cerca de 99,9% da variância acumulada, coerente com subespaço elástico de dimensão efetiva baixa; o número de condição (norma espectral) da matriz de correlação do treino é da ordem de 10^7, sinal de matriz mal condicionada alinhado aos VIF extremos.

5 Premissas e limitações

As curvas e a porosidade tratam-se como co-registradas na profundidade informada, sem corrigir deslocamentos instrumentais. O protocolo principal permanece, por construção, **intra-coluna** (corte vertical num único ficheiro). O ensaio *leave-one-well-out* da Tabela 3 aproxima exclusão mútua entre ficheiros, mas com apenas quatro poços não substitui um estudo de campo exaustivo: os R^2 por linha variam e um caso (F02-1 como teste) desvia substancialmente dos demais. O contraste entre recortes na Figura 6 compara qualidade de ajuste interno a cada coluna, não transferência aprendida numa coluna e testada na outra. Por fim, R^2 alto pode refletir acoplamento fí sico e redundância estatí stica, não independência informacional entre preditores. A informação mútua estimada por `mutual_info_regression` (mesma pilha numérica do ensaio) tem **magnitude absoluta** sensível a hiperparâmetros internos do estimador; no texto, a leitura prioritária é a **ordenação** entre preditores e a separação de ordens de grandeza, não a calibração de nats entre estudos distintos. O bootstrap no teste (Secção 4.3.1) quantifica incerteza amostral das métricas com modelo fixo; não incorpora variância de retreino nem generalização entre poços.

6 Resultados

6.1 Síntese numérica

A Tabela 1 reúne os indicadores no conjunto de teste profundo. No recorte principal, as quatro variantes apresentam desempenho praticamente idêntico: a remoção de V_p ou de impedância, isolada ou conjunta, não altera de forma substantiva MAE, RMSE nem R^2. Já no recorte de contraste, R^2 cai para a ordem de 0,95 com MAE e RMSE maiores, o que antecipa a discussão sobre dependência do intervalo litológico e da qualidade relativa das curvas.

A comparação entre a primeira linha da tabela (F03-4, baseline completa) e a última (F06-1, baseline completa) constitui apenas **contraste qualitativo** entre duas séries tabulares sob o **mesmo** protocolo interno (treino no trecho raso, teste no bloco profundo de 20%); **não** é validação cruzada entre poços nem transferência de um modelo aprendido num poço para outro.

Cenário (recorte principal, salvo nota)	MAE	RMSE	R^2
Todos os preditores elásticos	0,00053	0,00111	0,988
Sem V_p	0,00054	0,00111	0,988
Sem impedância	0,00054	0,00111	0,988
Sem V_p e sem impedância	0,00054	0,00111	0,988
Recorte de contraste (baseline completa)	0,00222	0,00456	0,945

Tabela 1: Desempenho no teste profundo (20% inferior da coluna). MAE (3) e RMSE (4) na unidade da porosidade; R^2 adimensional (2).

A Tabela 2 reporta intervalos aproximados a 95% (bootstrap pareado, $B = 2000$, Secção 4.3.1) apenas para a linha de **baseline completa** em cada recorte, isto é, o mesmo cenário da primeira linha da Tabela 1 e da última (F06-1).

Recorte (baseline completa)	IC 95% MAE	IC 95% RMSE	IC 95% R^2
F03-4	[0,00043, 0,00066]	[0,00090, 0,00132]	[0,9829, 0,9923]
F06-1	[0,00156, 0,00298]	[0,00333, 0,00573]	[0,9172, 0,9679]

Tabela 2: Bootstrap pareado no teste profundo ($B = 2000$, semente 0; $n = 287$ no F03-4 e $n = 116$ no F06-1). Limites: quantis empí ricos 2,5% e 97,5% das réplicas.

6.1.1 Robustez ao corte em profundidade

Mantendo o mesmo GBDT e o ficheiro F03-4, repetiu-se a partição com frações de teste profundo de 15%, 20% e 25%. O R^2 no teste oscilou entre 0,988 e 0,993 (MAE e RMSE na mesma ordem de grandeza), o que indica que a conclusão de ajuste forte **não** depende de um único ponto de corte na grelha considerada. Com `max_depth` $\in \{4, 6, 8\}$ e demais hiperparâmetros fixos, o R^2 no mesmo corte de 20% permanece na casa de 0,988, sugerindo que a leitura de redundância marginal não está ancorada num único valor de profundidade de árvore.

6.1.2 Exclusão mútua entre poços (*leave-one-well-out*)

Para aproximar a crítica de generalização **entre** colunas, treinou-se o mesmo tipo de GBDT na união de três ficheiros 7logs e testou-se no quarto, percorrendo os quatro poços disponíveis (F02-1, F03-2, F03-4, F06-1). O R^2 no poço retido varia substancialmente (Tabela 3): permanece elevado quando o teste é F03-2, F03-4 ou F06-1, mas cai para cerca de 0,96 quando o teste é F02-1, o que reforça que "R^2 alto" não é garantia automática de transferência entre contextos litológicos e instrumentais distintos.

Poço retido (teste)	n_{treino}	n_{teste}	MAE	R^2
F02-1	3595	445	0,00311	0,960
F03-2	2456	1584	0,00030	0,996
F03-4	2605	1435	0,00011	0,999
F06-1	3464	576	0,00013	1,000*

Tabela 3: LOO entre quatro ficheiros 7logs: treino na união dos outros três, teste no poço da linha. *Arredondamento a três casas; valor pontual 0,999845.

6.2 Perfil de porosidade observada e prevista

As Figuras 2 a 5 mostram, para o recorte principal, a porosidade observada e a curva prevista ao longo da profundidade, com linha de corte entre treino e teste. Visualmente, a coincidência no trecho profundo é marcada em todas as variantes, o que é coerente com os números da Tabela 1. A Figura 6 transporta o mesmo tipo de painel para o recorte de contraste: observa-se maior dispersão relativa entre observado e previsto, alinhada à queda de R^2 na última linha da tabela. O contraste visual com a Figura 6 reforça o mesmo aviso: duas colunas tratadas isoladamente com o mesmo procedimento, sem inferência de transportabilidade entre poços.

6.3 Estrutura de correlação e colinearidade

As Figuras 9 e 10 evidenciam correlações lineares e monótonas quase unitárias entre AC, ρ_b, impedância e V_p, bem como correlação forte deste bloco com a porosidade **no recorte principal**. O padrão sustenta a hipótese de um subespaço elástico de dimensão efetiva baixa neste conjunto: várias colunas movem-se em conjunto, em vez de oferecer direções independentes no espaço das variáveis.

A Tabela 4 traduz essa leitura em termos de (5): fatores da ordem de 10^5 a 10^6 para AC, ρ_b, impedância e V_p não devem ser tomados como magnitudes calibradas de um modelo linear final. Dado o nível extremo de colinearidade, os **valores absolutos** de VIF perdem interesse quantitativo fino e devem ser lidos apenas como **marcadores de degenerescência severa** do sistema linear auxiliar; comparações finas entre, por exemplo, $7{,}0 \times 10^5$ e $1{,}1 \times 10^5$ não devem ser interpretadas como diferença substancial de "grau de colinearidade". Para GR e V_c, os VIF permanecem elevados face ao limiar usual da ordem de dez, coerente com a forte associação mútua observada nas matrizes.

6.4 Dependência entre GR e V_c: postos e empates

O par GR–V_c aparece nas matrizes de correlação com associação forte, mas a leitura sob **empates nos postos** (vários pontos com o mesmo valor, logo o mesmo posto após

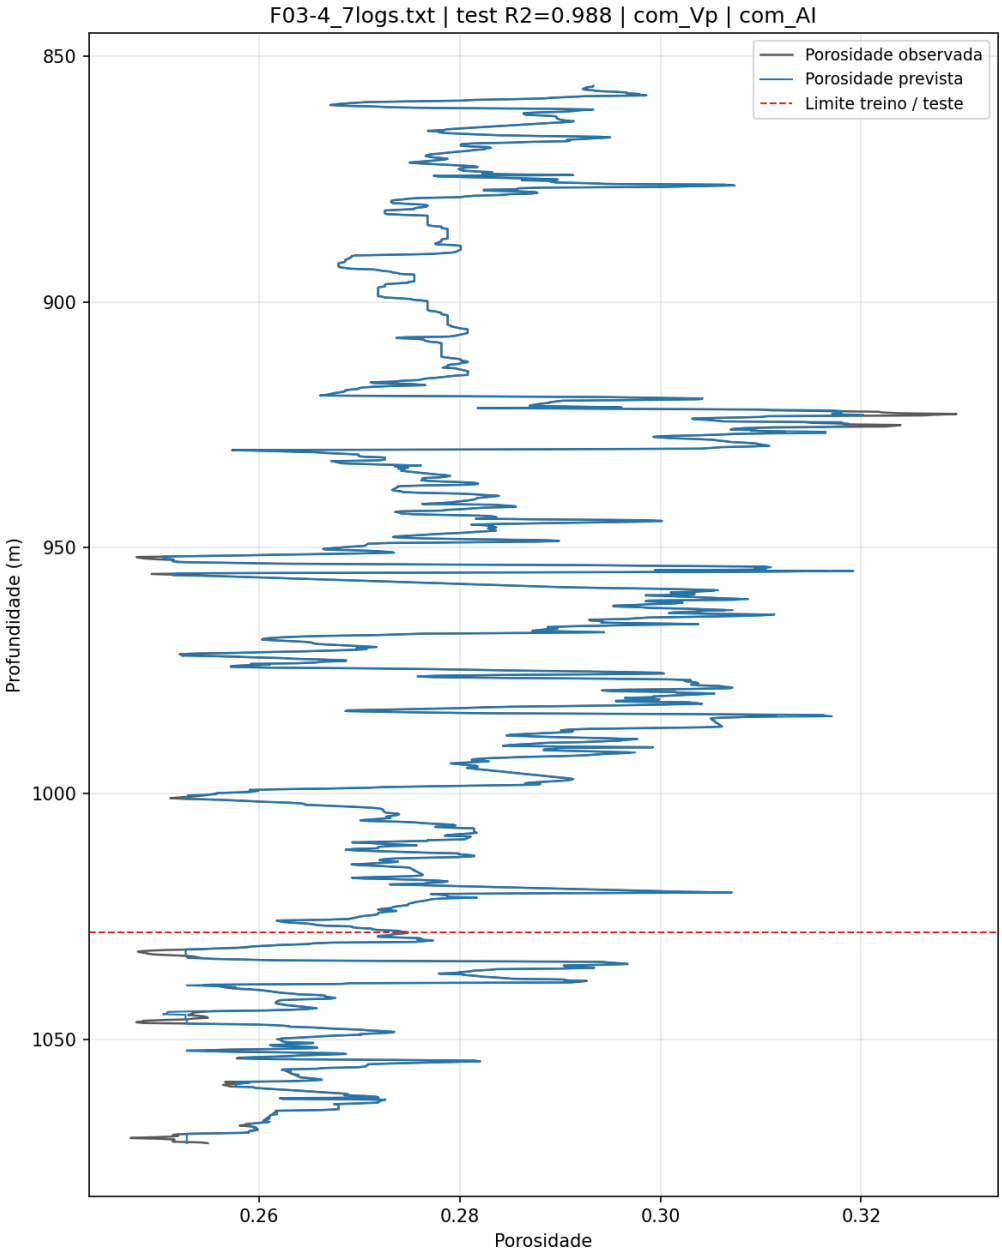

Figura 2: Recorte principal: porosidade observada e prevista com todos os preditores elásticos disponí veis.

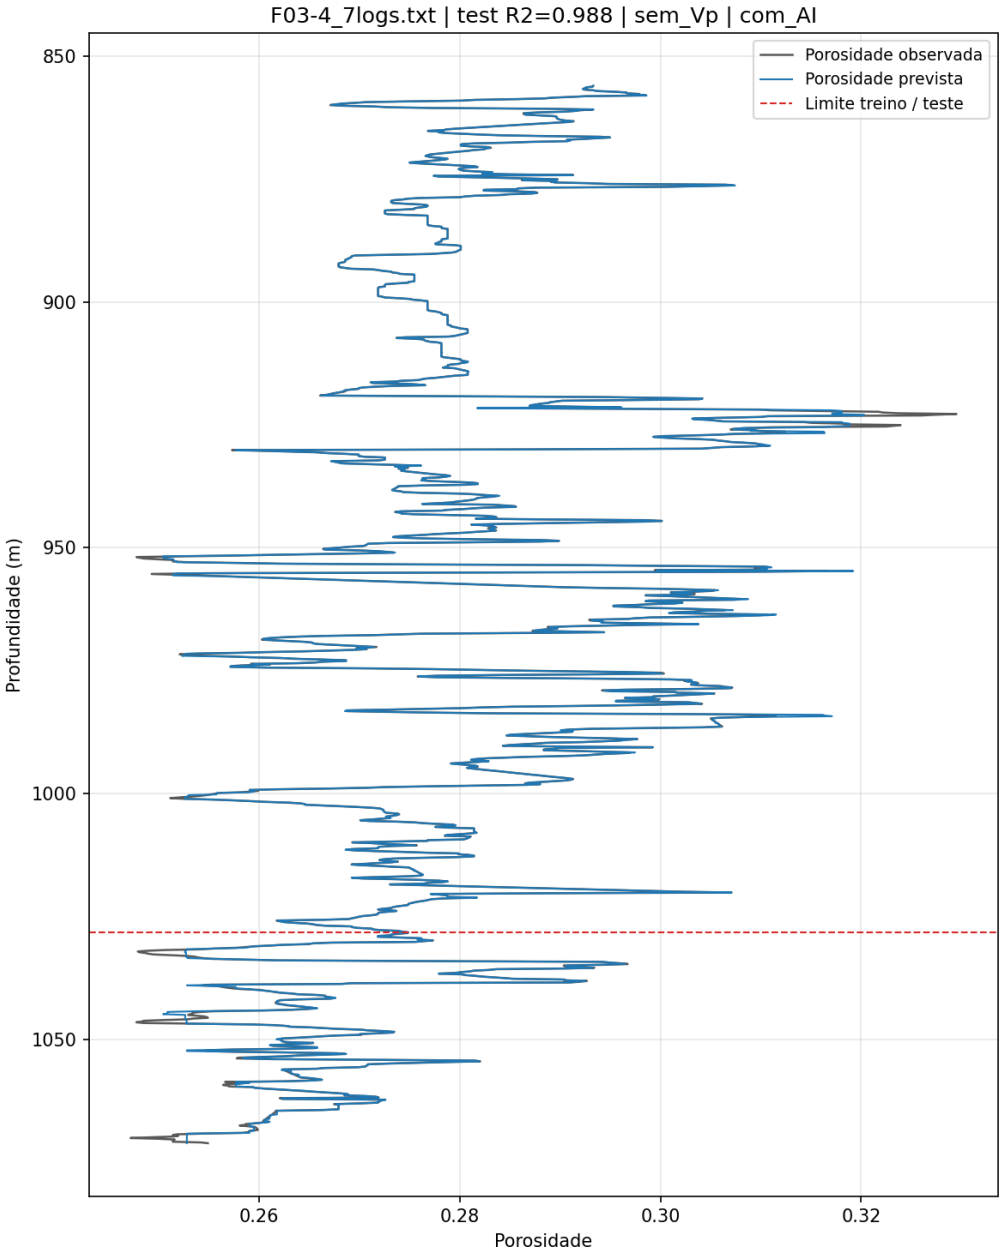

Figura 3: Recorte principal: modelo sem V_p.

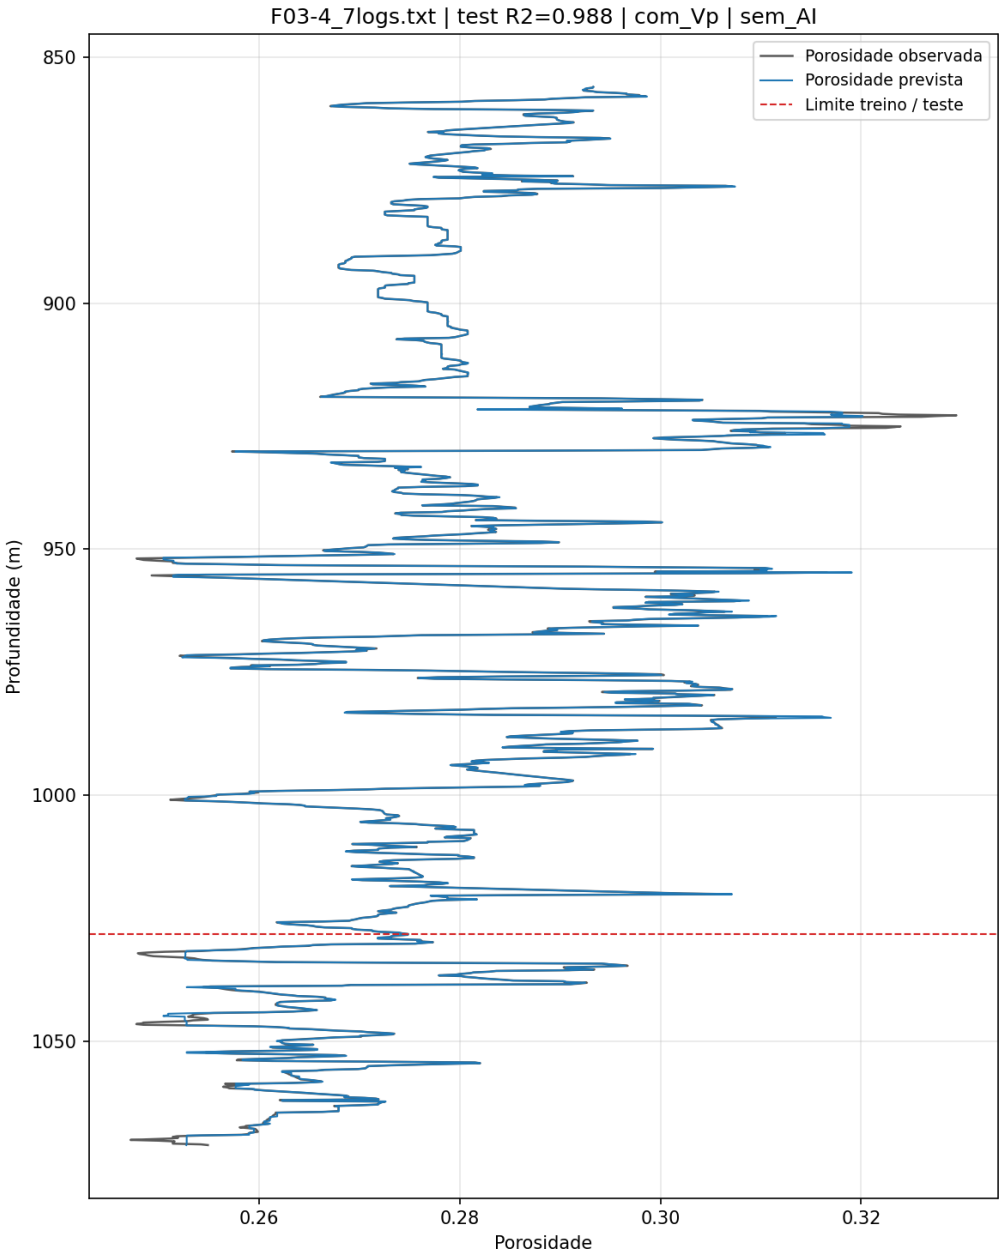

Figura 4: Recorte principal: modelo sem impedância acústica.

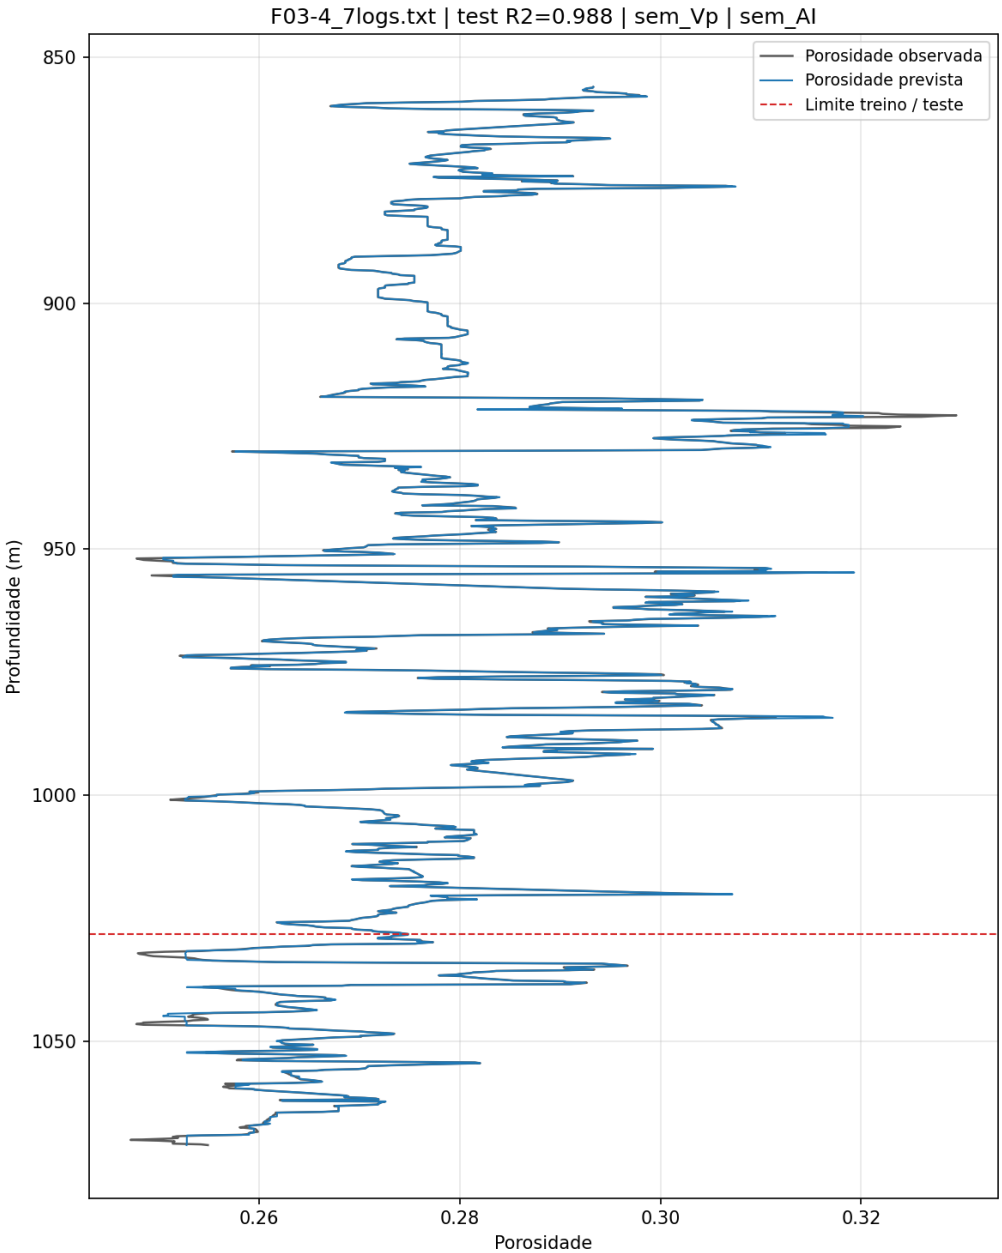

Figura 5: Recorte principal: modelo apenas com AC, ρ_b, GR e V_c.

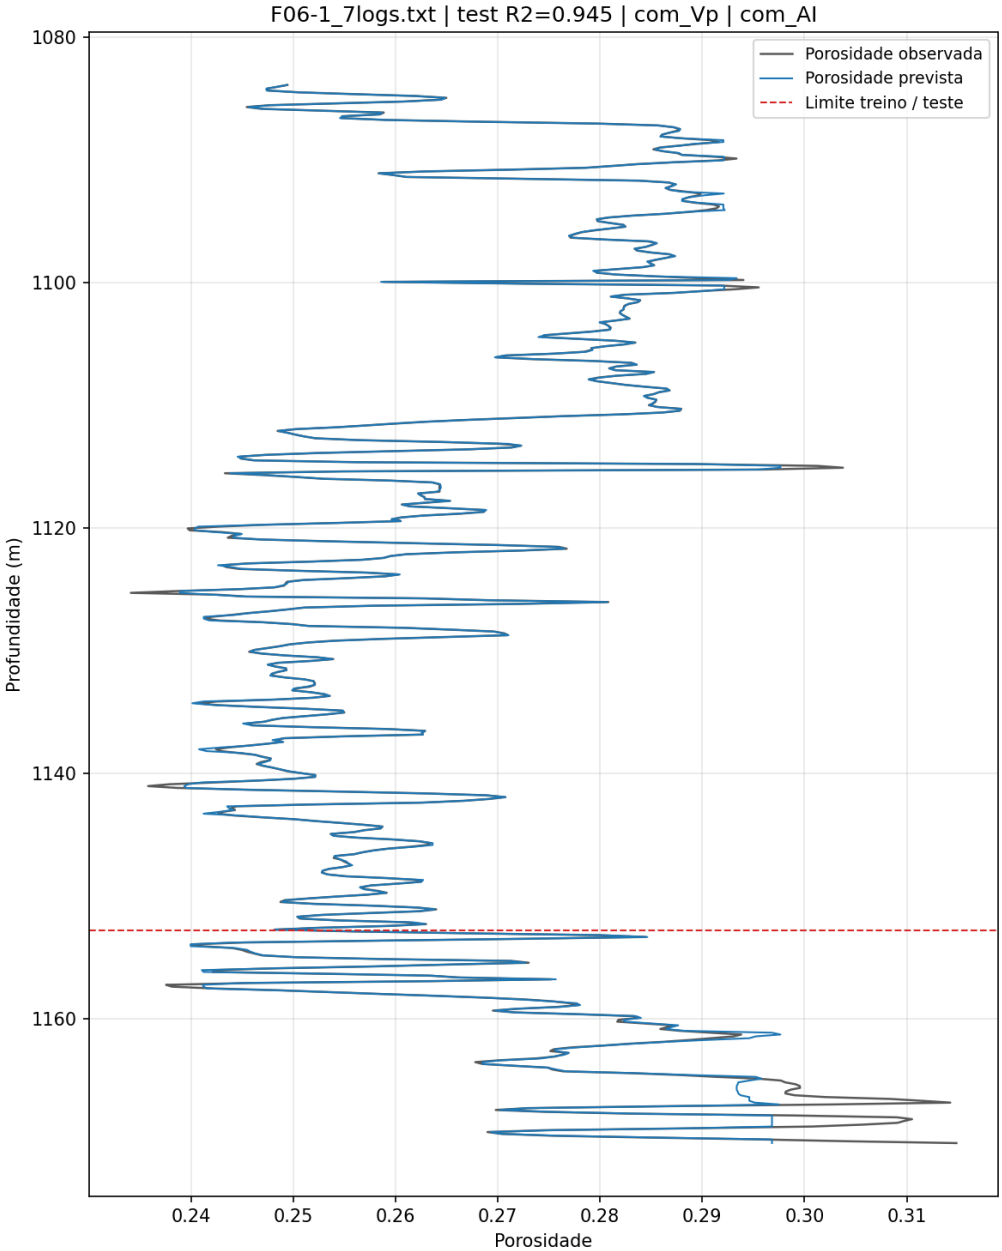

Figura 6: Recorte de contraste: baseline completa.

Preditor	VIF (ordem de grandeza)
AC	$7{,}0 \times 10^5$
ρ_b	$7{,}0 \times 10^5$
Impedância	$1{,}1 \times 10^5$
V_p	$1{,}1 \times 10^5$
GR	$8{,}3 \times 10^1$
V_c	$8{,}2 \times 10^1$

Tabela 4: Fatores VIF aproximados no recorte principal (treino, bloco raso), calculados por (5).

ranking) e sob **desempates** extremos (*min* e *max* do `rankdata`) informa se a dependência seria artefato numérico ou se permanece quase determiní stica.

No recorte principal, sobre o mesmo conjunto 7logs já filtrado por linhas completas, calcularam-se estatí sticas de empates, correlações de Pearson, Spearman e Kendall, correlações parciais via correlação entre resíduos de regressões lineares ordinárias (controlo pela profundidade; controlo adicional pelo bloco elástico em bruto; variantes em que preditores e profundidade entram como postos médios), e uma estabilidade de Spearman sob *jitter* uniforme minúsculo repetido (80 sorteios, escala da ordem de 10^{-8} face à amplitude das curvas). As tabelas seguintes consolidam os indicadores dessa etapa para o recorte principal.

Coluna	n	valores distintos	fração em empates	multiplicidade máx.
GR	1435	1110	0,298	23
V_c	1435	1110	0,298	23

Tabela 5: Empates nos valores brutos: GR e V_c compartilham a mesma cardinalidade de valores distintos e a mesma fração de linhas em empates (recorte principal).

A Tabela 5 mostra que GR e V_c não são meramente correlacionados: compartilham **exatamente** o mesmo número de valores distintos, a mesma fração de linhas em empates e a mesma multiplicidade máxima, o que é compatível com V_c construí do a partir de GR (ou inversamente) com a mesma grelha de quantização. A Tabela 6 confirma uma relação quase monótona perfeita (Spearman e Kendall unitários) e mantém correlação parcial elevada mesmo depois de linearizar profundidade ou o bloco elástico, pelo menos no esquema de controlo linear adotado. Uma regressão isotônica crescente $V_c \approx f(\mathrm{GR})$ ajustada aos mesmos dados atinge R^2 praticamente unitário e erro de reconstrução desprezível na precisão numérica exportada, o que quantifica a redundância monótona além das correlações clássicas. **No recorte principal, GR e V_c não devem ser tratados como eixos independentes de informação:** a evidência sugere que um deles é, na prática, quase inteiramente reconstruí vel a partir do outro, de modo que mantê-los simultaneamente pode inflar artificialmente a dimensão aparente do espaço de atributos. A Tabela 7 mostra que a escolha de desempate (*average*, *min*, *max*) quase não move o coeficiente; o *jitter* deixa a Spearman estável na unidade até 10^{-6}.

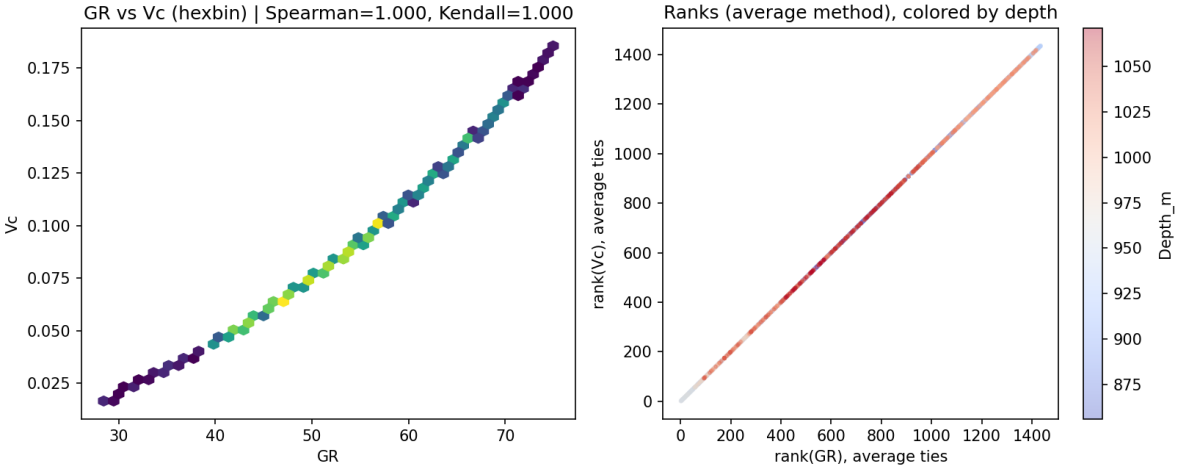

Figura 7: GR versus V_c (hexbin) e postos médios com cores por profundidade. Spearman e Kendall próximos de um indicam monotonia quase perfeita no recorte.

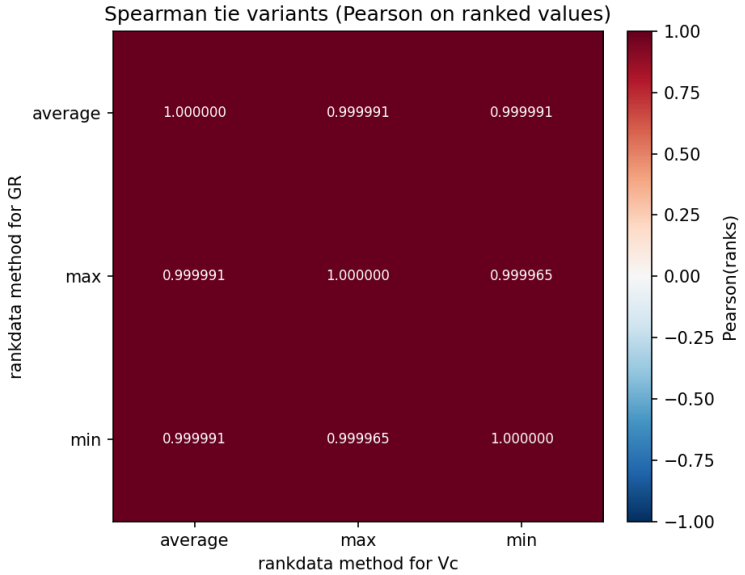

Figura 8: Mapa de calor da matriz da Tabela 7: sensibilidade da correlação de Pearson aplicada a pares de postos, com coeficientes anotados em cada célula (seis casas decimais).

Medida	Notação / controlo	Valor
Pearson (bruto)	$\rho_{GR,Vc}$	0,993
Spearman	ρ_S	1,000
Kendall	τ	1,000
Parcial (bruto)	resíduos OLS; controlo: profundidade	0,993
Parcial (postos)	resíduos OLS em postos médios; controlo: posto(prof.)	1,000
Parcial (bruto)	resíduos OLS; controlo: AC, ρ_b, AI, V_p	0,992
Parcial (postos)	postos médios; controlo: prof. e elásticos (postos)	1,000
Spearman + *jitter*	média de 80 sorteios	0,999992
	desvio-padrão	$8{,}6 \times 10^{-7}$

Tabela 6: Associação GR–V_c e correlações parciais lineares (resíduos OLS; controlo **linear** apenas, sem equivalência a independência condicional geral). Com monotonia empí rica quase perfeita entre GR e V_c, os p-valores dos testes de Spearman e de Kendall (hipótese de independência) ficam abaixo do que a aritmética de ponto flutuante distingue de zero, aparecendo como 0 na tabela.

posto(GR) \ posto(V_c)	*average*	*min*	*max*
average	1,000000	0,999991	0,999991
min	0,999991	1,000000	0,999965
max	0,999991	0,999965	1,000000

Tabela 7: Sensibilidade ao desempate: Pearson entre postos definidos com `rankdata(..., method)` (*scipy*); valores fora da diagonal diferem só na séxta casa decimal.

6.5 Informação mútua, permutação e SHAP

A informação mútua (MI) entre cada preditor e a porosidade concentra-se em valores elevados e muito próximos entre si para AC, ρ_b, impedância e V_p, enquanto GR e V_c ficam num patamar inferior, porém não nulos. A leitura relevante da MI é **ordinal e comparativa** entre preditores (ordenação e separação entre blocos), e não o valor absoluto em nats como grandeza transportável entre estudos. A Tabela 8 quantifica essa separação: os quatro preditores elásticos ficam na casa de 5,3 nats (arredondamento à segunda casa; MI estimada no treino), enquanto GR e V_c permanecem perto de 0,51, isto é, magnitudes cerca de dez vezes menores no mesmo ajuste MI. Isto reforça que, **no recorte principal**, o bloco elástico compartilha quase o mesmo conteúdo informativo sobre o alvo, ao passo que GR e V_c introduzem um eixo litológico mais fraco neste recorte, sem ser nulo.

A Figura 11 sintetiza a importância por permutação (25 repetições no teste profundo). A Tabela 9 traduz a figura em números: a queda média de R^2 ao baralhar AC é da ordem de 1,30, com desvio-padrão de 0,06, enquanto ρ_b aparece distante, mas ainda positiva ($\approx 0{,}05$). AI e V_p têm quedas médias uma ordem de grandeza menores; V_p fica na casa de 10^{-5}, compatível com ausência de contribuição marginal detectável à escala do ruí do de permutação. GR exibe média ligeiramente negativa ($\approx -9 \times 10^{-4}$), compatível com flutuação estatí stica em torno de zero quando o preditor é redundante; V_c registra queda

Preditor	MI com porosidade (nats, arred.)
AC	5,30
ρ_b	5,43
AI	5,28
V_p	5,30
GR	0,52
V_c	0,51

Tabela 8: MI estimada no conjunto de treino (bloco raso, mesma partição que as Figuras 9–10). Valores arredondados; ver limitações na Secção 5.

média nula na precisão exportada, coerente com o acoplamento quase determiní stico a GR já documentado.

Em presença de colinearidade forte, a importância por permutação mede contribuição **marginal** condicionada ao restante dos preditores e, por construção, tende a **subestimar** variáveis cuja informação já foi absorvida por colunas correlacionadas; quedas quase nulas em AI e V_p não equivalem a ausência fí sica de conteúdo informativo, mas sim a redundância preditiva face a AC e ρ_b neste ajuste.

Preditor	Queda média de R^2	Desvio-padrão
AC	1,298	0,064
ρ_b	0,050	0,005
AI	0,0056	0,0010
V_p	$2{,}9 \times 10^{-5}$	$3{,}4 \times 10^{-6}$
GR	$-9{,}1 \times 10^{-4}$	$3{,}3 \times 10^{-4}$
V_c	0,000	0,000

Tabela 9: Importância por permutação no teste profundo (25 repetições). O ficheiro exportado inclui a coluna booleana `likely_redundant_or_noise` quando a queda média de R^2 não é positiva.

A Figura 12, no mesmo modelo GBDT e no recorte principal, mostra que AC emerge como o principal **carregador de informação preditiva marginal** na base explicada: a nuvem de SHAP para AC ocupa faixa horizontal visivelmente mais larga do que as de AI, V_p e ρ_b, sinal de que pequenas variações de AC se traduzem em variações grandes no valor de Shapley ao longo das observações do teste. Isto não atribui a AC o papel de "variável certa" em sentido absoluto, apenas descreve o modelo ajustado neste protocolo. AI e V_p aparecem como faixas estreitas centradas perto de zero, coerente com a redundância frente a AC e densidade. ρ_b mostra dispersão intermediária, refletindo o papel secundário mas não nulo visto na permutação. GR e V_c mantém dispersão modesta e parcialmente sobreposta, alinhada à MI baixa e à quase colinearidade entre si: o SHAP deve ser lido como explicação *local* do ajuste, não como atribuição causal fí sica.

7 Discussão

A estabilidade das métricas na Tabela 1, percorrida em paralelo com as ablações ilustradas nas Figuras 3–5, indica que, **no recorte principal** e sob o protocolo treino/teste em

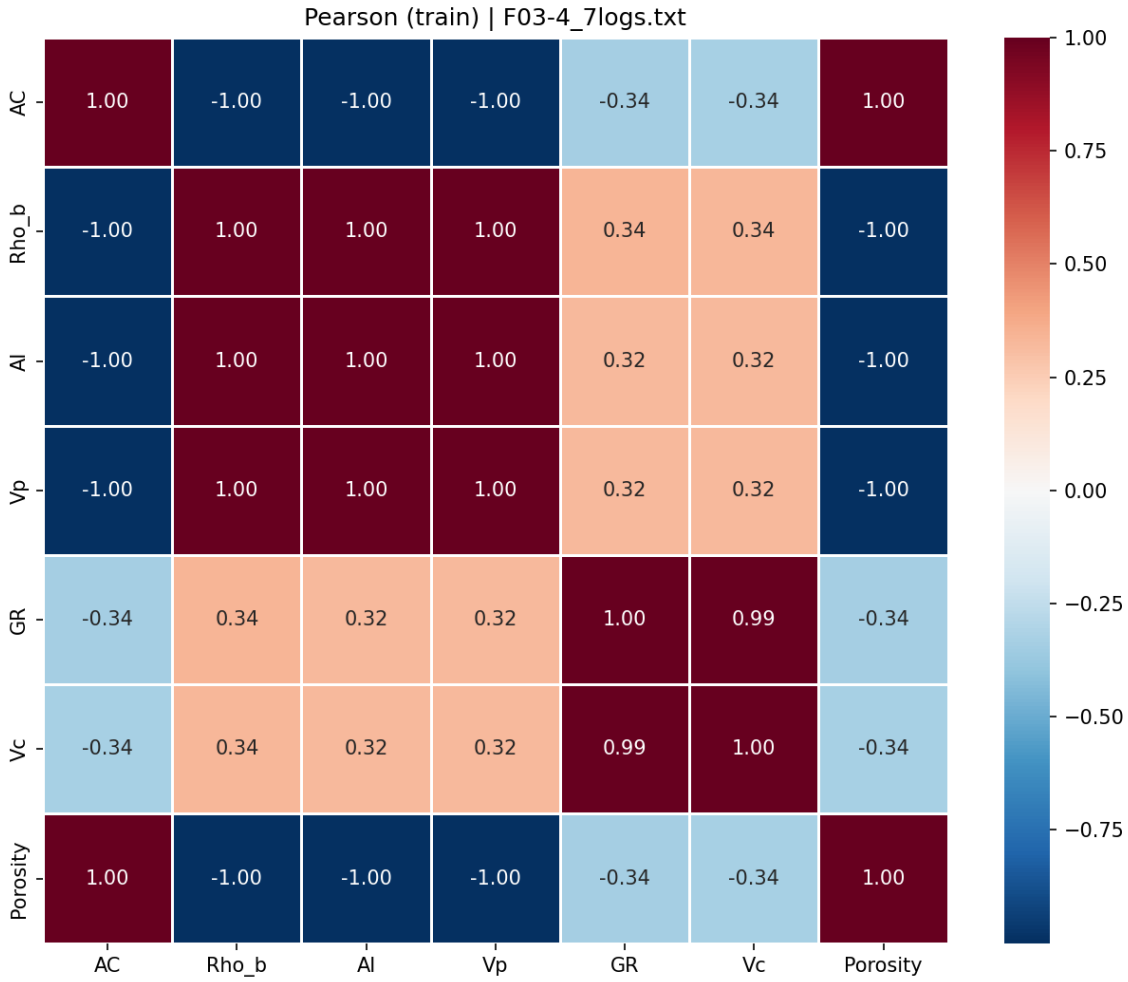

Figura 9: Correlações de Pearson entre preditores e porosidade (recorte principal).

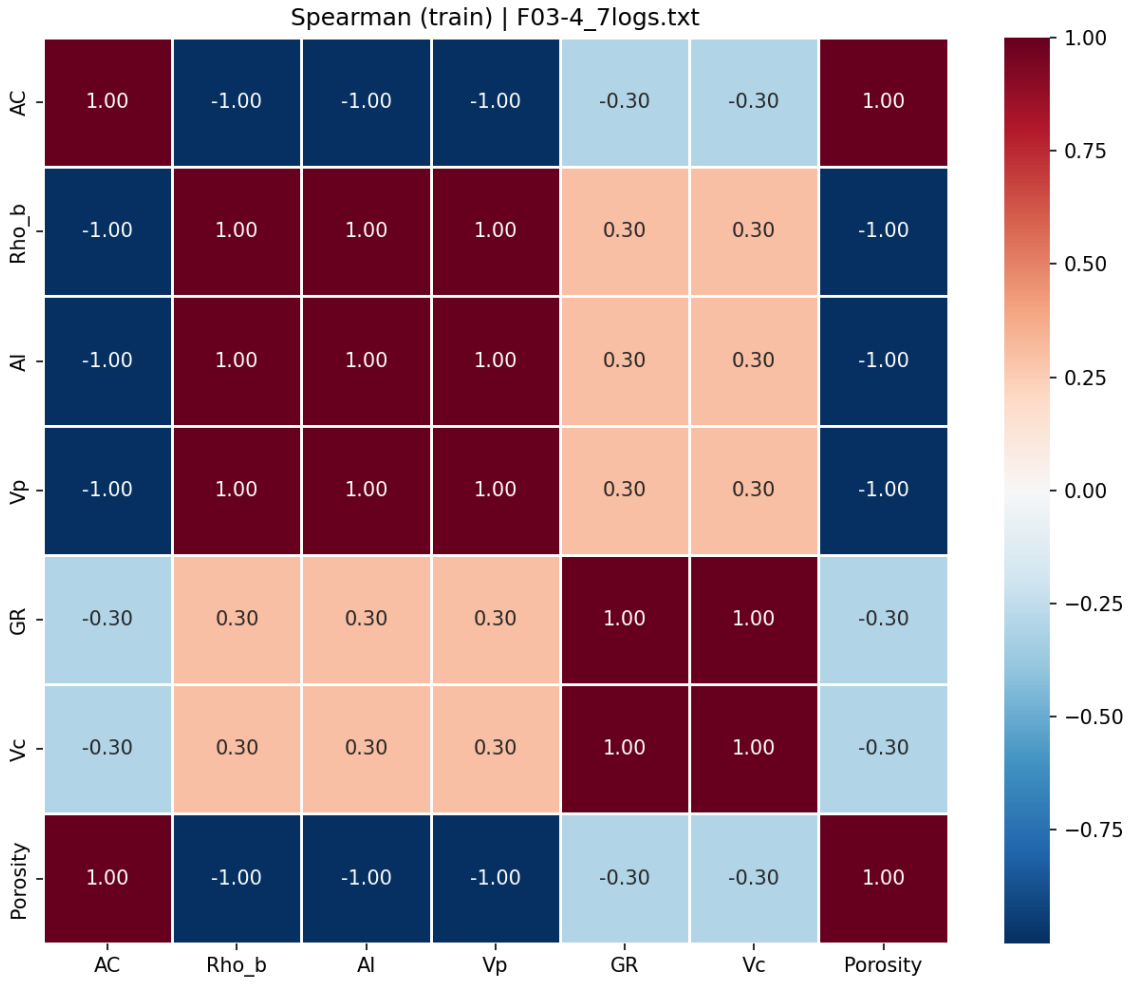

Figura 10: Correlações de Spearman (recorte principal).

profundidade, V_p e a impedância não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já estão disponí veis com a qualidade relativa destas curvas. Não se trata de desvalorizar medidas fí sicas centrais: o experimento não implica irrelevância fí sica de V_p ou de AI, mas sim ausência de contribuição preditiva marginal detectável neste contexto, dado o forte acoplamento dessas grandezas com AC e densidade.

A Secção 6 fornece a evidência multivariada que sustenta esta leitura: correlações quase unitárias no bloco elástico (Figuras 9 e 10), VIF extremos na Tabela 4, MI ordenada como na Tabela 8, quedas de R^2 por permutação como na Tabela 9 e na Figura 11, e resumo SHAP (Figura 12) coerente com essa hierarquia. Em conjunto, estas linhas de evidência fecham o ciclo lógico entre a pergunta formulada na Secção 3 e o desenho metodológico da Figura 1.

A subsecção 6.4 aprofunda o par GR–V_c sob a ótica de empates nos postos e de desempates extremos. As Tabelas 5–7 e as Figuras 7 e 8 mostram estrutura de empates idêntica entre colunas, Spearman e Kendall próximos de um e correlação parcial ainda elevada após controlo linear pela profundidade ou pelo bloco elástico, o que reforça que, neste recorte, GR e V_c não funcionam como preditores litológicos independentes no espaço de entrada.

O contraste com a Figura 6 e a última linha da Tabela 1 mostra que o nível de R^2 não é propriedade universal do modelo: depende do recorte. Daí a cautela ao extrapolar conclusões entre colunas distintas sem protocolo de exclusão mútua no treino.

Contraste entre recortes F03-4 e F06-1. No recorte principal (F03-4), após remoção de linhas incompletas, restam $n = 1435$ profundidades entre 856 e 1071 m, com porosidade média 0,278 e desvio-padrão 0,014. No recorte de contraste (F06-1), $n = 576$ entre 1084 e 1170 m, com porosidade média 0,267 e desvio 0,017. A janela vertical é distinta e o segundo conjunto é menor; a porosidade apresenta dispersão relativa ligeiramente maior no F06-1. Estes fatos não explicam por si sós toda a queda de R^2 na Tabela 1, mas mostram que o teste profundo (20%) corresponde a litologias, profundidades e tamanhos amostrais diferentes, pelo que o R^2 deixa de ser comparável como se fosse repetição do mesmo experimento. Complementou-se essa comparação com o bootstrap pareado da Secção 4.3.1 (Tabela 2): os intervalos aproximados a 95% para R^2 **não se sobrepêm** entre F03-4 e F06-1 (limite superior 0,9679 versus limite inferior 0,9829), o que sustenta que a diferença pontual entre 0,988 e 0,945 não se explica apenas por flutuação de amostragem *dentro* de cada coluna sob esta reamostragem. O aviso metodológico permanece: estes intervalos não substituem validação por exclusão de poço.

Limite principal. O ensaio caracteriza **robustez interna** ao recorte e ao protocolo adotado; não caracteriza **transferência entre poços** nem domínio geológico alargado. O teste profundo, por mais exigente que seja face a um sorteio i.i.d., permanece intra-coluna: esta limitação deve pesar em qualquer extrapolação além do material tabular analisado.

8 Conclusões

No recorte principal, o modelo atinge R^2 elevado no teste profundo e mantém esse desempenho ao remover V_p ou impedância, o que é explicado, não contradito, pela colinearidade forte documentada nas Figuras 9 e 10 e pelos VIF da Tabela 4. A MI (Tabela 8) e as quedas de R^2 por permutação (Tabela 9 e Figura 11), juntamente com

o SHAP (Figura 12), indicam que, **no modelo ajustado e neste recorte**, AC emerge como o principal carregador de informação preditiva marginal, enquanto a maior parte da variância explicada no teste flui por um eixo elástico estreito no qual AI e V_p ficam preditivamente redundantes face a AC e ρ_b, sem afastar a sua relevância fí sica em outros contextos ou com outras qualidades de aquisição.

O recorte de contraste lembra que a generalização espacial ou entre contextos exige desenho experimental próprio; o presente ensaio não o substitui. Os IC de bootstrap no teste (Tabela 2) reforçam que o contraste de R^2 entre recortes não é compatível com intervalos sobrepostos sob a reamostragem adotada, sem por isso afastar a necessidade de protocolos entre poços. A revisão de dependência entre GR e V_c sob postos e empates (Secção 6.4) confirma quase redundância formal entre esses preditores no recorte principal.

O ensaio caracteriza robustez interna ao recorte e **não** transferência entre poços; esta última permanece etapa futura necessária. Como próximos passos, **recomenda-se**: (i) validação *leave-one-well-out* ou equivalente com exclusão mútua de poços no treino; (ii) repetição do mesmo protocolo em múltiplos recortes e múltiplas colunas, para verificar estabilidade do diagnóstico de redundância; (iii) quando possível, substituir ou complementar a porosidade-alvo por referência menos acoplada às curvas elásticas usadas como entrada.

Referências

- Pedregosa et al., Scikit-learn: Machine Learning in Python, *Journal of Machine Learning Research*, 2011.
- Lundberg, S. M.; Lee, S.-I., A Unified Approach to Interpreting Model Predictions, *Conference on Neural Information Processing Systems* (NeurIPS), 2017.

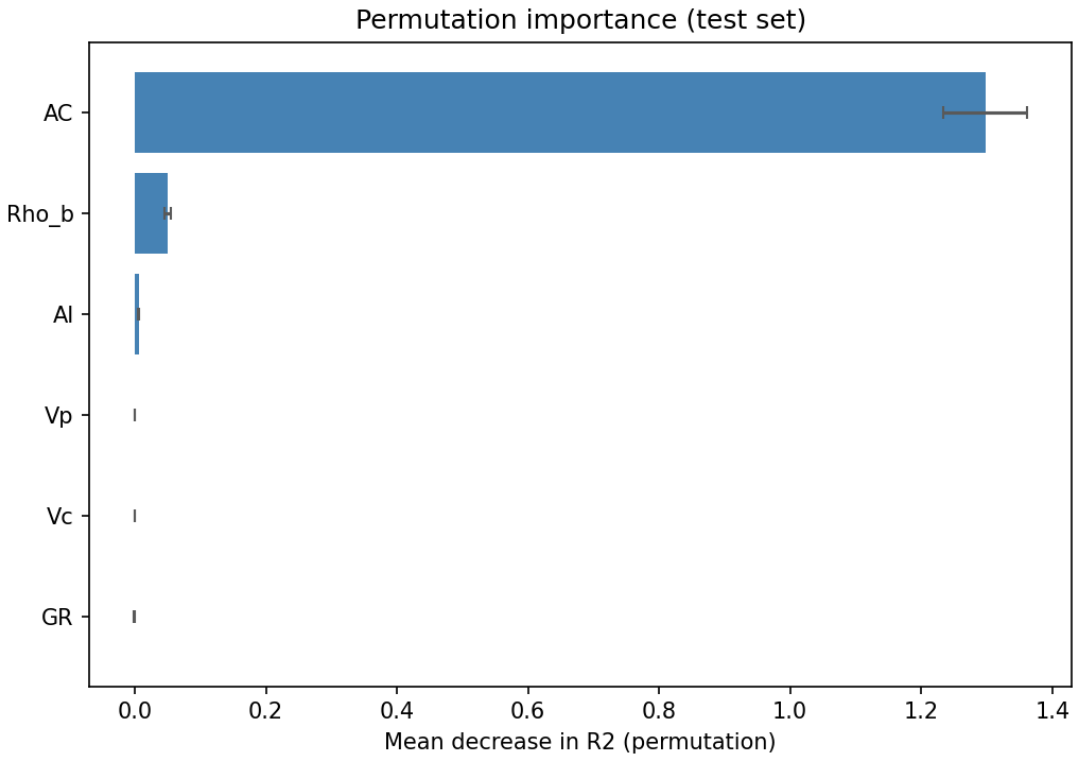

Figura 11: Importância por permutação: queda média de R^2 no teste ao baralhar cada preditor.

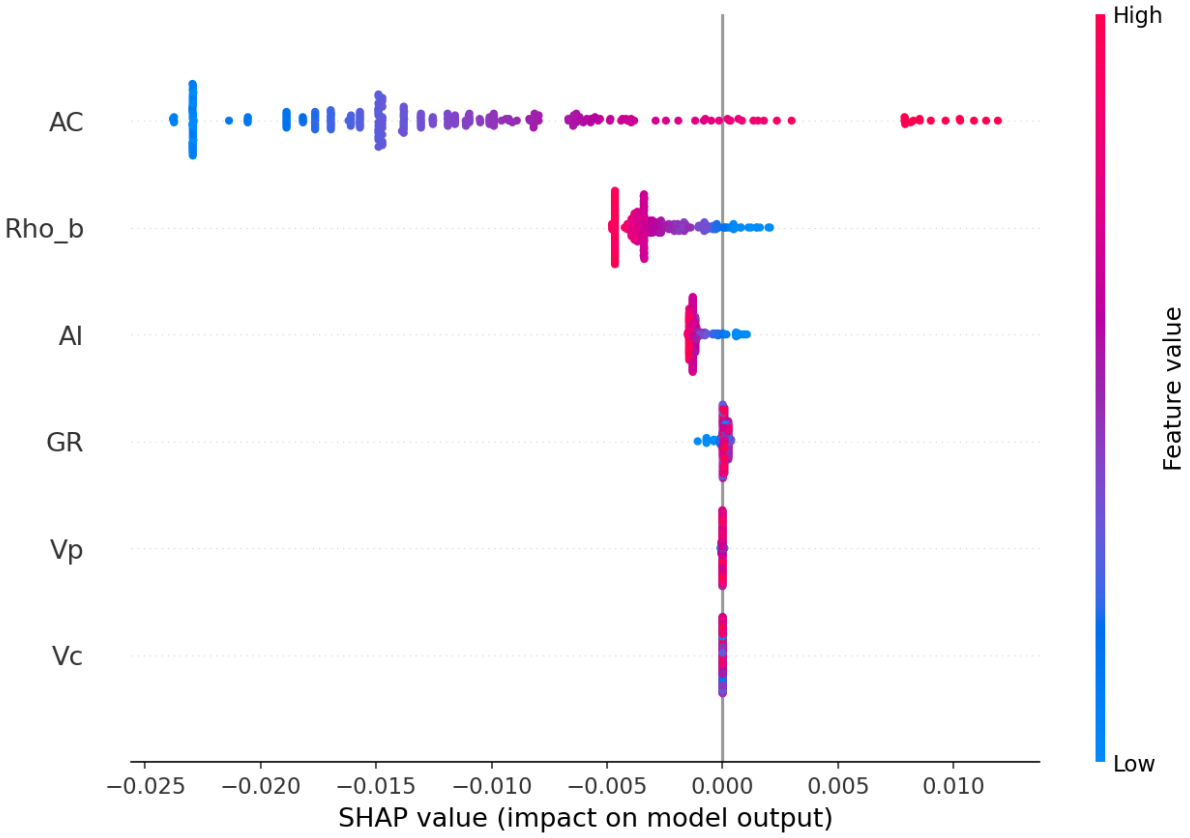

Figura 12: Resumo SHAP (*SHapley Additive exPlanations*) no conjunto de teste profundo (287 observações).