Regressão supervisionada de porosidade a partir de perfis convencionais: diagnóstico de colinearidade e leitura crítica das métricas

15 de abril de 2026

Resumo

Trata-se do registro analítico de um ensaio de regressão para estimar porosidade a partir de curvas de perfilagem: intervalo de trânsito sônico (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade da onda de compressão P (V_p), raio gama (GR) e variável associada à fração argilosa (V_c). O ajuste emprega um modelo GBDT (*Gradient Boosting Decision Trees*, conjunto de árvores de decisão com reforço por gradiente, aqui na variante baseada em histogramas). A avaliação usa partição treino–teste ao longo da profundidade; por **teste profundo**, equivalente neste documento a **bloco de teste profundo**, entende-se o conjunto das 20% observações com maior profundidade após ordenar o conjunto tabular pela profundidade mecânica registada ao longo da coluna, mantendo o treino na fração rasa complementar. Descrevem-se ainda ablações de preditores e o diagnóstico multivariado: correlações de Pearson e de Spearman e fator de inflação da variância (VIF) no treino; informação mútua (MI) entre cada preditor e a porosidade também no treino; importância por permutação do coeficiente de determinação (R^2) no teste, e valores SHAP (*SHapley Additive exPlanations*, decomposição aditiva do efeito de cada preditor com base em Shapley). Complementam o quadro, no conjunto de teste profundo, o erro absoluto médio (MAE, do inglês *mean absolute error*) e a raiz do erro quadrático médio (RMSE, *root mean squared error*). No **recorte principal**, sob partição treino–teste ao longo da profundidade e com as curvas tal como apresentadas nas figuras deste relatório, V_p e a impedância acústica (AI) não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já entram no modelo: o R^2 no teste profundo permanece praticamente inalterado após retirá-los. Isto documenta redundância preditiva **local** nesse protocolo, não irrelevância física universal dessas grandezas. A leitura das ablações e do diagnóstico multivariado no recorte principal permanece ancorada a esse protocolo intra-coluna. Complementarmente, uma validação LOO entre quatro conjuntos de dados 7logs (tabela no texto) indica encaixe elevado em cada poço retido, com heterogeneidade moderada entre colunas; isso não substitui estudos alargados nem afirma independência geológica plena entre esses quatro poços.

1 Introdução

A porosidade controla, com mineralogia e fluido, a resposta elástica efetiva da rocha. Em colunas perfiladas, relações empíricas entre porosidade e grandezas sônicas ou de densidade

são esperadas; o mesmo vale para grandezas derivadas da combinação massa–rigidez, como a impedância acústica (AI) e a velocidade da onda de compressão P (V_p). Daí decorre um risco metodológico: modelos supervisionados podem atingir erros baixos no teste sem que isso signifique, por si só, que cada preditor contribua com informação independente.

Os achados de ablação não implicam irrelevância física de V_p ou de AI, mas sim **ausência de contribuição preditiva marginal detectável** no recorte considerado, dado o forte acoplamento dessas grandezas com AC e ρ_b e a qualidade relativa das curvas usadas como entrada.

O objetivo deste texto é documentar, com rigor modesto porém explícito, um baseline de regressão e o diagnóstico que o acompanha. Pretende-se responder, com base em números e figuras, se a retirada isolada de V_p ou da impedância acústica (AI) altera o desempenho, e se correlações e o fator de inflação da variância (VIF) sustentam a leitura de redundância entre preditores. Inclui-se ainda um contraste entre dois recortes verticais distintos e uma validação LOO entre quatro conjuntos de dados 7logs, para lembrar que a leitura entre contextos não se resume a R^2 elevado num único intervalo nem implica transferência homogénea entre colunas.

2 Quadro teórico sucinto

Em meio efetivo, a impedância acústica Z relaciona massa volumétrica ρ e velocidade V segundo

$$Z = \rho V. \tag{1}$$

Quando ρ e V são estimados a partir das mesmas observações que alimentam o intervalo de trânsito, a informação trazida por Z tende a sobrepor-se à de V e à de ρ, em vez de acrescentar graus de liberdade estatísticos novos.

Para avaliar o ajuste global no teste, utilizou-se o coeficiente de determinação

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}, \tag{2}$$

onde y_i é a porosidade observada, $\hat{y}_i$ a predição e $\bar{y}$ a média amostral no conjunto de teste de cardinalidade n. O erro absoluto médio (MAE) foi

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{3}$$

isto é, o erro absoluto médio (MAE, do inglês *mean absolute error*). A raiz do erro quadrático médio (RMSE, *root mean squared error*) foi

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}\,. \tag{4}$$

Estas grandezas resumem o encaixe, mas não distinguem, por si só, contribuição marginal de preditores correlacionados.

3 Questões de trabalho

Colocam-se as seguintes questões, respondidas na Secção 7 com apoio nas Figuras 2–12 e na Tabela 1:

1. O erro de generalização no bloco de teste profundo muda de forma relevante quando se retira V_p, quando se retira a impedância, ou ambas?
2. As estruturas de correlação e o fator de inflação da variância (VIF, medida clássica de colinearidade em regressão linear auxiliar) indicam colinearidade forte o suficiente para explicar a estabilidade de R^2 sob ablação?
3. A importância por permutação do R^2 e o resumo SHAP (*SHapley Additive exPlanations*) apontam para um preditor dominante entre os elásticos?
4. O mesmo protocolo, aplicado a um segundo recorte vertical, produz R^2 sensivelmente diferente?

4 Metodologia

4.1 Dados e variáveis

Utilizou-se um perfil tabular com **seis** preditores — intervalo de trânsito (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade V_p, raio gama (GR) e variável associada à argila (V_c) — e **porosidade** como alvo.

As rotinas de leitura e filtragem usadas na preparação exploratória admitem esquemas 3logs, 6logs e 7logs; contudo, as inferências centrais deste relatório limitam-se a **recortes tabulares 7logs completos** (em particular F03-4 e F06-1 no texto principal), sem pretender que conclusões obtidas nesse esquema se estendam automaticamente a outros conjuntos de curvas sem repetir o protocolo.

Neste relatório, **recorte** designa um **trecho vertical** da coluna perfilada analisado através de um **conjunto tabular 7logs completo** (preditor + alvo), com amostragem regular ao longo da profundidade e **identificador de amostra** próprio (etiqueta convencional do recorte vertical considerado). O **recorte principal** corresponde à etiqueta F03-4; o **recorte de contraste**, ao F06-1. Trata-se de duas séries distintas para confrontar o mesmo protocolo computacional. O vocabulário *recorte* não implica, por si só, que se trate do mesmo poço em duas profundidades ou da mesma litologia dominante.

Adotou-se o recorte F03-4 como estudo principal e o F06-1 como contraste qualitativo.

4.2 Fluxo de processamento

O procedimento computacional segue a cadeia ilustrada na Figura 1, lida de cima para baixo: primeiro consolidam-se tabela de preditores e alvo; em seguida remove-se linhas incompletas; depois separa-se o trecho mais profundo para teste, mantendo o trecho mais raso para treino; estima-se o *Gradient Boosting* em histogramas (GBDT) **sem** padronização *z-score* nas features, por coerência com modelos baseados em árvores (mantém-se, como variante opcional, a possibilidade de padronizar as entradas para comparação com modelos lineares); calculam-se MAE (3), RMSE (4) e R^2 (2) no teste, com variantes por ablação; por fim, executa-se o bloco de diagnóstico multivariado (correlações e VIF no treino, MI

no treino, permutação e SHAP no teste profundo). A avaliação por permutação insere-se nesse último bloco, pois reutiliza o modelo ajustado e as partições fixas.

Para rastreabilidade computacional, o módulo partilhado `run_metadata.py` é invocado em `feature_relationship_study.py` e em `gr_vc_rank_dependence.py`, gravando em cada execução um registo auxiliar em JSON (`experiment.json`) com carimbo temporal em UTC e identificador curto da revisão Git quando o repositório está acessível a partir do diretório de trabalho, alinhando números e figuras desses blocos ao estado do código (o baseline de porosidade pode registar o mesmo tipo de saída JSON quando ativado por opção de linha de comandos).

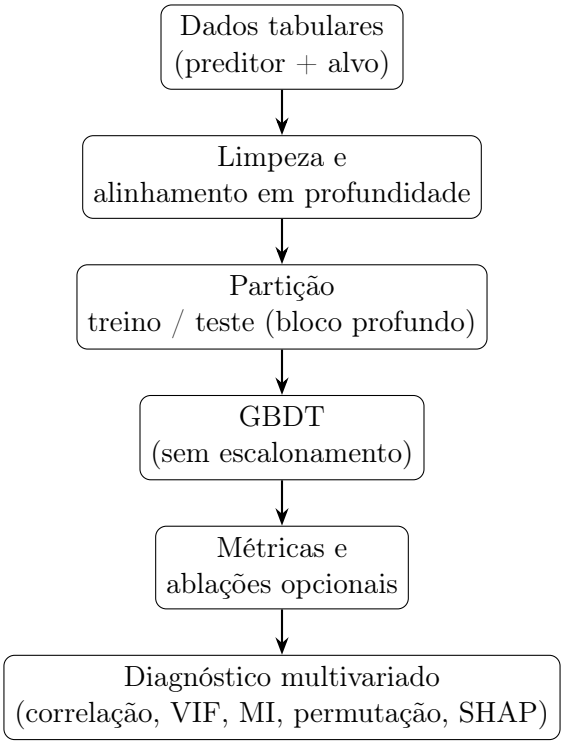

Figura 1: Sequência metodológica adotada neste ensaio.

Na prática, cada retângulo corresponde a uma etapa documentável. O primeiro bloco fixa o universo de variáveis e o alvo; o segundo evita lacunas artificiais que distorceriam correlações; o terceiro impõe que o teste seja **contíguo em profundidade** (um bloco contínuo ao longo do eixo vertical tabulado), o que aproxima o protocolo de um cenário em que se prevê porosidade abaixo de uma profundidade de corte usando apenas informação mais rasa. O quarto bloco estima o GBDT diretamente nas features físicas (sem escalonamento obrigatório); as predições nesse bloco alimentam as curvas da Secção 6. O quinto bloco calcula MAE, RMSE e R^2 no teste profundo e registra variantes sem V_p ou sem AI. O sexto bloco quantifica redundância e sensibilidade: as matrizes de correlação (treino) resumem acoplamento linear ou monótono; o VIF mede quasi-colinearidade num sistema linear auxiliar ajustado ao treino; a MI mede dependência estatística (não necessariamente linear) de cada preditor com a porosidade **no treino**; a permutação mede o quanto o R^2 degrada ao destruir informação de um preditor de cada vez; o SHAP decompõe predições em contribuições aditivas locais no **espaço de entrada do modelo** (coincidente com as features originais neste protocolo). Assim, a Figura 1 não dispensa a narração: orienta a ordem em que os resultados das Secções 6 e 7 devem ser lidos.

4.3 Avaliação e ablação

Ao longo do texto, **teste profundo** e **bloco de teste profundo** referem-se ao mesmo subconjunto de linhas: as observações situadas na cauda mais profunda após ordenar o conjunto pela profundidade mecânica tabulada, correspondendo, no estudo principal, a 20% dos registos mais profundos (em sensibilidades posteriormente reportadas utilizaram-se também 15% e 25%). A partição por profundidade reduz o vazamento espacial inerente a sorteios independentes em perfil quase contínuo: o teste corresponde a esse trecho mais profundo, onde a extrapolação a partir de padrões rasos é mais exigente do que numa partição aleatória i.i.d. (independentes e identicamente distribuídas entre observações).

Foram treinadas variantes do mesmo modelo com subconjuntos de preditores: todas as variáveis elásticas disponíveis; sem V_p; sem impedância; sem V_p e sem impedância conjuntamente. A comparação direta das métricas no teste responde à primeira questão levantada na Secção 3.

4.3.1 Bootstrap pareado no conjunto de teste

Para quantificar a incerteza amostral das métricas no bloco de teste profundo, mantendo o modelo GBDT já ajustado no treino e as predições $\hat{y}_i$ fixas, aplicou-se **bootstrap pareado**: sorteiam-se n índices do teste com reposição, recalculam-se MAE, RMSE e R^2 sobre o par $(y, \hat{y})$ reamostrado e repetem-se $B = 2000$ réplicas com semente pseudoaleatória fixa (com réplicas independentes e semente pseudoaleatória fixa igual a zero). Os quantis empíricos 2,5% e 97,5% definem intervalos bilaterais aproximados a 95%. Esta incerteza refere-se à variação das métricas sob reamostragem das observações de teste, **não** à variância de retreino do estimador nem à transferência entre poços.

4.4 Diagnóstico multivariado

Para cada preditor j do conjunto elástico, o fator de inflação da variância (VIF) foi calculado a partir de uma regressão auxiliar linear de x_j face aos demais preditores **no conjunto de treino** (bloco raso), com

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{5}$$

em que R_j^2 é o coeficiente de determinação dessa regressão auxiliar. Valores elevados indicam que x_j é quase combinação linear dos outros preditores. Complementarmente, calcularam-se matrizes de correlação de Pearson e de Spearman **no treino** (figuras do recorte principal), a informação mútua (MI, *mutual information*) entre cada preditor e a porosidade **também no treino**, a importância por permutação da queda de R^2 no teste e um resumo SHAP (*SHapley Additive exPlanations*) obtido com explicador de árvore aplicado ao modelo GBDT ajustado. Para além disso, calcularam-se correlações de Pearson e de Spearman sobre o **conjunto completo** de linhas válidas **antes** da partição treino–teste, com o único propósito de **análise exploratória dos dados**: oferecem uma visão global do acoplamento linear e monótono entre variáveis sem impor o mesmo protocolo de exclusão do bloco profundo. Esses resumos exploratórios **não** sustentam as figuras nem a discussão principal do modelo, que permanecem ancoradas às matrizes obtidas apenas no treino. A permutação e o SHAP reutilizam o mesmo modelo e o mesmo teste profundo. Sobre as features standardizadas do treino, uma PCA sintética indica que as duas primeiras componentes explicam cerca de 99,9% da variância acumulada, coerente

com subespaço elástico de dimensão efetiva baixa; o número de condição (norma espectral) da matriz de correlação do treino é da ordem de 10^7, sinal de matriz mal condicionada alinhado aos VIF extremos.

5 Premissas e limitações

As curvas e a porosidade tratam-se como co-registradas na profundidade informada, sem corrigir deslocamentos instrumentais. O protocolo principal permanece, por construção, **intra-coluna** (corte vertical num único conjunto tabular). A validação **LOO** (*leave-one-well-out*, ou seja, *exclusão sucessiva de um poço por vez*: em cada rodada treina-se com a união de todos os *outros* recortes tabulares e avalia-se somente no poço que ficou de fora do treino), apresentada na Tabela 3, aproxima a exclusão mútua entre conjuntos tabulares distintos nestes quatro conjuntos de dados 7logs. Os R^2 no poço retido situam-se entre 0,960 e cerca de 0,9998 (MAE baixo em todas as linhas), o que indica transferência entre poços globalmente favorável neste conjunto, sem uniformidade estrita: quando o teste é F02-1, o R^2 é o mais baixo da tabela e o MAE o mais alto, enquanto as outras três exclusões concentram-se ainda mais perto do teto numérico. Com apenas quatro recortes, o LOO não substitui um estudo de campo exaustivo nem documenta grau de independência física entre poços, semelhança instrumental ou ausência de acoplamento alvo–preditores. O contraste entre recortes na Figura 6 compara qualidade de ajuste interno a cada coluna, não transferência aprendida numa coluna e testada na outra. Por fim, R^2 alto pode refletir acoplamento físico e redundância estatística, não independência informacional entre preditores. A informação mútua obtida pelo estimador de informação mútua adotado na rotina computacional do ensaio tem **magnitude absoluta** sensível a hiperparâmetros internos do estimador; no texto, a leitura prioritária é a **ordenação** entre preditores e a separação de ordens de grandeza, não a calibração de nats entre estudos distintos. O bootstrap no teste (Secção 4.3.1) quantifica incerteza amostral das métricas com modelo fixo; não incorpora variância de retreino nem generalização entre poços.

6 Resultados

6.1 Síntese numérica

A Tabela 1 reúne os indicadores no conjunto de teste profundo. No recorte principal, as quatro variantes apresentam desempenho praticamente idêntico: a remoção de V_p ou de impedância, isolada ou conjunta, não altera de forma substantiva MAE, RMSE nem R^2. Já no recorte de contraste, R^2 cai para a ordem de 0,95 com MAE e RMSE maiores, o que antecipa a discussão sobre dependência do intervalo litológico e da qualidade relativa das curvas.

A comparação entre a primeira linha da tabela (F03-4, baseline completa) e a última (F06-1, baseline completa) constitui apenas **contraste qualitativo** entre duas séries tabulares sob o **mesmo** protocolo interno (treino no trecho raso, teste no bloco profundo de 20%); **não** corresponde ao protocolo LOO da Tabela 3, em que um único modelo treina na união de três colunas e avalia exclusivamente na quarta.

A Tabela 2 reporta intervalos aproximados a 95% (bootstrap pareado, $B = 2000$, Secção 4.3.1) apenas para a linha de **baseline completa** em cada recorte, isto é, o mesmo cenário da primeira linha da Tabela 1 e da última (F06-1).

Cenário (recorte principal, salvo nota)	MAE	RMSE	R^2
Todos os preditores elásticos	0,00053	0,00111	0,988
Sem V_p	0,00054	0,00111	0,988
Sem impedância	0,00054	0,00111	0,988
Sem V_p e sem impedância	0,00054	0,00111	0,988
Recorte de contraste (baseline completa)	0,00222	0,00456	0,945

Tabela 1: Desempenho no teste profundo (20% inferior da coluna). MAE (3) e RMSE (4) na unidade da porosidade; R^2 adimensional (2).

Recorte (baseline completa)	IC 95% MAE	IC 95% RMSE	IC 95% R^2
F03-4	[0,00043, 0,00066]	[0,00090, 0,00132]	[0,9829, 0,9923]
F06-1	[0,00156, 0,00298]	[0,00333, 0,00573]	[0,9172, 0,9679]

Tabela 2: Bootstrap pareado no teste profundo ($B = 2000$, semente 0; $n = 287$ no F03-4 e $n = 116$ no F06-1). Limites: quantis empíricos 2,5% e 97,5% das réplicas.

6.1.1 Robustez ao corte em profundidade

Mantendo o mesmo GBDT no recorte principal (F03-4), repetiu-se a partição com frações de teste profundo de 15%, 20% e 25%. O R^2 no teste oscilou entre 0,988 e 0,993 (MAE e RMSE na mesma ordem de grandeza), o que indica que a conclusão de encaixe elevado no teste **não** depende de um único ponto de corte na grelha considerada. Com profundidade máxima das árvores $\in \{4, 6, 8\}$ e demais hiperparâmetros fixos, o R^2 no mesmo corte de 20% permanece na casa de 0,988, sugerindo que a leitura de redundância marginal não está ancorada num único valor de profundidade de árvore.

6.1.2 Exclusão sucessiva de um poço (LOO, *leave-one-well-out*)

Para aproximar a crítica de generalização **entre** colunas, aplicou-se a validação **LOO** já definida nas premissas: em cada passo, treina-se o mesmo tipo de GBDT na união de três recortes tabulares 7logs e testa-se no quarto, percorrendo os quatro poços disponíveis (F02-1, F03-2, F03-4, F06-1). Na Tabela 3, o R^2 no poço retido situa-se entre 0,960 e 0,999 (valor pontual máximo 0,999845) e o MAE permanece baixo em todas as linhas: o quadro indica generalização entre poços globalmente forte nestes quatro conjuntos de dados. A variação entre linhas — notadamente o contraste de F02-1 ($R^2 = 0{,}960$, MAE = 0,00311) com F03-2, F03-4 e F06-1 — mostra que R^2 elevado **não** implica transferência estritamente homogénea entre contextos distintos; qualifica um resultado globalmente favorável, sem sugerir instabilidade grave nem substituir validação em conjuntos mais vastos ou em condições de aquisição claramente independentes.

6.2 Perfil de porosidade observada e prevista

As Figuras 2 a 5 mostram, para o recorte principal, a porosidade observada e a curva prevista ao longo da profundidade, com linha de corte entre treino e teste. Visualmente, a coincidência no trecho profundo é marcada em todas as variantes, o que é coerente com os números da Tabela 1. A Figura 6 transporta o mesmo tipo de painel para o recorte de contraste: observa-se maior dispersão relativa entre observado e previsto, alinhada à

Poço retido (teste)	n_{treino}	n_{teste}	MAE	R^2
F02-1	3595	445	0,00311	0,960
F03-2	2456	1584	0,00030	0,996
F03-4	2605	1435	0,00011	0,999
F06-1	3464	576	0,00013	1,000*

Tabela 3: Validação LOO entre quatro recortes tabulares 7logs (treino na união dos outros três, teste exclusivo no poço da linha). *Arredondamento a três casas; valor pontual 0,999845.

queda de R^2 na última linha da tabela. O contraste visual com a Figura 6 reforça o mesmo aviso: duas colunas tratadas isoladamente com o mesmo procedimento, sem inferência de transportabilidade entre poços.

6.3 Estrutura de correlação e colinearidade

As Figuras 9 e 10 evidenciam correlações lineares e monótonas quase unitárias entre AC, ρ_b, impedância e V_p, bem como correlação forte deste bloco com a porosidade **no recorte principal**. O padrão sustenta a hipótese de um subespaço elástico de dimensão efetiva baixa neste conjunto: várias colunas movem-se em conjunto, em vez de oferecer direções independentes no espaço das variáveis.

A Tabela 4 traduz essa leitura em termos de (5): fatores da ordem de 10^5 a 10^6 para AC, ρ_b, impedância e V_p não devem ser tomados como magnitudes calibradas de um modelo linear final. Dado o nível extremo de colinearidade, os **valores absolutos** de VIF perdem interesse quantitativo fino e devem ser lidos apenas como **marcadores de degenerescência severa** do sistema linear auxiliar; comparações finas entre, por exemplo, $7{,}0 \times 10^5$ e $1{,}1 \times 10^5$ não devem ser interpretadas como diferença substancial de "grau de colinearidade". Para GR e V_c, os VIF permanecem elevados face ao limiar usual da ordem de dez, coerente com a forte associação mútua observada nas matrizes.

Preditor	VIF (ordem de grandeza)
AC	$7{,}0 \times 10^5$
ρ_b	$7{,}0 \times 10^5$
Impedância	$1{,}1 \times 10^5$
V_p	$1{,}1 \times 10^5$
GR	$8{,}3 \times 10^1$
V_c	$8{,}2 \times 10^1$

Tabela 4: Fatores VIF aproximados no recorte principal (treino, bloco raso), calculados por (5).

6.4 Dependência entre GR e V_c: postos e empates

O par GR–V_c aparece nas matrizes de correlação com associação forte, mas a leitura sob **empates nos postos** (vários pontos com o mesmo valor, logo o mesmo posto após *ranking*) e sob **desempates** extremos (*min* e *max* na rotina de postos adotada) informa se a dependência seria artefato numérico ou se permanece quase determinística.

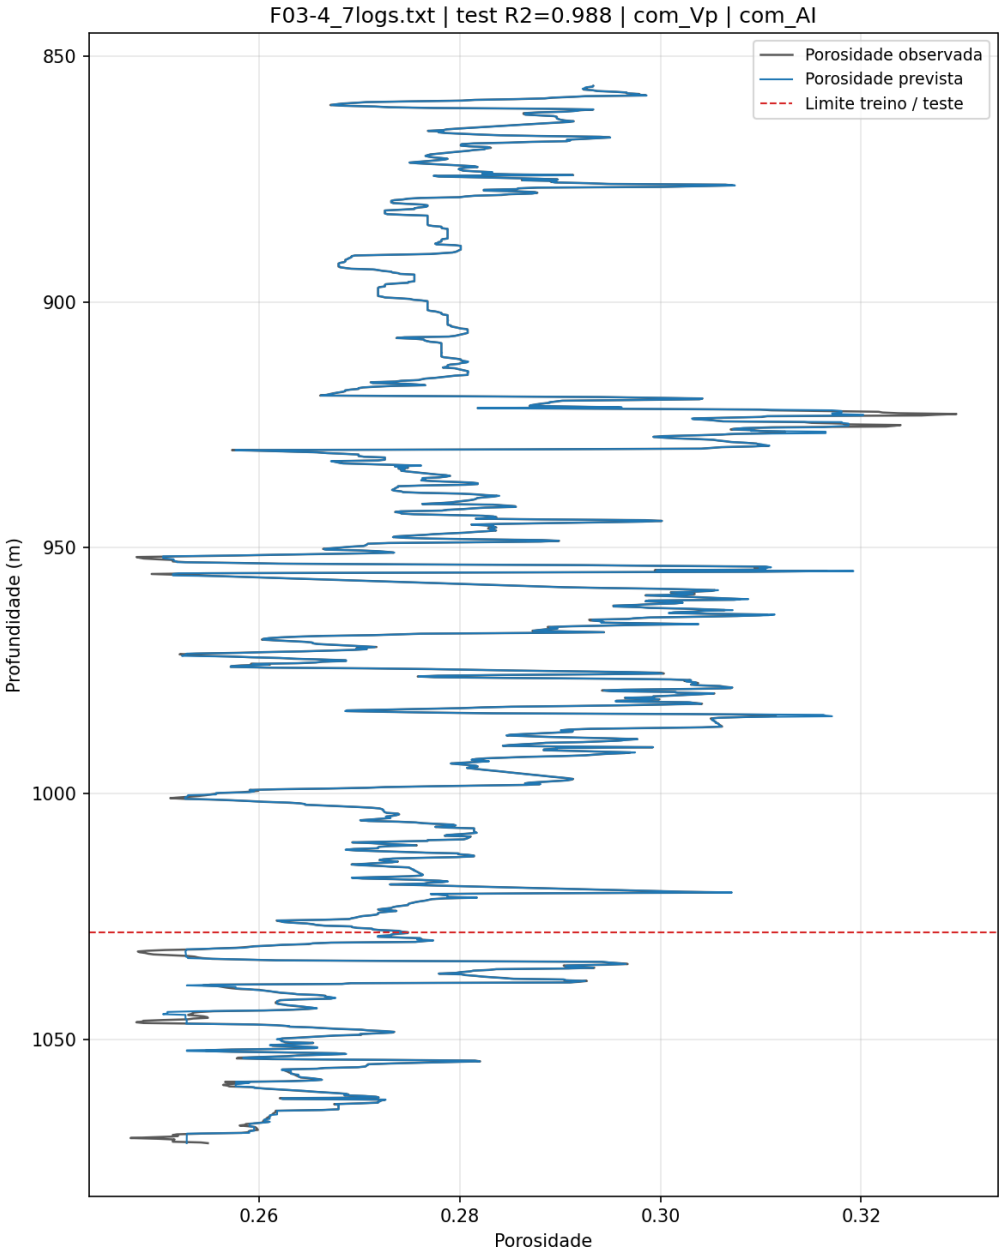

Figura 2: Recorte principal: porosidade observada e prevista com todos os preditores elásticos disponíveis.

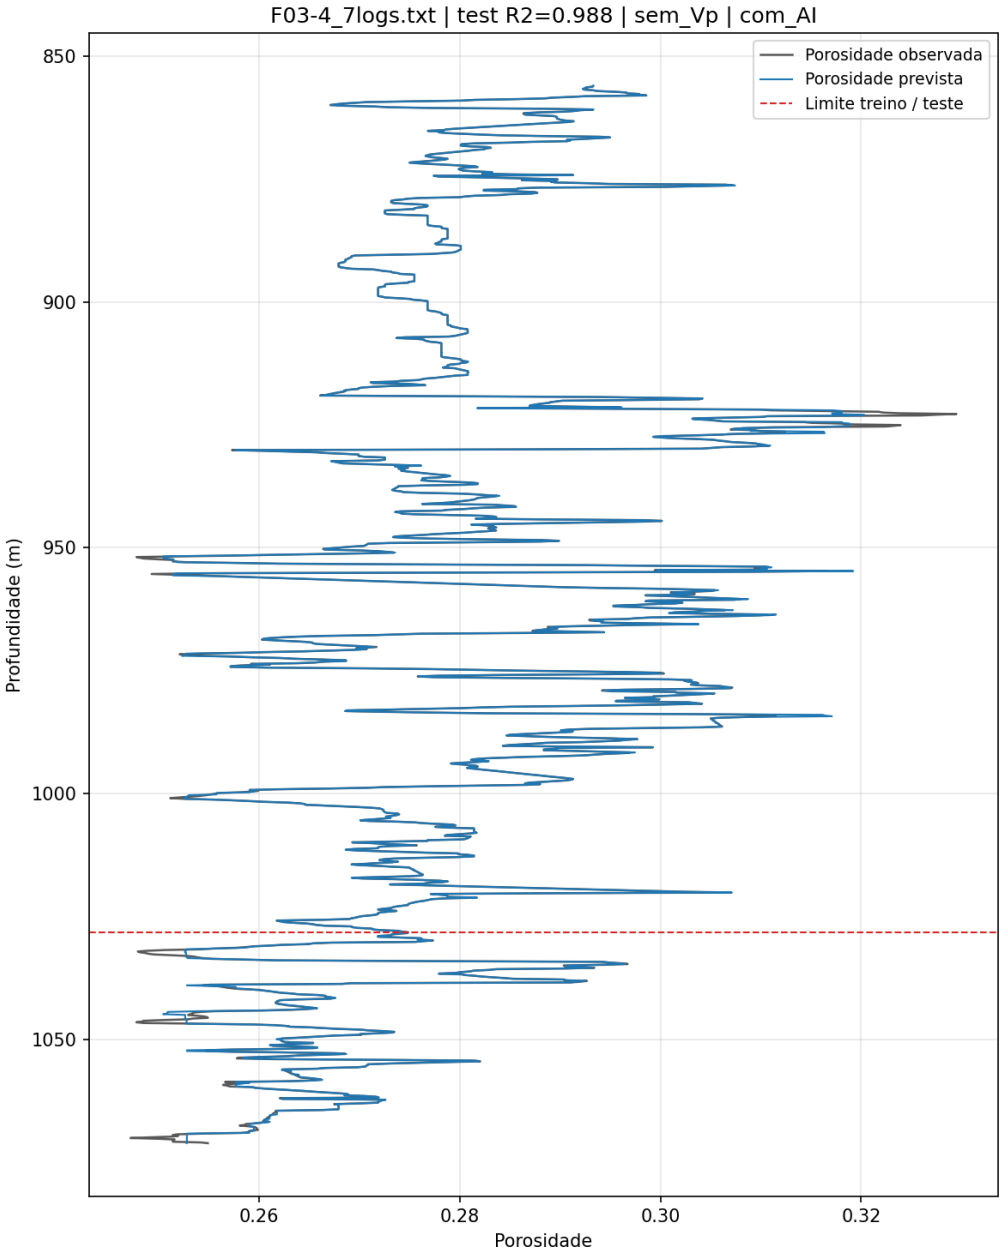

Figura 3: Recorte principal: modelo sem V_p.

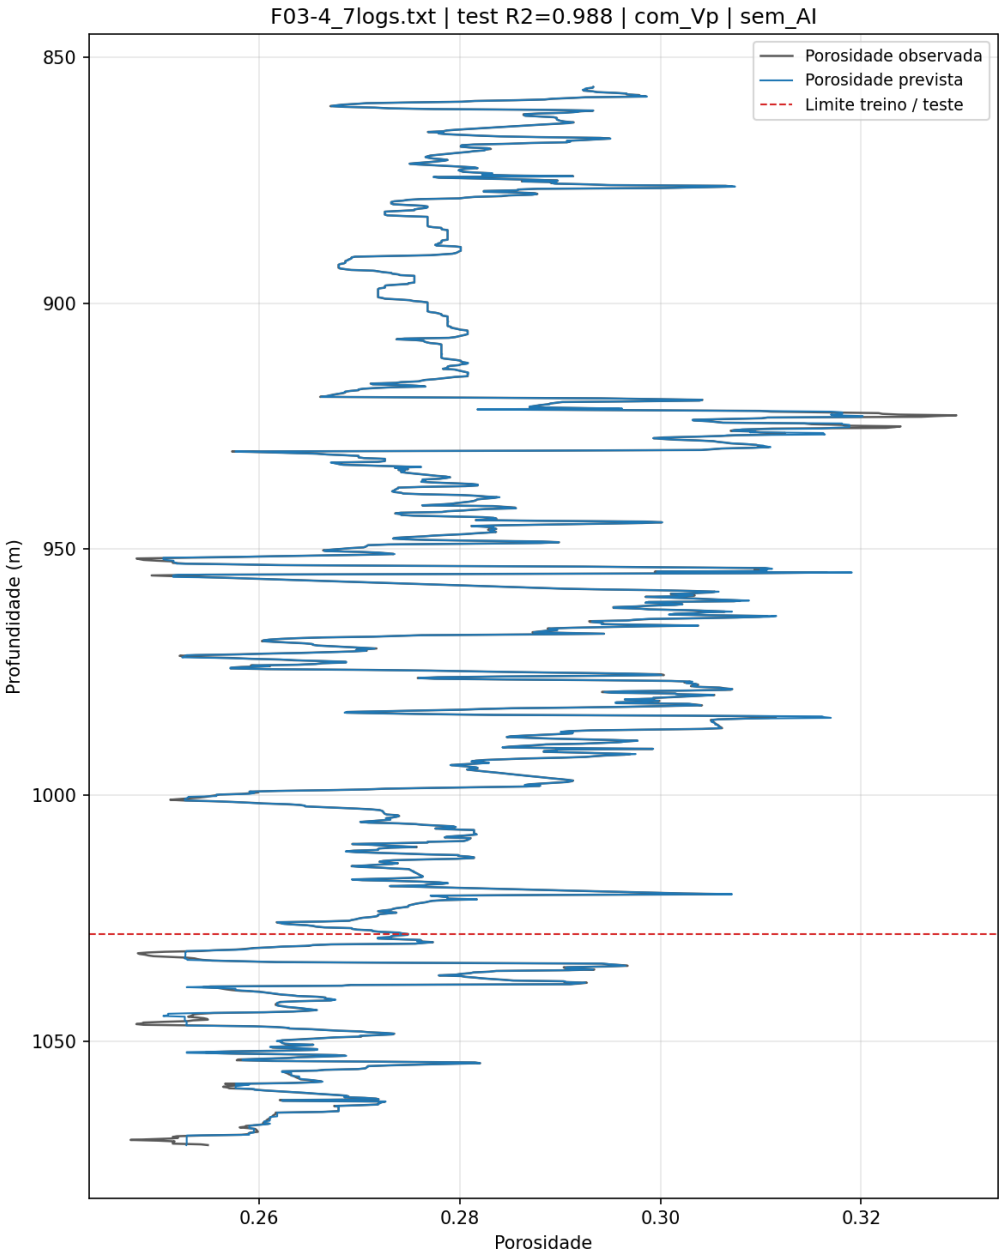

Figura 4: Recorte principal: modelo sem impedância acústica.

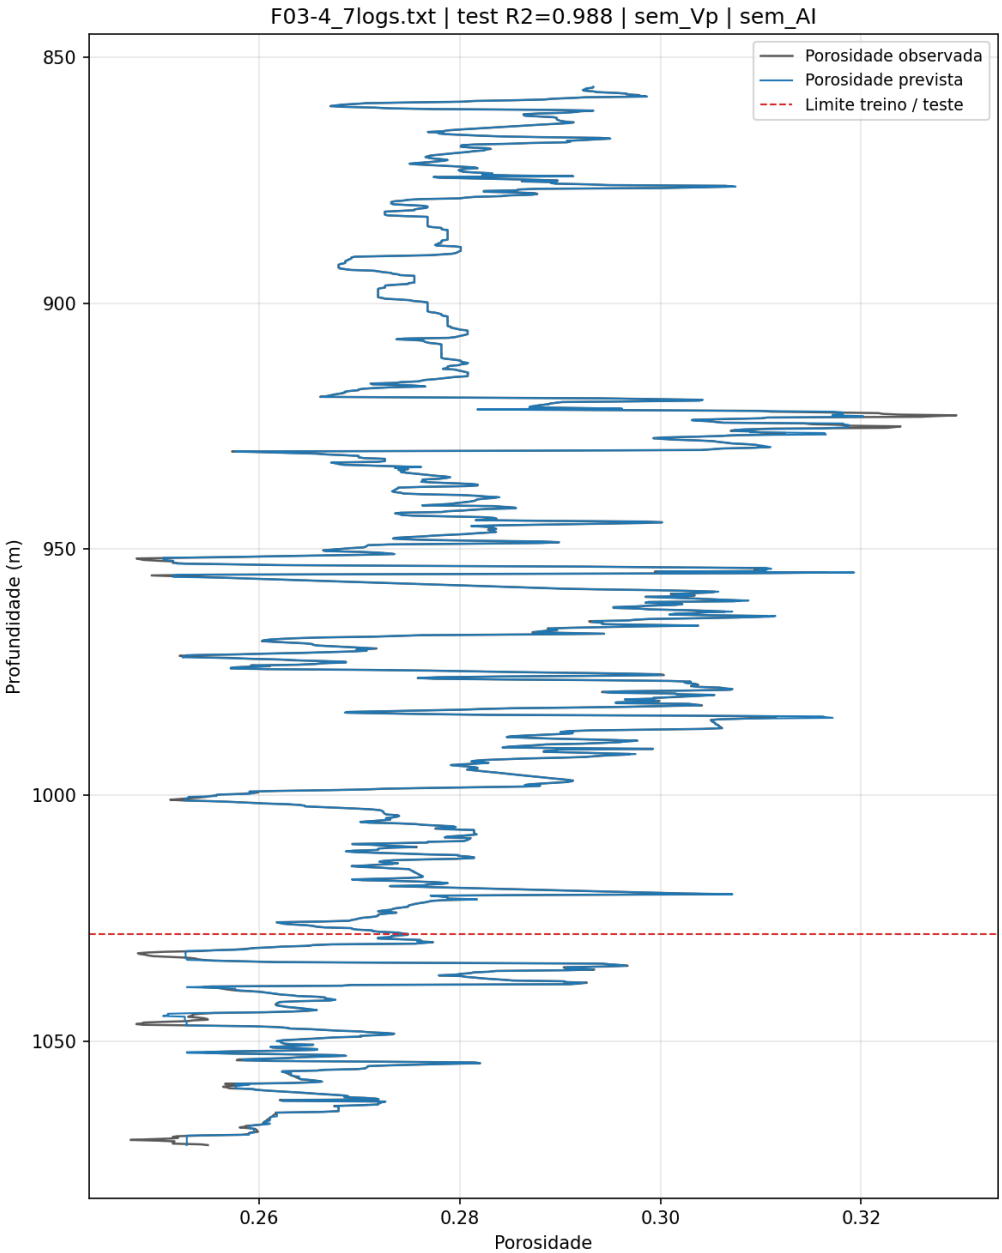

Figura 5: Recorte principal: modelo apenas com AC, ρ_b, GR e V_c.

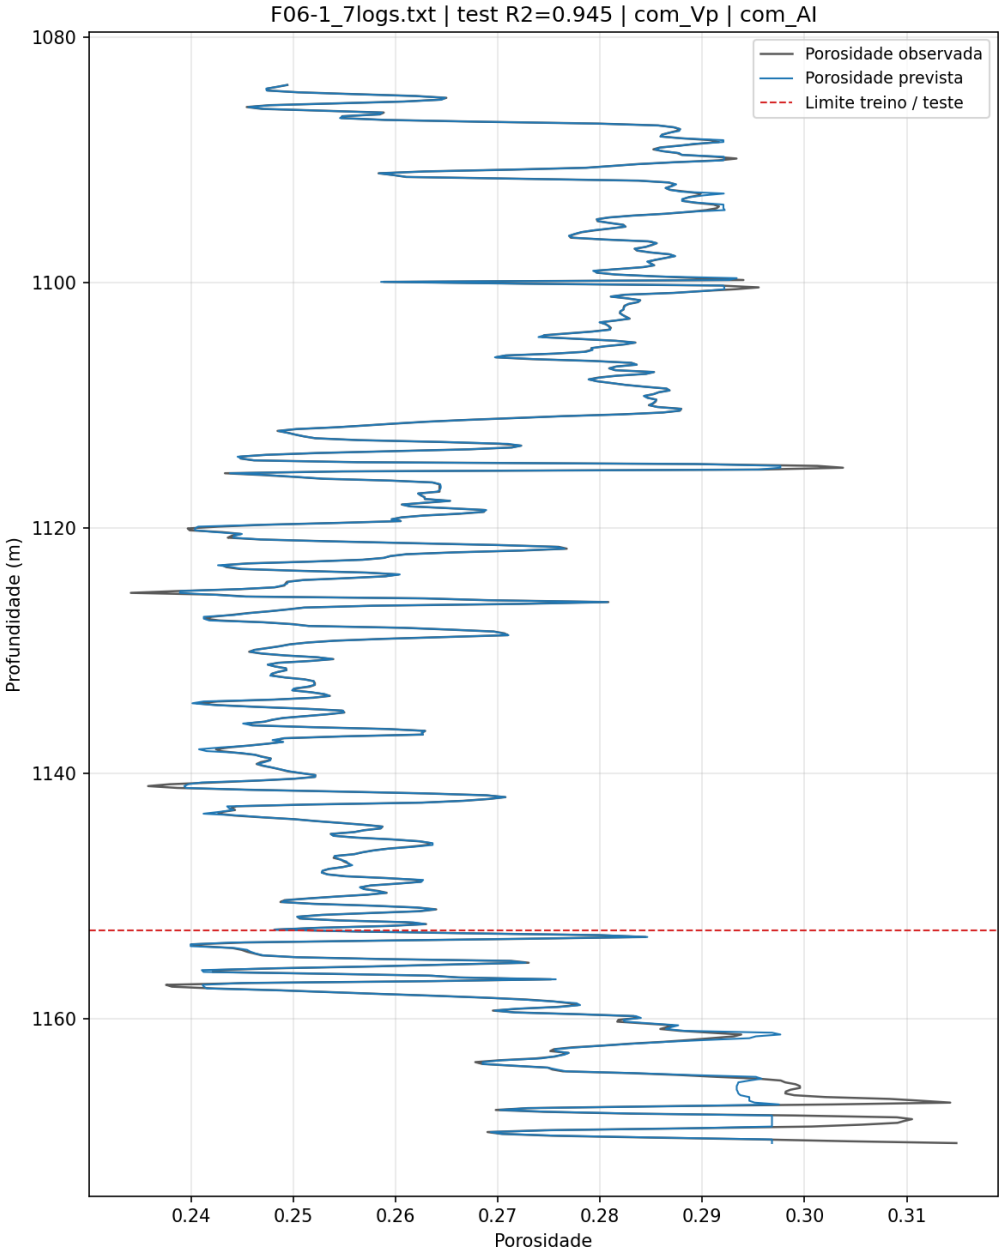

Figura 6: Recorte de contraste: baseline completa.

No recorte principal, sobre o mesmo conjunto 7logs já filtrado por linhas completas, calcularam-se estatísticas de empates, correlações de Pearson, Spearman e Kendall, correlações parciais via correlação entre resíduos de regressões lineares ordinárias (controlo pela profundidade; controlo adicional pelo bloco elástico em bruto; variantes em que preditores e profundidade entram como postos médios), e uma estabilidade de Spearman sob *jitter* uniforme minúsculo repetido (80 sorteios, escala da ordem de 10^{-8} face à amplitude das curvas). As tabelas seguintes consolidam os indicadores dessa etapa para o recorte principal.

Coluna	n	valores distintos	fração em empates	multiplicidade máx.
GR	1435	1110	0,298	23
V_c	1435	1110	0,298	23

Tabela 5: Empates nos valores brutos: GR e V_c compartilham a mesma cardinalidade de valores distintos e a mesma fração de linhas em empates (recorte principal).

Medida	Notação / controlo	Valor
Pearson (bruto)	$\rho_{GR,Vc}$	0,993
Spearman	ρ_S	1,000
Kendall	τ	1,000
Parcial (bruto)	resíduos OLS; controlo: profundidade	0,993
Parcial (postos)	resíduos OLS em postos médios; controlo: posto(prof.)	1,000
Parcial (bruto)	resíduos OLS; controlo: AC, ρ_b, AI, V_p	0,992
Parcial (postos)	postos médios; controlo: prof. e elásticos (postos)	1,000
Spearman + *jitter*	média de 80 sorteios	0,999992
	desvio-padrão	$8{,}6 \times 10^{-7}$

Tabela 6: Associação GR–V_c e correlações parciais lineares (resíduos OLS; controlo **linear** apenas, sem equivalência a independência condicional geral). Com monotonia empírica quase perfeita entre GR e V_c, os p-valores dos testes de Spearman e de Kendall (hipótese de independência) ficam abaixo do que a aritmética de ponto flutuante distingue de zero, aparecendo como 0 na tabela.

A Tabela 5 mostra que GR e V_c não são meramente correlacionados: compartilham **exatamente** o mesmo número de valores distintos, a mesma fração de linhas em empates e a mesma multiplicidade máxima, o que é compatível com V_c construído a partir de GR (ou inversamente) com a mesma grelha de quantização. A Tabela 6 confirma uma relação quase monótona perfeita (Spearman e Kendall unitários) e mantém correlação parcial elevada mesmo depois de linearizar profundidade ou o bloco elástico, pelo menos no esquema de controlo linear adotado. Uma regressão isotônica crescente $V_c \approx f(\mathrm{GR})$ ajustada aos mesmos dados atinge R^2 praticamente unitário e erro de reconstrução desprezível à escala da precisão finita do cálculo, o que quantifica a redundância monótona além das correlações clássicas. **No recorte principal, GR e V_c não devem ser tratados como eixos**

posto(GR) \ posto(V_c)	*average*	*min*	*max*
average	1,000000	0,999991	0,999991
min	0,999991	1,000000	0,999965
max	0,999991	0,999965	1,000000

Tabela 7: Sensibilidade ao desempate: Pearson entre postos obtidos com os métodos *average*, *min* e *max* de desempate; valores fora da diagonal diferem só na sexta casa decimal.

independentes de informação: a evidência sugere que um deles é, na prática, quase inteiramente reconstruível a partir do outro, de modo que mantê-los simultaneamente pode inflar artificialmente a dimensão aparente do espaço de atributos. A Tabela 7 mostra que a escolha de desempate (*average*, *min*, *max*) quase não move o coeficiente; o *jitter* deixa a Spearman estável na unidade até 10^{-6}.

6.5 Informação mútua, permutação e SHAP

A informação mútua (MI) entre cada preditor e a porosidade concentra-se em valores elevados e próximos entre si para AC, ρ_b, impedância e V_p, enquanto GR e V_c ficam num patamar inferior, porém não nulos. A leitura relevante da MI é **ordinal e comparativa** entre preditores (ordenação e separação entre blocos), e não o valor absoluto em nats como grandeza transportável entre estudos. A Tabela 8 quantifica essa separação: os quatro preditores elásticos ficam na casa de 5,3 nats (arredondamento à segunda casa; MI estimada no treino), enquanto GR e V_c permanecem perto de 0,51, isto é, magnitudes cerca de dez vezes menores no mesmo ajuste MI. Isto reforça que, **no recorte principal**, o bloco elástico compartilha quase o mesmo conteúdo informativo sobre o alvo, ao passo que GR e V_c introduzem um eixo litológico mais fraco neste recorte, sem ser nulo.

Preditor	MI com porosidade (nats, arred.)
AC	5,30
ρ_b	5,43
AI	5,28
V_p	5,30
GR	0,52
V_c	0,51

Tabela 8: MI estimada no conjunto de treino (bloco raso, mesma partição que as Figuras 9–10). Valores arredondados; ver limitações na Secção 5.

A Figura 11 sintetiza a importância por permutação (25 repetições no teste profundo). A Tabela 9 traduz a figura em números: a queda média de R^2 ao baralhar AC é da ordem de 1,30, com desvio-padrão de 0,06, enquanto ρ_b aparece distante, mas ainda positiva ($\approx 0{,}05$). AI e V_p têm quedas médias uma ordem de grandeza menores; V_p fica na casa de 10^{-5}, compatível com ausência de contribuição marginal detectável à escala do ruído de permutação. GR exibe média ligeiramente negativa ($\approx -9 \times 10^{-4}$), compatível com flutuação estatística em torno de zero quando o preditor é redundante; V_c registra queda média nula à resolução numérica utilizada na tabela, coerente com o acoplamento quase determinístico a GR já documentado.

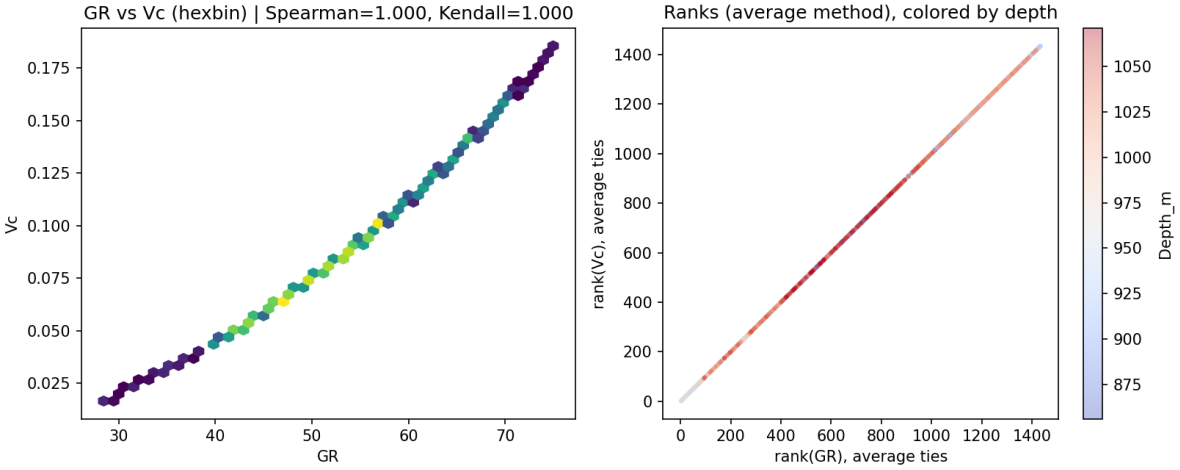

Figura 7: GR versus V_c (hexbin) e postos médios com cores por profundidade. Spearman e Kendall próximos de um indicam monotonia quase perfeita no recorte.

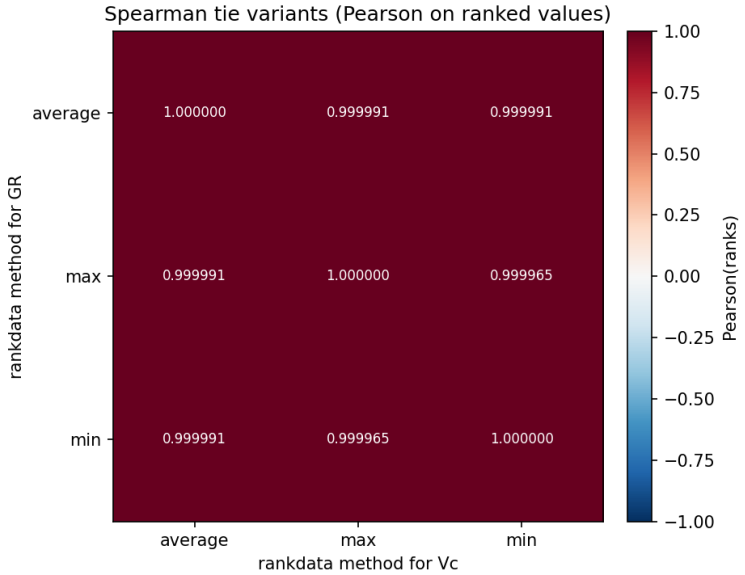

Figura 8: Mapa de calor da matriz da Tabela 7: sensibilidade da correlação de Pearson aplicada a pares de postos, com coeficientes anotados em cada célula (seis casas decimais).

Em presença de colinearidade forte, a importância por permutação mede contribuição **marginal** condicionada ao restante dos preditores e, por construção, tende a **subestimar** variáveis cuja informação já foi absorvida por colunas correlacionadas; quedas quase nulas em AI e V_p não equivalem a ausência física de conteúdo informativo, mas sim a redundância preditiva face a AC e ρ_b neste ajuste.

Preditor	Queda média de R^2	Desvio-padrão
AC	1,298	0,064
ρ_b	0,050	0,005
AI	0,0056	0,0010
V_p	$2{,}9 \times 10^{-5}$	$3{,}4 \times 10^{-6}$
GR	$-9{,}1 \times 10^{-4}$	$3{,}3 \times 10^{-4}$
V_c	0,000	0,000

Tabela 9: Importância por permutação no teste profundo (25 repetições). Registou-se, em paralelo à tabela, um indicador binário que assinala preditores cuja queda média de R^2 não é positiva, para facilitar a leitura de redundância ou ruído à escala do procedimento.

A Figura 12, no mesmo modelo GBDT e no recorte principal, mostra que AC emerge como o principal **carregador de informação preditiva marginal** na base explicada: a nuvem de SHAP para AC ocupa faixa horizontal visivelmente mais larga do que as de AI, V_p e ρ_b, sinal de que pequenas variações de AC se traduzem em variações grandes no valor de Shapley ao longo das observações do teste. Isto não atribui a AC o papel de "variável certa" em sentido absoluto, apenas descreve o modelo ajustado neste protocolo. AI e V_p aparecem como faixas estreitas centradas perto de zero, coerente com a redundância frente a AC e densidade. ρ_b mostra dispersão intermediária, refletindo o papel secundário mas não nulo visto na permutação. GR e V_c mantém dispersão modesta e parcialmente sobreposta, alinhada à MI baixa e à quase colinearidade entre si: o SHAP deve ser lido como explicação *local* do ajuste, não como atribuição causal física.

7 Discussão

A estabilidade das métricas na Tabela 1, percorrida em paralelo com as ablações ilustradas nas Figuras 3–5, indica que, **no recorte principal** e sob o protocolo treino/teste em profundidade, V_p e a impedância não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já estão disponíveis com a qualidade relativa destas curvas. Não se trata de desvalorizar medidas físicas centrais: o experimento não implica irrelevância física de V_p ou de AI, mas sim ausência de contribuição preditiva marginal detectável neste contexto, dado o forte acoplamento dessas grandezas com AC e densidade.

A Secção 6 fornece a evidência multivariada que sustenta esta leitura: correlações quase unitárias no bloco elástico (Figuras 9 e 10), VIF extremos na Tabela 4, MI ordenada como na Tabela 8, quedas de R^2 por permutação como na Tabela 9 e na Figura 11, e resumo SHAP (Figura 12) coerente com essa hierarquia. Em conjunto, estas linhas de evidência fecham o ciclo lógico entre a pergunta formulada na Secção 3 e o desenho metodológico da Figura 1.

A subsecção 6.4 aprofunda o par GR–V_c sob a ótica de empates nos postos e de desempates extremos. As Tabelas 5–7 e as Figuras 7 e 8 mostram estrutura de empates idêntica entre colunas, Spearman e Kendall próximos de um e correlação parcial ainda

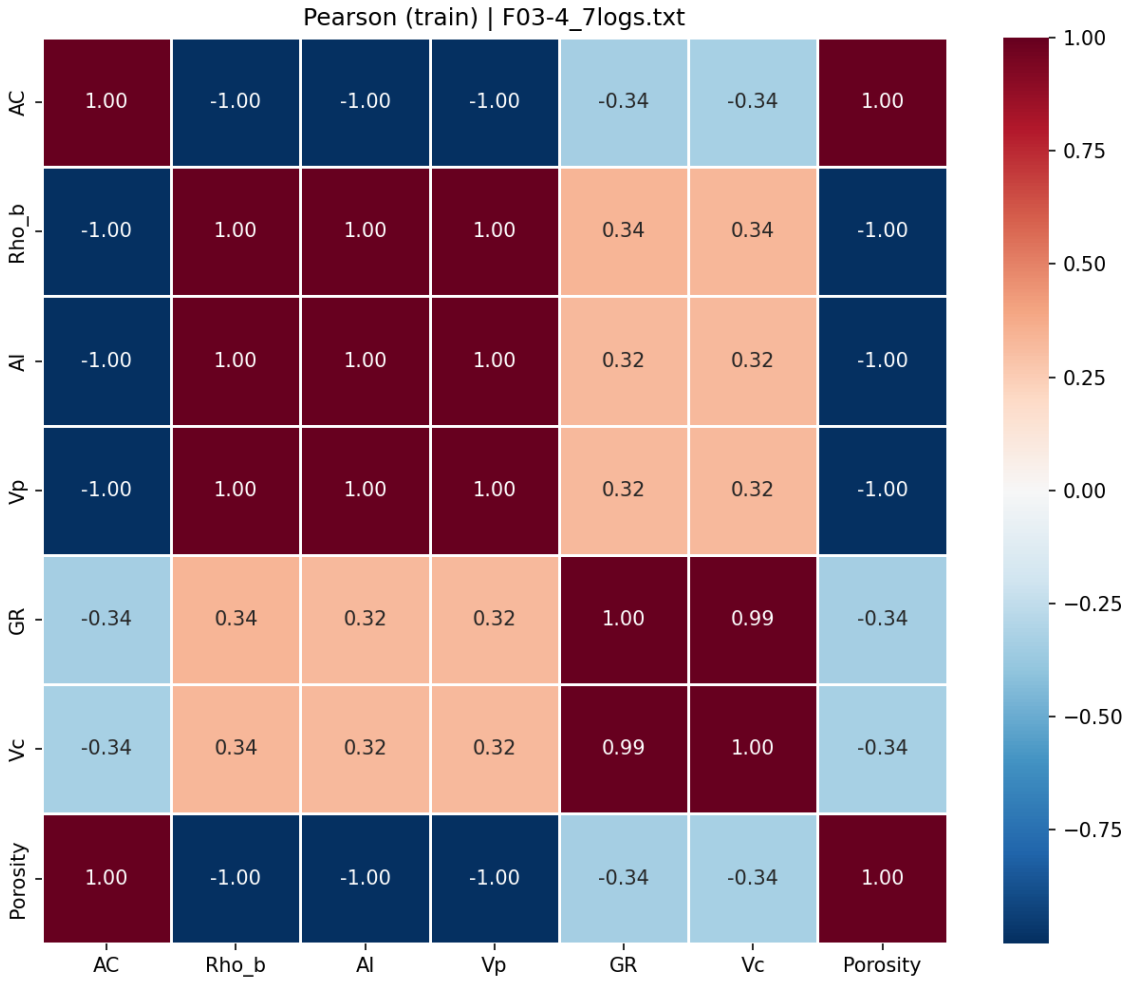

Figura 9: Correlações de Pearson entre preditores e porosidade (recorte principal).

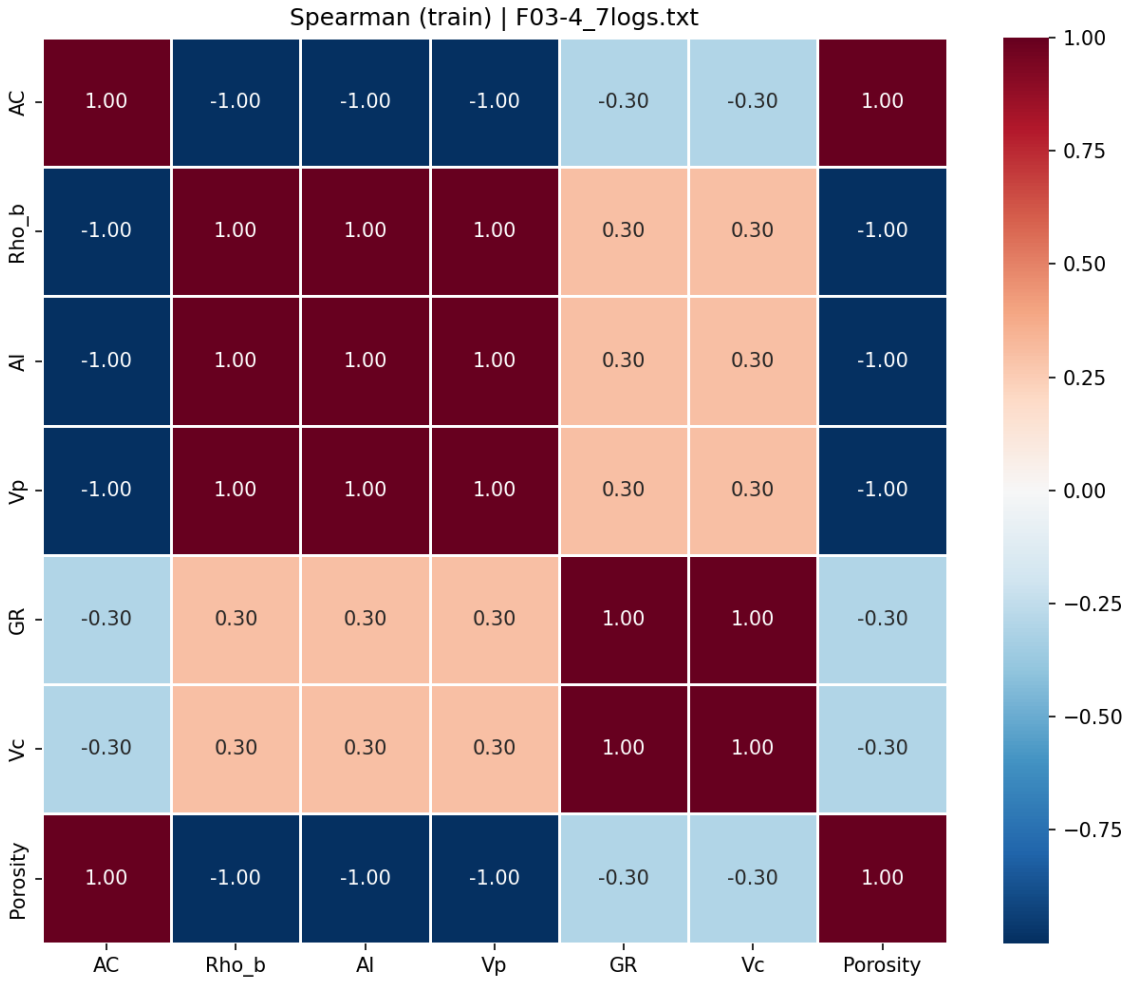

Figura 10: Correlações de Spearman (recorte principal).

elevada após controlo linear pela profundidade ou pelo bloco elástico, o que reforça que, neste recorte, GR e V_c não funcionam como preditores litológicos independentes no espaço de entrada.

O contraste com a Figura 6 e a última linha da Tabela 1 mostra que o nível de R^2 não é propriedade universal do modelo: depende do recorte. Daí a cautela ao extrapolar conclusões entre colunas distintas sem protocolo de exclusão mútua no treino.

Contraste entre recortes F03-4 e F06-1. No recorte principal (F03-4), após remoção de linhas incompletas, restam $n = 1435$ profundidades entre 856 e 1071 m, com porosidade média 0,278 e desvio-padrão 0,014. No recorte de contraste (F06-1), $n = 576$ entre 1084 e 1170 m, com porosidade média 0,267 e desvio 0,017. A janela vertical é distinta e o segundo conjunto é menor; a porosidade apresenta dispersão relativa ligeiramente maior no F06-1. Estes fatos não explicam por si sós toda a queda de R^2 na Tabela 1, mas mostram que o teste profundo (20%) corresponde a litologias, profundidades e tamanhos amostrais diferentes, pelo que o R^2 deixa de ser comparável como se fosse repetição do mesmo experimento. Complementou-se essa comparação com o bootstrap pareado da Secção 4.3.1 (Tabela 2): os intervalos aproximados a 95% para R^2 **não se sobrepêm** entre F03-4 e F06-1 (limite superior 0,9679 versus limite inferior 0,9829), o que sustenta que a diferença pontual entre 0,988 e 0,945 não se explica apenas por flutuação de amostragem *dentro* de cada coluna sob esta reamostragem. O aviso metodológico permanece: estes intervalos não substituem validação por exclusão de poço.

Limite principal. O protocolo núcleo (partição raso/profundo por coluna) caracteriza **robustez interna** ao recorte e ao modelo ajustado naquela coluna. A Tabela 3 acrescenta, sobre quatro recortes 7logs, evidência de encaixe elevado no poço retido em cada exclusão, compatível com transferência favorável nesse conjunto finito, porém **não** uniforme entre linhas nem substituto de domínio geológico alargado. O teste profundo permanece, por construção, intra-coluna; a leitura das ablações e do diagnóstico multivariado nas figuras centrais deve distinguir-se da extrapolação além do material tabular analisado ou além dos quatro conjuntos de dados percorridos no LOO.

8 Conclusões

No recorte principal, o modelo atinge R^2 elevado no teste profundo e mantém esse desempenho ao remover V_p ou impedância, o que é explicado, não contradito, pela colinearidade forte documentada nas Figuras 9 e 10 e pelos VIF da Tabela 4. A MI (Tabela 8) e as quedas de R^2 por permutação (Tabela 9 e Figura 11), juntamente com o SHAP (Figura 12), indicam que, **no modelo ajustado e neste recorte**, AC emerge como o principal carregador de informação preditiva marginal, enquanto a maior parte da variância explicada no teste flui por um eixo elástico estreito no qual AI e V_p ficam preditivamente redundantes face a AC e ρ_b, sem afastar a sua relevância física em outros contextos ou com outras qualidades de aquisição.

O recorte de contraste lembra que a generalização espacial ou entre contextos exige desenho experimental próprio; o presente ensaio não o substitui. Os IC de bootstrap no teste (Tabela 2) reforçam que o contraste de R^2 entre recortes não é compatível com intervalos sobrepostos sob a reamostragem adotada, sem por isso afastar a necessidade

de protocolos entre poços. A revisão de dependência entre GR e V_c sob postos e empates (Secção 6.4) confirma quase redundância formal entre esses preditores no recorte principal.

O protocolo principal no recorte F03-4 caracteriza robustez interna à coluna; a Tabela 3 acrescenta validação LOO entre quatro conjuntos de dados, com encaixe elevado em cada poço retido e heterogeneidade moderada (F02-1 mais exigente que os demais). Como próximos passos, **recomenda-se**: (i) alargar validação entre poços para mais colunas ou bases independentes quando dados estiverem disponíveis, mantendo exclusão mútua no treino; (ii) repetir o mesmo protocolo de diagnóstico em múltiplos recortes, para verificar estabilidade da leitura de redundância; (iii) quando possível, substituir ou complementar a porosidade-alvo por referência menos acoplada às curvas elásticas usadas como entrada.

As conclusões sobre ablações, VIF, MI e SHAP no recorte principal constituem evidência **intra-coluna** naquele protocolo em profundidade. A síntese LOO aplica-se ao quatro conjuntos de dados indicados e não se estende, sem novo desenho, a outros poços, profundidades ou esquemas de curvas.

Referências

- Pedregosa et al., Scikit-learn: Machine Learning in Python, *Journal of Machine Learning Research*, 2011.
- Lundberg, S. M.; Lee, S.-I., A Unified Approach to Interpreting Model Predictions, *Conference on Neural Information Processing Systems* (NeurIPS), 2017.

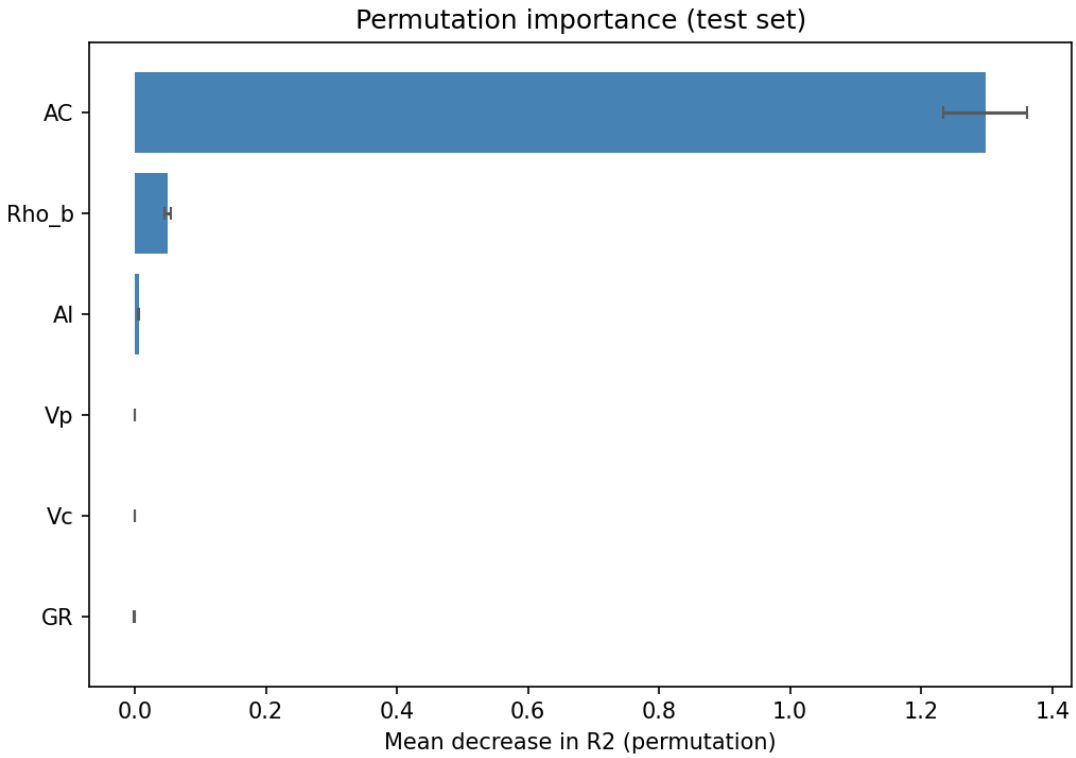

Figura 11: Importância por permutação: queda média de R^2 no teste ao baralhar cada preditor.

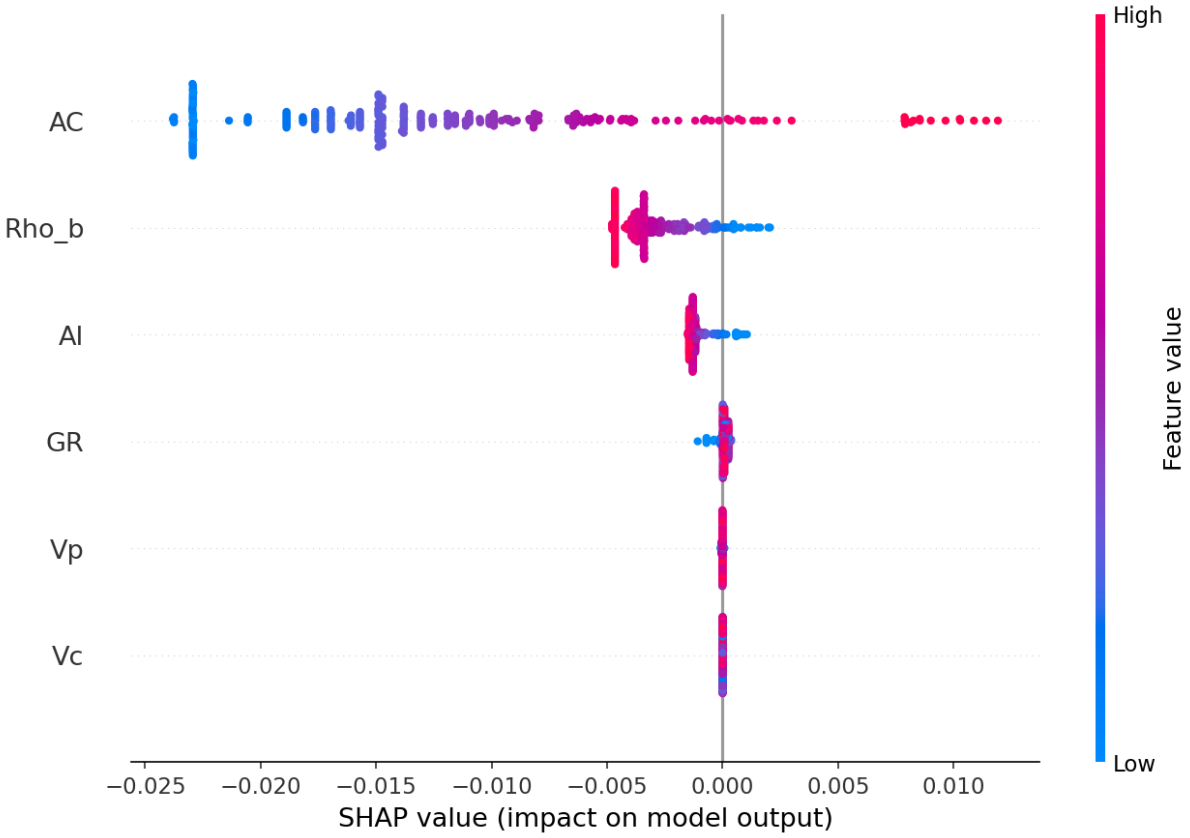

Figura 12: Resumo SHAP (*SHapley Additive exPlanations*) no conjunto de teste profundo (287 observações).