Regressão supervisionada de porosidade a partir de perfis convencionais: diagnóstico de colinearidade e leitura crítica das métricas

16 de abril de 2026

Resumo

Trata-se do registro analítico de um ensaio de regressão para estimar porosidade a partir de curvas de perfilagem: intervalo de trânsito sônico (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade da onda de compressão P (V_p), raio gama (GR) e variável associada à fração argilosa (V_c). O ajuste emprega um modelo GBDT (*Gradient Boosting Decision Trees*, conjunto de árvores de decisão com reforço por gradiente, aqui na variante baseada em histogramas; fundamentação em Friedman, 2001, com variantes de eficiência em espírito semelhante a Ke et al., 2017 e implementação no ecossistema de Pedregosa et al., 2011). A avaliação usa partição treino–teste ao longo da profundidade; por **teste profundo**, equivalente neste documento a **bloco de teste profundo**, entende-se o conjunto das 20% observações com maior profundidade após ordenar o conjunto tabular pela profundidade mecânica registrada ao longo da coluna, mantendo o treino na fração rasa complementar. Descrevem-se ainda ablações de preditores e o diagnóstico multivariado: correlações de Pearson e de Spearman e fator de inflação da variância (VIF) no treino; informação mútua (MI) entre cada preditor e a porosidade também no treino; importância por permutação do coeficiente de determinação (R^2) no teste, e valores SHAP (*SHapley Additive exPlanations*, decomposição aditiva do efeito de cada preditor com base em Shapley; Lundberg and Lee, 2017). Complementam o quadro, no conjunto de teste profundo, o erro absoluto médio (MAE, do inglês *mean absolute error*) e a raiz do erro quadrático médio (RMSE, *root mean squared error*). No **conjunto de dados de referência (F03-4)**, sob partição treino–teste ao longo da profundidade e com as curvas tal como apresentadas nas figuras deste relatório, V_p e a impedância acústica (AI) não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já entram no modelo: o R^2 no teste profundo permanece praticamente inalterado após retirá-los. Isto documenta redundância preditiva **local** nesse protocolo, não irrelevância física universal dessas grandezas. A leitura das ablações e do diagnóstico multivariado no conjunto de dados de referência (F03-4) permanece ancorada a esse protocolo intra-coluna. Complementarmente, uma validação LOO entre quatro conjuntos de dados 7logs (tabela no texto) indica encaixe elevado em cada poço retido, com heterogeneidade moderada entre colunas; isso não substitui estudos alargados nem afirma independência geológica plena entre esses quatro poços.

1 Introdução

A porosidade controla, com mineralogia e fluido, a resposta elástica efetiva da rocha. Em colunas perfiladas, relações empíricas entre porosidade e grandezas sônicas ou de densidade são esperadas; o mesmo vale para grandezas derivadas da combinação massa–rigidez, como a impedância acústica (AI) e a velocidade da onda de compressão P (V_p). Daí decorre um risco metodológico: modelos supervisionados podem atingir erros baixos no teste sem que isso signifique, por si só, que cada preditor contribua com informação independente.

Os achados de ablação não implicam irrelevância física de V_p ou de AI, mas sim **ausência de contribuição preditiva marginal detectável** no conjunto de dados de referência (F03-4) considerado, dado o forte acoplamento dessas grandezas com AC e ρ_b e a qualidade relativa das curvas usadas como entrada.

O objetivo deste texto é documentar, com rigor modesto porém explícito, um baseline de regressão e o diagnóstico que o acompanha. Pretende-se responder, com base em números e figuras, se a retirada isolada de V_p ou da impedância acústica (AI) altera o desempenho, e se correlações e o fator de inflação da variância (VIF) sustentam a leitura de redundância entre preditores. Inclui-se ainda um contraste entre o conjunto de dados de referência (F03-4) e o conjunto de dados de validação (F06-1) e uma validação LOO entre quatro conjuntos de dados 7logs, para lembrar que a leitura entre contextos não se resume a R^2 elevado num único intervalo nem implica transferência homogênea entre colunas.

2 Quadro teórico sucinto

Em meio efetivo, a impedância acústica Z relaciona massa volumétrica ρ e velocidade V segundo

$$Z = \rho V. \tag{1}$$

Quando ρ e V são estimados a partir das mesmas observações que alimentam o intervalo de trânsito, a informação trazida por Z tende a sobrepor-se à de V e à de ρ, em vez de acrescentar graus de liberdade estatísticos novos.

Para avaliar o ajuste global no teste, utilizou-se o coeficiente de determinação

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}, \tag{2}$$

onde y_i é a porosidade observada, $\hat{y}_i$ a predição e $\bar{y}$ a média amostral no conjunto de teste de cardinalidade n. O erro absoluto médio (MAE) foi

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \tag{3}$$

isto é, o erro absoluto médio (MAE, do inglês *mean absolute error*). A raiz do erro quadrático médio (RMSE, *root mean squared error*) foi

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}\,. \tag{4}$$

Estas grandezas resumem o encaixe, mas não distinguem, por si só, contribuição marginal de preditores correlacionados.

3 Questões de trabalho

Colocam-se as seguintes questões, respondidas na Secção 7 com apoio nas Figuras 2–12 e na Tabela 1:

1. O erro de generalização no bloco de teste profundo muda de forma relevante quando se retira V_p, quando se retira a impedância, ou ambas?
2. As estruturas de correlação e o fator de inflação da variância (VIF, medida clássica de colinearidade em regressão linear auxiliar) indicam colinearidade forte o suficiente para explicar a estabilidade de R^2 sob ablação?
3. A importância por permutação do R^2 e o resumo SHAP (*SHapley Additive exPlanations*) apontam para um preditor dominante entre os elásticos?
4. O mesmo protocolo, aplicado ao conjunto de dados de validação (F06-1), produz R^2 sensivelmente diferente?

4 Metodologia

4.1 Dados e variáveis

Utilizou-se um perfil tabular com **seis** preditores — intervalo de trânsito (AC), densidade aparente ρ_b, impedância acústica (AI), velocidade V_p, raio gama (GR) e variável associada à argila (V_c) — e **porosidade** como alvo.

As rotinas de leitura e filtragem usadas na preparação exploratória admitem esquemas 3logs, 6logs e 7logs; contudo, as inferências centrais deste relatório limitam-se a **recortes tabulares 7logs completos** (em particular os dois conjuntos fixados abaixo), sem pretender que conclusões obtidas nesse esquema se estendam automaticamente a outros conjuntos de curvas sem repetir o protocolo.

Neste relatório, **recorte** designa um **trecho vertical** da coluna perfilada analisado através de um **conjunto tabular 7logs completo** (preditor + alvo), com amostragem regular ao longo da profundidade e **identificador de amostra** próprio (etiqueta da coluna ou série considerada). Dois conjuntos fixam o texto central. O **conjunto de dados de referência (F03-4)** concentra as figuras e tabelas de diagnóstico multivariado (correlações, VIF, MI, SHAP, ablações). O **conjunto de dados de validação (F06-1)** designa o segundo conjunto tabular onde o mesmo protocolo computacional é aplicado para confrontar métricas entre colunas; **não** se confunde com um subconjunto de validação no sentido de partição treino/validação *dentro* da mesma coluna (essa partição continua a ser apenas raso versus profundo em cada coluna). O vocabulário *recorte* não implica, por si só, o mesmo poço em duas profundidades nem litologia dominante idêntica entre etiquetas distintas.

4.2 Fluxo de processamento

4.2.1 Estimador: GBDT em histogramas

O *Gradient Boosting* sobre árvores de decisão (GBDT) constrói um conjunto de árvores de forma **sequencial**: a cada etapa acrescenta-se uma árvore que aproxima o gradiente da função de perda em relação à predição acumulada, de modo que novas árvores corrigem

principalmente os resíduos ainda mal explicados pelo conjunto anterior, em vez de forçar uma única árvore muito profunda. A predição final soma contribuições aditivas das árvores, na formulação clássica de *gradient boosting* para aproximação gulosa por árvores fracas (Friedman, 2001).

Neste ensaio, o GBDT é usado como **regressor de referência** sobre dados **tabulares** (linhas = profundidades, colunas = curvas e alvo), contexto em que boosting com árvores costuma ser competitivo sem exigir especificação explícita de termos não lineares ou de interações: partições recursivas capturam relações não lineares e acoplamentos entre preditores sem suposição de linearidade forte entre porosidade e logs, adequado quando se admite que a relação físico-estatística pode desviar-se de um modelo linear simples.

A implementação adotada segue a variante **baseada em histogramas** (*histogram-based*): valores contínuos das entradas são discretizados em intervalos (*bins*) durante o treino, reduzindo o custo de procura de cortes em colunas com muitas observações e tendendo a estabilizar o ajuste em bases relativamente grandes frente a métodos que avaliam cada ponto de corte contínuo isoladamente. Essa estratégia de discretização alinha-se a implementações de *boosting* de alta eficiência descritas na literatura (Ke et al., 2017); o ajuste numérico integra o ecossistema *software* de aprendizado de máquina documentado em (Pedregosa et al., 2011).

Por fim, **não** se impõe padronização *z-score* obrigatória nas features antes do GBDT: partições por limiar em árvores são invariantes a transformações monótonas afim por coluna (mudança de unidade ou escala linear não altera a ordem dos valores), ao contrário de regressões lineares ou de métodos guiados por distâncias, nos quais a escala importa diretamente. Mantém-se apenas, como **variante opcional**, o escalonamento das entradas para comparações com modelos lineares auxiliares, preservando coerência com a natureza do estimador principal e evitando etapas de pré-processamento desnecessárias para o bloco central em árvores.

O procedimento computacional segue a cadeia ilustrada na Figura 1, lida de cima para baixo: primeiro consolidam-se tabela de preditores e alvo; em seguida remove-se linhas incompletas; depois separa-se o trecho mais profundo para teste, mantendo o trecho mais raso para treino; estima-se o *Gradient Boosting* em histogramas (GBDT) **sem** padronização *z-score* nas features, por coerência com modelos baseados em árvores (mantém-se, como variante opcional, a possibilidade de padronizar as entradas para comparação com modelos lineares); calculam-se MAE (3), RMSE (4) e R^2 (2) no teste, com variantes por ablação; por fim, executa-se o bloco de diagnóstico multivariado (correlações e VIF no treino, MI no treino, permutação e SHAP no teste profundo). A avaliação por permutação insere-se nesse último bloco, pois reutiliza o modelo ajustado e as partições fixas.

Na prática, cada retângulo corresponde a uma etapa documentável. O primeiro bloco fixa o universo de variáveis e o alvo; o segundo evita lacunas artificiais que distorceriam correlações; o terceiro impõe que o teste seja **contíguo em profundidade** (um bloco contínuo ao longo do eixo vertical tabulado), o que aproxima o protocolo de um cenário em que se prevê porosidade abaixo de uma profundidade de corte usando apenas informação mais rasa. O quarto bloco estima o GBDT diretamente nas features físicas (sem escalonamento obrigatório); as predições nesse bloco alimentam as curvas da Secção 6. O quinto bloco calcula MAE, RMSE e R^2 no teste profundo e registra variantes sem V_p ou sem AI. O sexto bloco quantifica redundância e sensibilidade: as matrizes de correlação (treino) resumem acoplamento linear ou monótono; o VIF mede quasi-colinearidade num sistema linear auxiliar ajustado ao treino; a MI mede dependência estatística (não necessariamente linear) de cada preditor com a porosidade **no treino**; a permutação mede o quanto o R^2

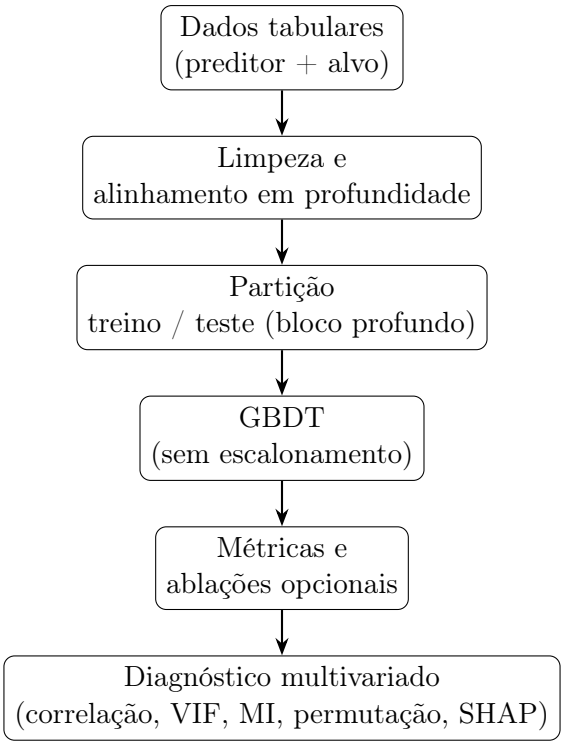

Figura 1: Sequência metodológica adotada neste ensaio.

degrada ao destruir informação de um preditor de cada vez; o SHAP decompõe predições em contribuições aditivas locais no **espaço de entrada do modelo** (coincidente com as features originais neste protocolo). Assim, a Figura 1 não dispensa a narração: orienta a ordem em que os resultados das Secções 6 e 7 devem ser lidos.

Para **rastreabilidade** das execuções numéricas, alinhada à ordem da Figura 1, as etapas finais de diagnóstico multivariado (último bloco do fluxograma) podem deixar, quando a infraestrutura o permitir, um **registro auxiliar em formato JSON** com carimbo temporal em UTC e identificador curto da revisão Git do código utilizado, de forma a associar tabelas e figuras ao estado do software na data da rodagem. O mesmo tipo de registro pode ser produzido de forma **opcional** após o ajuste do GBDT (bloco central da mesma figura), quando a gravação desse metadado estiver habilitada na execução.

4.3 Avaliação e ablação

Ao longo do texto, **teste profundo** e **bloco de teste profundo** referem-se ao mesmo subconjunto de linhas: as observações situadas na cauda mais profunda após ordenar o conjunto pela profundidade mecânica tabulada, correspondendo, no estudo principal, a 20% dos registros mais profundos (em sensibilidades posteriormente reportadas utilizaram-se também 15% e 25%). A partição por profundidade reduz o vazamento espacial inerente a sorteios independentes em perfil quase contínuo: o teste corresponde a esse trecho mais profundo, onde a extrapolação a partir de padrões rasos é mais exigente do que numa partição aleatória i.i.d. (independentes e identicamente distribuídas entre observações).

Foram treinadas variantes do mesmo modelo com subconjuntos de preditores: todas as variáveis elásticas disponíveis; sem V_p; sem impedância; sem V_p e sem impedância conjuntamente. A comparação direta das métricas no teste responde à primeira questão levantada na Secção 3.

4.3.1 Bootstrap pareado no conjunto de teste

Para quantificar a incerteza amostral das métricas no bloco de teste profundo, mantendo o modelo GBDT já ajustado no treino e as predições $\hat{y}_i$ fixas, aplicou-se **bootstrap pareado**: sorteiam-se n índices do teste com reposição, recalculam-se MAE, RMSE e R^2 sobre o par $(y, \hat{y})$ reamostrado e repetem-se $B = 2000$ réplicas com semente pseudoaleatória fixa (com réplicas independentes e semente pseudoaleatória fixa igual a zero). Os quantis empíricos 2,5% e 97,5% definem intervalos bilaterais aproximados a 95%. Esta incerteza refere-se à variação das métricas sob reamostragem das observações de teste, **não** à variância de retreino do estimador nem à transferência entre poços.

4.4 Diagnóstico multivariado

Para cada preditor j do conjunto elástico, o fator de inflação da variância (VIF) foi calculado a partir de uma regressão auxiliar linear de x_j face aos demais preditores **no conjunto de treino** (bloco raso), com

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}, \tag{5}$$

em que R_j^2 é o coeficiente de determinação dessa regressão auxiliar. Valores elevados indicam que x_j é quase combinação linear dos outros preditores. Complementarmente, calcularam-se matrizes de correlação de Pearson e de Spearman **no treino** (figuras do conjunto de dados de referência (F03-4)), a informação mútua (MI, *mutual information*) entre cada preditor e a porosidade **também no treino**, a importância por permutação da queda de R^2 no teste e um resumo SHAP (*SHapley Additive exPlanations*; Lundberg and Lee 2017) obtido com explicador de árvore aplicado ao modelo GBDT ajustado. Para além disso, calcularam-se correlações de Pearson e de Spearman sobre o **conjunto completo** de linhas válidas **antes** da partição treino–teste, com o único propósito de **análise exploratória dos dados**: oferecem uma visão global do acoplamento linear e monótono entre variáveis sem impor o mesmo protocolo de exclusão do bloco profundo. Esses resumos exploratórios **não** sustentam as figuras nem a discussão principal do modelo, que permanecem ancoradas às matrizes obtidas apenas no treino. A permutação e o SHAP reutilizam o mesmo modelo e o mesmo teste profundo. Sobre as **features elásticas** standardizadas do treino (AC, ρ_b, impedância e V_p), aplicou-se uma PCA apenas como leitura geométrica: embora existam quatro colunas, os perfis variam **quase conjuntamente**, de modo que quase toda a dispersão conjunta do bloco se projeta em **poucas** direções. Concretamente, as duas primeiras componentes principais explicam cerca de 99,9% da variância acumulada nesse subconjunto. Isto interpreta-se como evidência de **dimensão efetiva baixa**: o conjunto de estados elásticos visitados pela amostra ocupa, aproximadamente, um **subespaço** de dimensão intrínseca pequena dentro de $\mathbb{R}^4$, em lugar de se comportarem como quatro sinais mutuamente independentes no sentido estatístico do termo. Em consequência, espera-se **redundância preditiva** entre essas curvas em modelos lineares ou em árvores que particionam o espaço de entradas. O número de condição (norma espectral) da matriz de correlação do treino é da ordem de 10^7, sinal de matriz mal condicionada, coerente com VIF extremos quando o mesmo bloco é visto por regressões auxiliares lineares.

5 Premissas e limitações

As curvas e a porosidade tratam-se como co-registradas na profundidade informada, sem corrigir deslocamentos instrumentais. O protocolo principal permanece, por construção, **intra-coluna** (corte vertical num único conjunto tabular). A validação **LOO** (*leave-one-well-out*, ou seja, *exclusão sucessiva de um poço por vez*: em cada rodada treina-se com a união de todos os *outros* recortes tabulares e avalia-se somente no poço que ficou de fora do treino), apresentada na Tabela 3, aproxima a exclusão mútua entre conjuntos tabulares distintos nestes quatro conjuntos de dados 7logs. Os R^2 no poço retido situam-se entre 0,960 e cerca de 0,9998 (MAE baixo em todas as linhas), o que indica transferência entre poços globalmente favorável neste conjunto, sem uniformidade estrita: quando o teste é F02-1, o R^2 é o mais baixo da tabela e o MAE o mais alto, enquanto as outras três exclusões concentram-se ainda mais perto do teto numérico. Com apenas quatro recortes, o LOO não substitui um estudo de campo exaustivo nem documenta grau de independência física entre poços, semelhança instrumental ou ausência de acoplamento alvo–preditores. O contraste visual entre conjunto de dados de referência (F03-4) e conjunto de dados de validação (F06-1) na Figura 6 compara qualidade de ajuste interno a cada coluna, não transferência aprendida numa coluna e testada na outra. Por fim, R^2 alto pode refletir acoplamento físico e redundância estatística, não independência informacional entre preditores. A informação mútua obtida pelo estimador de informação mútua adotado na rotina computacional do ensaio tem **magnitude absoluta** sensível a hiperparâmetros internos do estimador; no texto, a leitura prioritária é a **ordenação** entre preditores e a separação de ordens de grandeza, não a calibração de nats entre estudos distintos. O bootstrap no teste (Secção 4.3.1) quantifica incerteza amostral das métricas com modelo fixo; não incorpora variância de retreino nem generalização entre poços.

6 Resultados

6.1 Síntese numérica

A Tabela 1 reúne os indicadores no conjunto de teste profundo. No conjunto de dados de referência (F03-4), as quatro variantes apresentam desempenho praticamente idêntico: a remoção de V_p ou de impedância, isolada ou conjunta, não altera de forma substantiva MAE, RMSE nem R^2. Já no conjunto de dados de validação (F06-1), R^2 cai para a ordem de 0,95 com MAE e RMSE maiores, o que antecipa a discussão sobre dependência do intervalo litológico e da qualidade relativa das curvas.

A comparação entre a primeira linha da tabela (F03-4: todos os preditores elásticos) e a última (F06-1: validação; baseline completa) constitui apenas **contraste qualitativo** entre duas séries tabulares sob o **mesmo** protocolo interno (treino no trecho raso, teste no bloco profundo de 20%); **não** corresponde ao protocolo LOO da Tabela 3, em que um único modelo treina na união de três colunas e avalia exclusivamente na quarta.

A Tabela 2 reporta intervalos aproximados a 95% (bootstrap pareado, $B = 2000$, Secção 4.3.1) apenas para a linha de **baseline completa** em cada coluna (referência e validação), isto é, o mesmo cenário da primeira linha da Tabela 1 e da última (F06-1).

Cenário	MAE	RMSE	R^2
F03-4: todos os preditores elásticos	0,00053	0,00111	0,988
F03-4: sem V_p	0,00054	0,00111	0,988
F03-4: sem impedância	0,00054	0,00111	0,988
F03-4: sem V_p e sem impedância	0,00054	0,00111	0,988
F06-1: validação (baseline completa)	0,00222	0,00456	0,945

Tabela 1: Desempenho no teste profundo (20% inferior da coluna). As quatro primeiras linhas referem-se ao conjunto de dados de referência (F03-4); a última, ao conjunto de dados de validação (F06-1). MAE (3) e RMSE (4) na unidade da porosidade; R^2 adimensional (2).

Coluna (baseline completa)	IC 95% MAE	IC 95% RMSE	IC 95% R^2
F03-4	[0,00043, 0,00066]	[0,00090, 0,00132]	[0,9829, 0,9923]
F06-1	[0,00156, 0,00298]	[0,00333, 0,00573]	[0,9172, 0,9679]

Tabela 2: Bootstrap pareado no teste profundo ($B = 2000$, semente 0; $n = 287$ no F03-4 e $n = 116$ no F06-1). Limites: quantis empíricos 2,5% e 97,5% das réplicas.

6.1.1 Robustez ao corte em profundidade

Mantendo o mesmo GBDT no conjunto de dados de referência (F03-4), repetiu-se a partição com frações de teste profundo de 15%, 20% e 25%. O R^2 no teste oscilou entre 0,988 e 0,993 (MAE e RMSE na mesma ordem de grandeza), o que indica que a conclusão de encaixe elevado no teste **não** depende de um único ponto de corte na grade considerada. Com profundidade máxima das árvores $\in \{4, 6, 8\}$ e demais hiperparâmetros fixos, o R^2 no mesmo corte de 20% permanece na casa de 0,988, sugerindo que a leitura de redundância marginal não está ancorada num único valor de profundidade de árvore.

6.1.2 Exclusão sucessiva de um poço (LOO, *leave-one-well-out*)

Para aproximar a crítica de generalização **entre** colunas, aplicou-se a validação **LOO** já definida nas premissas: em cada passo, treina-se o mesmo tipo de GBDT na união de três recortes tabulares 7logs e testa-se no quarto, percorrendo os quatro poços disponíveis (F02-1, F03-2, F03-4, F06-1). Na Tabela 3, o R^2 no poço retido situa-se entre 0,960 e 0,999 (valor pontual máximo 0,999845) e o MAE permanece baixo em todas as linhas: o quadro indica generalização entre poços globalmente forte nestes quatro conjuntos de dados. A variação entre linhas — notadamente o contraste de F02-1 ($R^2 = 0{,}960$, MAE = 0,00311) com F03-2, F03-4 e F06-1 — mostra que R^2 elevado **não** implica transferência estritamente homogênea entre contextos distintos; qualifica um resultado globalmente favorável, sem sugerir instabilidade grave nem substituir validação em conjuntos mais vastos ou em condições de aquisição claramente independentes.

6.2 Perfil de porosidade observada e prevista

As Figuras 2 a 5 mostram, para o conjunto de dados de referência (F03-4), a porosidade observada e a curva prevista ao longo da profundidade, com linha de corte entre treino e teste. Visualmente, a coincidência no trecho profundo é marcada em todas as variantes, o

Poço retido (teste)	n_{treino}	n_{teste}	MAE	R^2
F02-1	3595	445	0,00311	0,960
F03-2	2456	1584	0,00030	0,996
F03-4	2605	1435	0,00011	0,999
F06-1	3464	576	0,00013	1,000*

Tabela 3: Validação LOO entre quatro conjuntos de dados tabulares 7logs (treino na união dos outros três, teste exclusivo no poço da linha). *Arredondamento a três casas; valor pontual 0,999845.

que é coerente com as quatro primeiras linhas da Tabela 1 (todas no F03-4, $R^2 \approx 0{,}988$ no teste profundo). A Figura 6 transporta o mesmo tipo de painel para o conjunto de dados de validação (F06-1): observa-se maior dispersão relativa entre observado e previsto, coerente com a **última linha** dessa mesma tabela — a linha *F06-1: validação (baseline completa)*, em que $R^2 = 0{,}945$ (e MAE/RMSE superiores às linhas do F03-4). Isto não é uma "queda" de R^2 ao longo do tempo nem um efeito das figuras 2–5: é apenas o contraste entre dois ajustes *independentes* (uma coluna versus outra) sob o mesmo protocolo de partição raso/profundo. Distingue-se da Tabela 3, que reporta métricas do protocolo LOO (poço retido). O contraste visual com a Figura 6 reforça o mesmo aviso: neste painel de figuras e nas linhas correspondentes da Tabela 1, cada coluna tem **o seu** modelo GBDT — treino e teste limitados aos dados daquela coluna (partição raso/profundo). Comparar F03-4 com F06-1 **não** significa aplicar ao F06-1 o estimador já ajustado no F03-4; seriam precisos dados do poço-alvo no treino ou um protocolo explícito de transferência. A exclusão de poço no treino, com métricas na Tabela 3, aproxima precisamente essa leitura entre conjuntos de dados distintos.

6.3 Estrutura de correlação e colinearidade

As Figuras 9 e 10 evidenciam correlações lineares e monótonas quase unitárias entre AC, ρ_b, impedância e V_p, bem como correlação forte deste bloco com a porosidade **no conjunto de dados de referência (F03-4)**. Formalmente, quatro curvas elásticas definem quatro coordenadas, mas o padrão de acoplamento mostra que a amostra percorre apenas uma **faixa estreita** de combinações possíveis: mudanças de AC acompanham variações coerentes de ρ_b, AI e V_p, em vez de quatro fontes de variação ortogonais. Por **dimensão efetiva baixa** entende-se precisamente isto — o volume "real" ocupado pelos dados no espaço das elásticas tem poucos graus de liberdade estatísticos, compatível com a síntese por PCA no treino (duas componentes concentram cerca de 99,9% da variância do bloco; Secção 4.4). Essa imagem ajuda a explicar por que retirar V_p ou a impedância pode deixar o R^2 quase inalterado: essas grandezas funcionam, neste conjunto, como **reparametrizações** do mesmo eixo dominante já informado por AC e ρ_b, e não como eixos independentes.

A Tabela 4 traduz essa leitura em termos de (5): fatores da ordem de 10^5 a 10^6 para AC, ρ_b, impedância e V_p não devem ser tomados como magnitudes calibradas de um modelo linear final. Dado o nível extremo de colinearidade, os **valores absolutos** de VIF perdem interesse quantitativo fino e devem ser lidos apenas como **marcadores de degenerescência severa** do sistema linear auxiliar; comparações finas entre, por exemplo, $7{,}0 \times 10^5$ e $1{,}1 \times 10^5$ não devem ser interpretadas como diferença substancial de "grau de colinearidade". Para GR e V_c, os VIF permanecem elevados face ao limiar usual da ordem

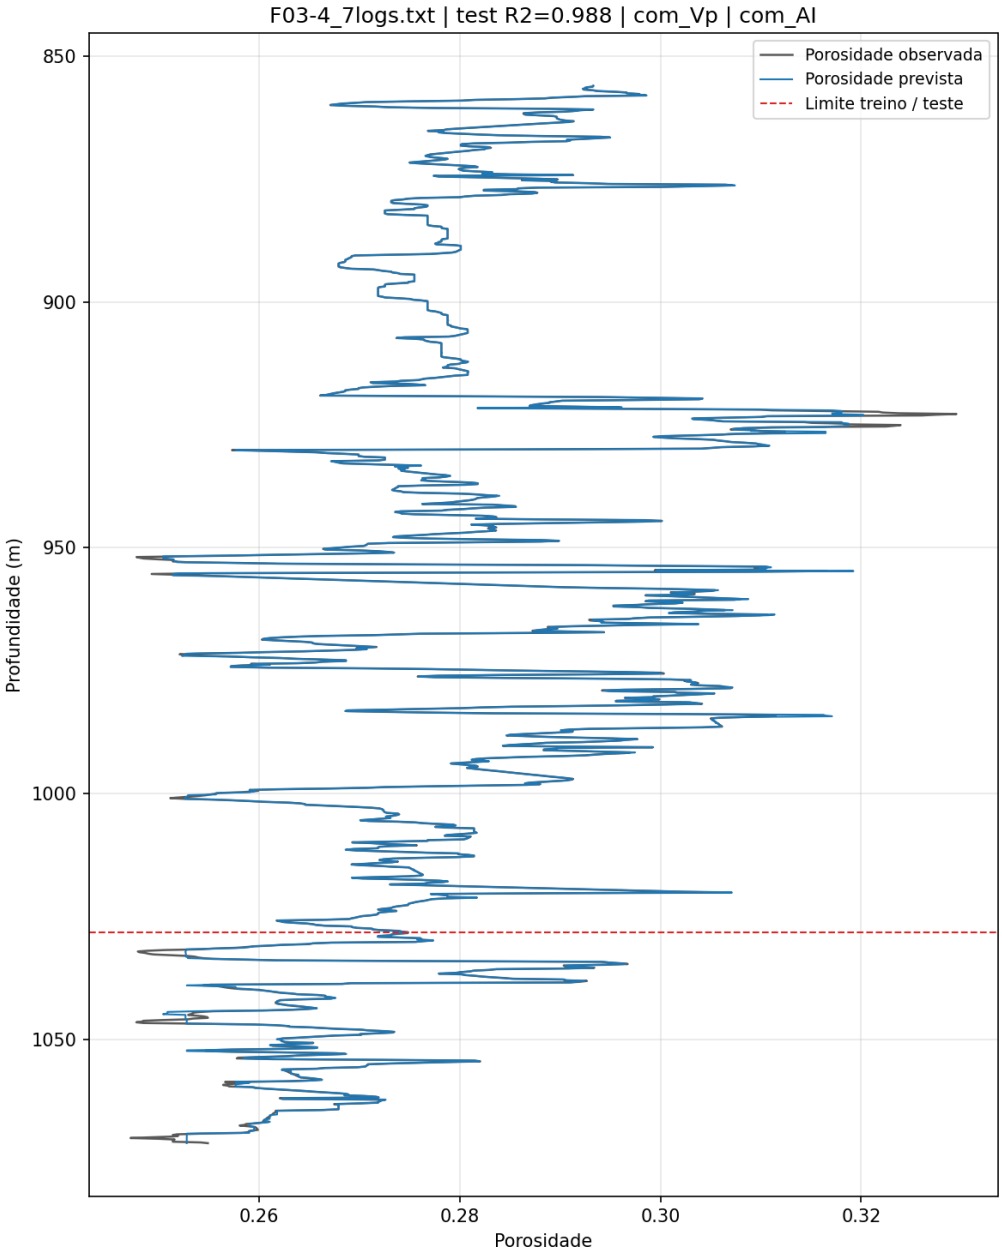

Figura 2: Conjunto de dados de referência (F03-4): porosidade observada e prevista com todos os preditores elásticos disponíveis.

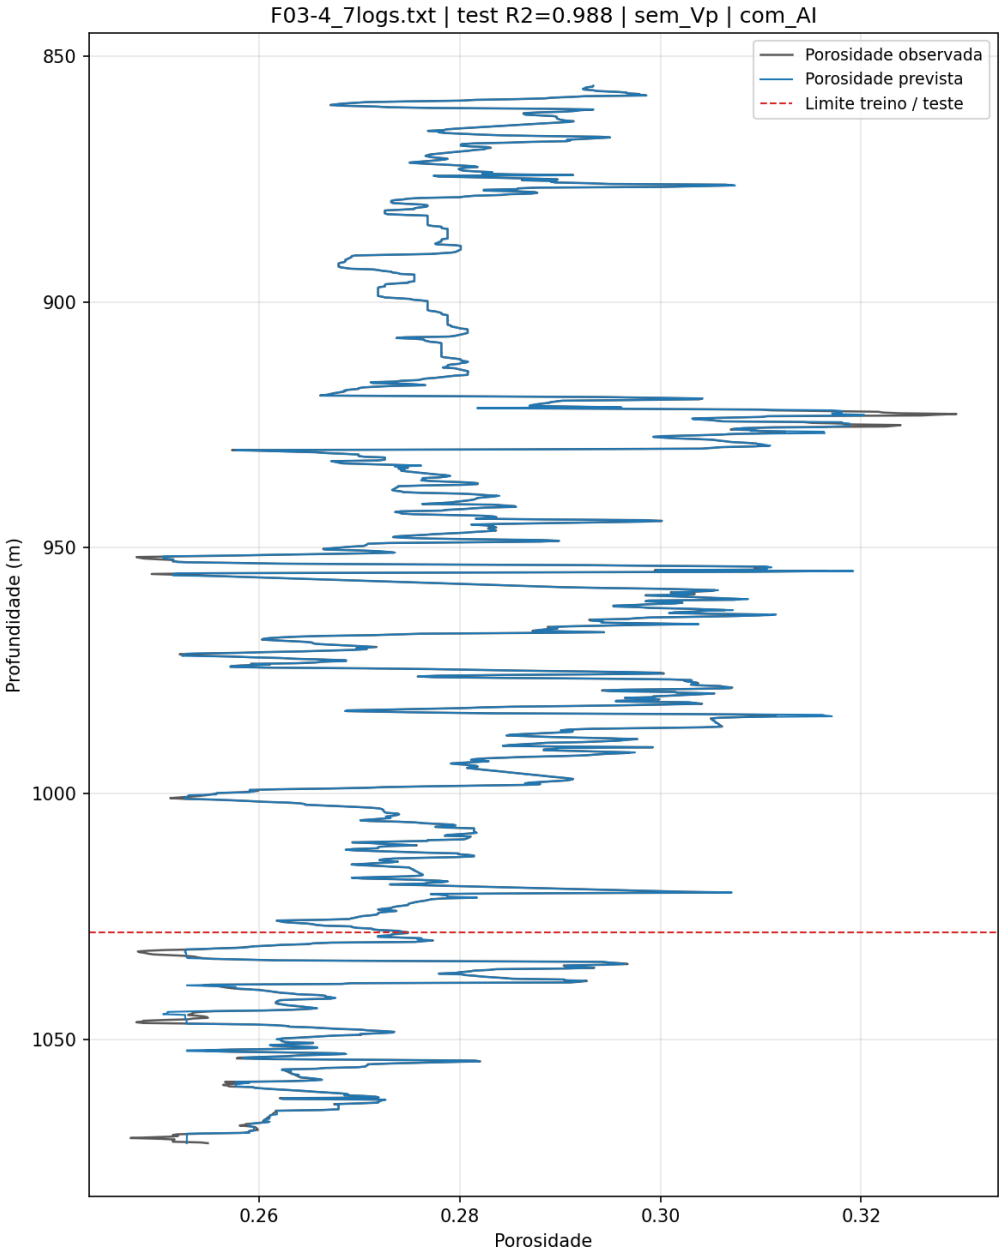

Figura 3: Conjunto de dados de referência (F03-4): modelo sem V_p.

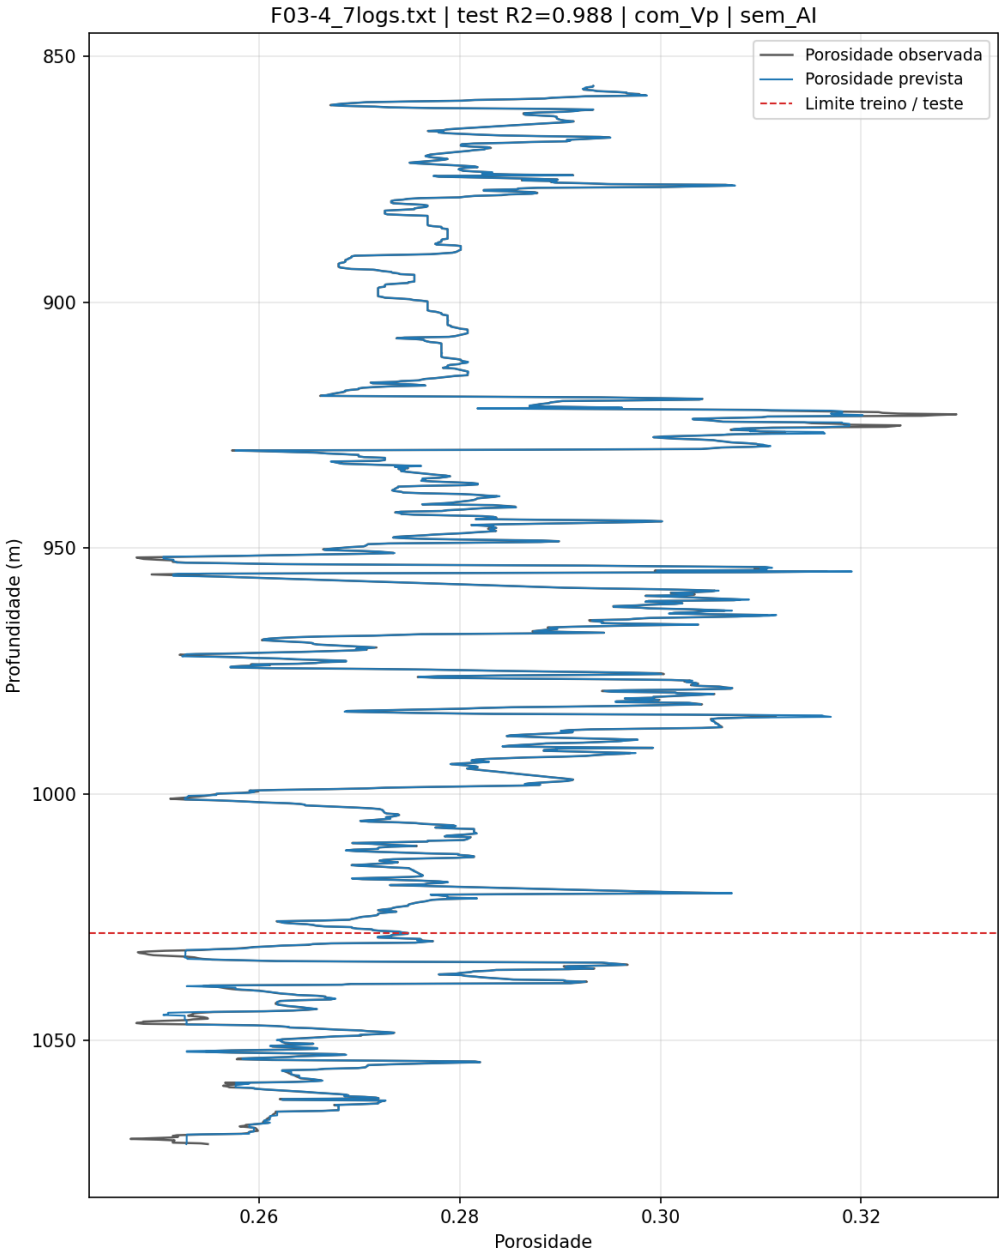

Figura 4: Conjunto de dados de referência (F03-4): modelo sem impedância acústica.

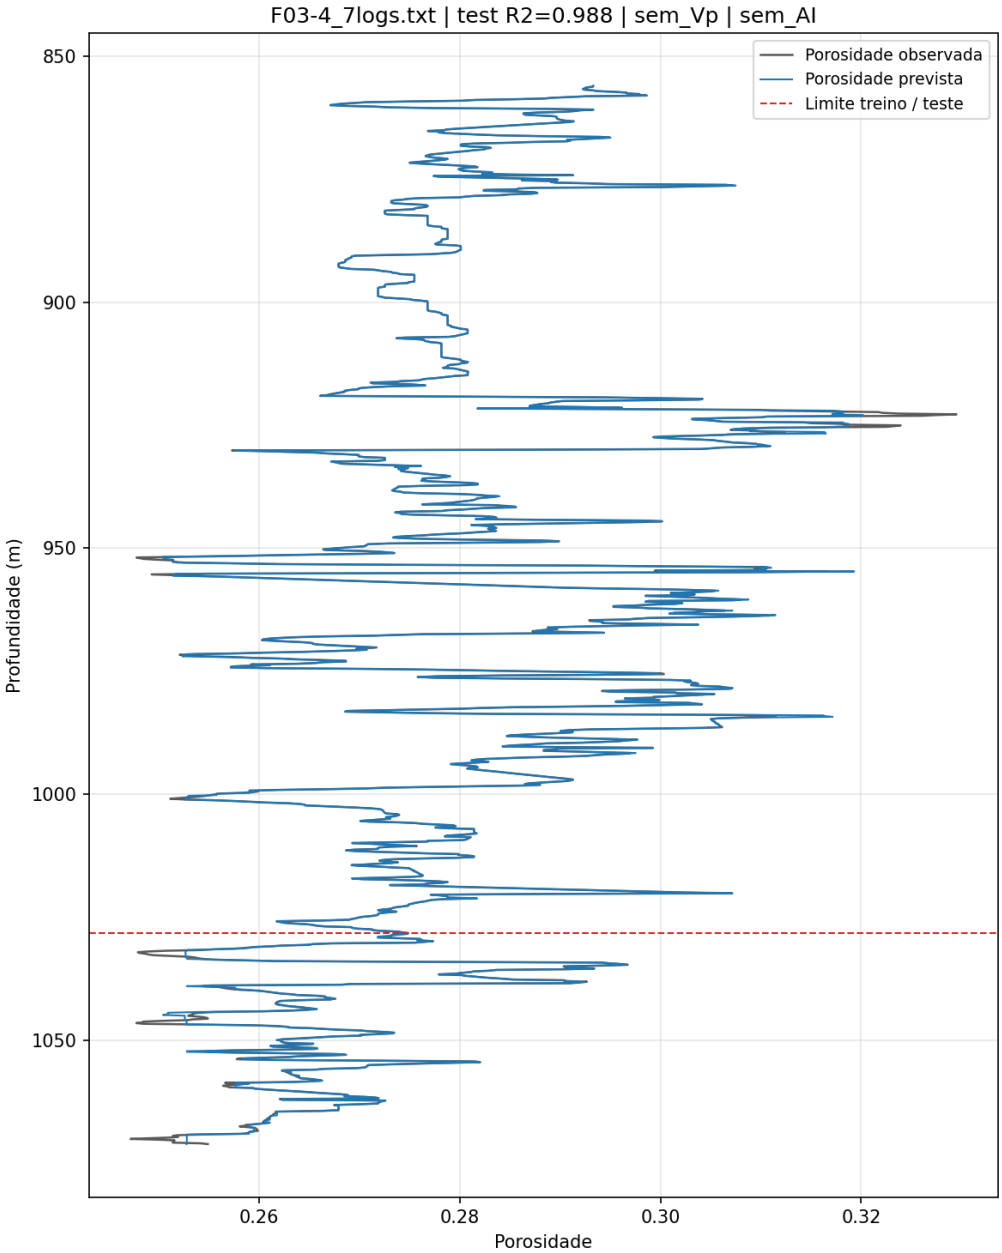

Figura 5: Conjunto de dados de referência (F03-4): modelo apenas com AC, ρ_b, GR e V_c.

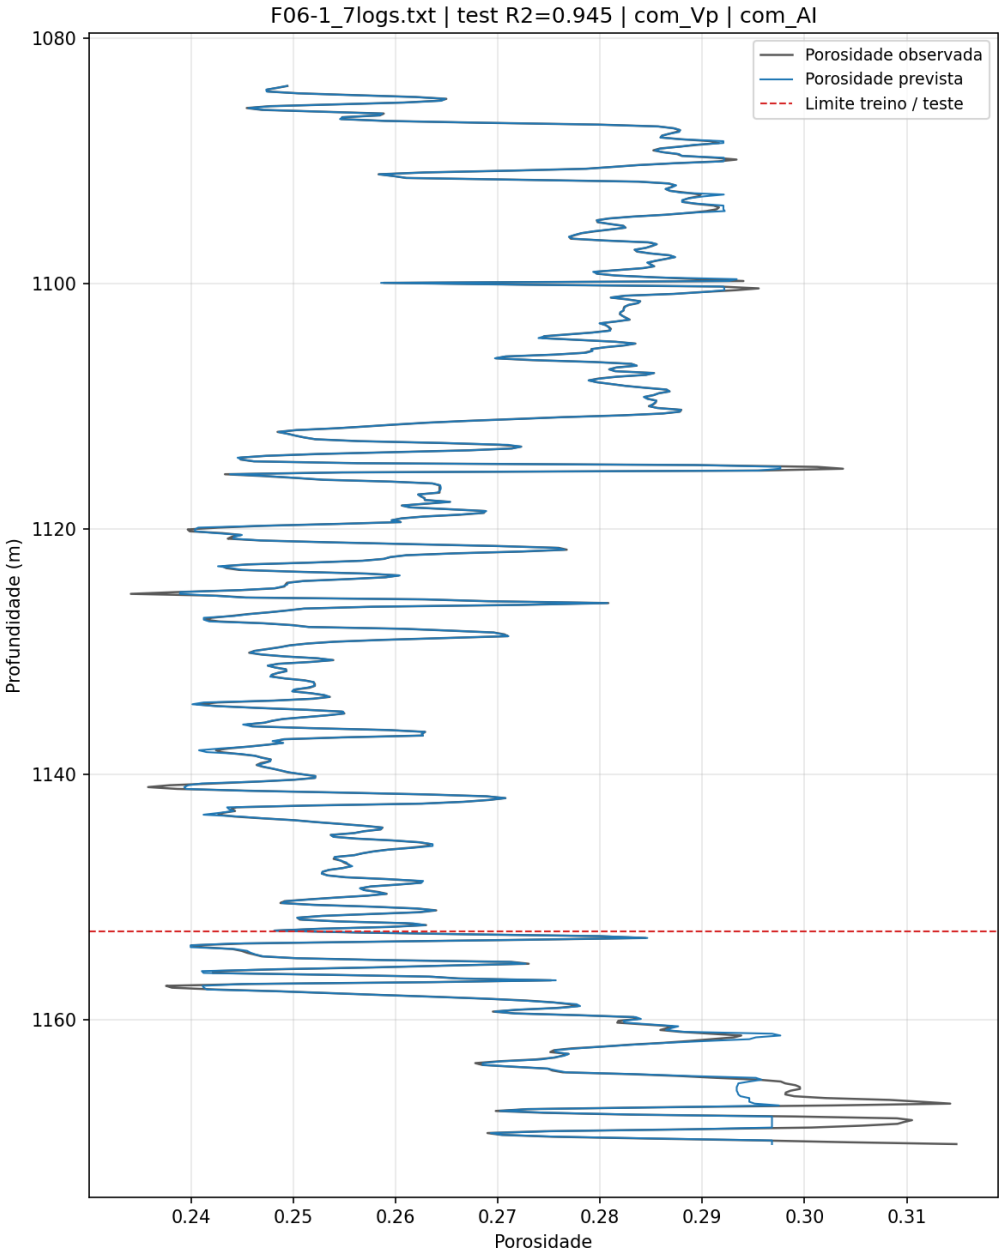

Figura 6: Conjunto de dados de validação (F06-1): baseline completa.

de dez, coerente com a forte associação mútua observada nas matrizes.

Preditor	VIF (ordem de grandeza)
AC	$7{,}0 \times 10^5$
ρ_b	$7{,}0 \times 10^5$
Impedância	$1{,}1 \times 10^5$
V_p	$1{,}1 \times 10^5$
GR	$8{,}3 \times 10^1$
V_c	$8{,}2 \times 10^1$

Tabela 4: Fatores VIF aproximados no conjunto de dados de referência (F03-4)(treino, bloco raso), calculados por (5).

6.4 Dependência entre GR e V_c: postos e empates

O par GR–V_c aparece nas matrizes de correlação com associação forte, mas a leitura sob **empates nos postos** (vários pontos com o mesmo valor, logo o mesmo posto após *ranking*) e sob **desempates** extremos (*min* e *max* na rotina de postos adotada) informa se a dependência seria artefato numérico ou se permanece quase determinística.

No conjunto de dados de referência (F03-4), sobre o mesmo conjunto 7logs já filtrado por linhas completas, calcularam-se estatísticas de empates, correlações de Pearson, Spearman e Kendall, correlações parciais via correlação entre resíduos de regressões lineares ordinárias (controle pela profundidade; controle adicional pelo bloco elástico em bruto; variantes em que preditores e profundidade entram como postos médios), e uma estabilidade de Spearman sob *jitter* uniforme minúsculo repetido (80 sorteios, escala da ordem de 10^{-8} face à amplitude das curvas). As tabelas seguintes consolidam os indicadores dessa etapa para o conjunto de dados de referência (F03-4).

Coluna	n	valores distintos	fração em empates	multiplicidade máx.
GR	1435	1110	0,298	23
V_c	1435	1110	0,298	23

Tabela 5: Empates nos valores brutos: GR e V_c compartilham a mesma cardinalidade de valores distintos e a mesma fração de linhas em empates (conjunto de dados de referência (F03-4)).

A Tabela 5 mostra que GR e V_c não são meramente correlacionados: compartilham **exatamente** o mesmo número de valores distintos, a mesma fração de linhas em empates e a mesma multiplicidade máxima, o que é compatível com V_c construído a partir de GR (ou inversamente) com a mesma grade de quantização. A Tabela 6 confirma uma relação quase monótona perfeita (Spearman e Kendall unitários) e mantém correlação parcial elevada mesmo depois de linearizar profundidade ou o bloco elástico, pelo menos no esquema de controle linear adotado. Uma regressão isotônica crescente $V_c \approx f(\mathrm{GR})$ ajustada aos mesmos dados atinge R^2 praticamente unitário e erro de reconstrução desprezível à escala da precisão finita do cálculo, o que quantifica a redundância monótona além das correlações clássicas. **No conjunto de dados de referência (F03-4), GR e V_c não devem ser tratados como eixos independentes de informação:** a evidência sugere que um deles

Medida	Notação / controle	Valor
Pearson (bruto)	$\rho_{GR,Vc}$	0,993
Spearman	ρ_S	1,000
Kendall	τ	1,000
Parcial (bruto)	resíduos OLS; controle: profundidade	0,993
Parcial (postos)	resíduos OLS em postos médios; controle: posto(prof.)	1,000
Parcial (bruto)	resíduos OLS; controle: AC, ρ_b, AI, V_p	0,992
Parcial (postos)	postos médios; controle: prof. e elásticos (postos)	1,000
Spearman + *jitter*	média de 80 sorteios	0,999992
	desvio-padrão	$8{,}6 \times 10^{-7}$

Tabela 6: Associação GR–V_c e correlações parciais lineares (resíduos OLS; controle **linear** apenas, sem equivalência a independência condicional geral). Com monotonia empírica quase perfeita entre GR e V_c, os p-valores dos testes de Spearman e de Kendall (hipótese de independência) ficam abaixo do que a aritmética de ponto flutuante distingue de zero, aparecendo como 0 na tabela.

posto(GR) \ posto(V_c)	*average*	*min*	*max*
average	1,000000	0,999991	0,999991
min	0,999991	1,000000	0,999965
max	0,999991	0,999965	1,000000

Tabela 7: Sensibilidade ao desempate: Pearson entre postos obtidos com os métodos *average*, *min* e *max* de desempate; valores fora da diagonal diferem só na sexta casa decimal.

é, na prática, quase inteiramente reconstruível a partir do outro, de modo que mantê-los simultaneamente pode inflar artificialmente a dimensão aparente do espaço de atributos. A Tabela 7 mostra que a escolha de desempate (*average*, *min*, *max*) quase não move o coeficiente; o *jitter* deixa a Spearman estável na unidade até 10^{-6}.

6.5 Informação mútua, permutação e SHAP

A informação mútua (MI) entre cada preditor e a porosidade concentra-se em valores elevados e próximos entre si para AC, ρ_b, impedância e V_p, enquanto GR e V_c ficam num patamar inferior, porém não nulos. A leitura relevante da MI é **ordinal e comparativa** entre preditores (ordenação e separação entre blocos), e não o valor absoluto em nats como grandeza transportável entre estudos. A Tabela 8 quantifica essa separação: os quatro preditores elásticos ficam na casa de 5,3 nats (arredondamento à segunda casa; MI estimada no treino), enquanto GR e V_c permanecem perto de 0,51, isto é, magnitudes cerca de dez vezes menores no mesmo ajuste MI. Isto reforça que, **no conjunto de dados de referência (F03-4)**, o bloco elástico compartilha quase o mesmo conteúdo informativo sobre o alvo, ao passo que GR e V_c introduzem um eixo litológico mais fraco neste conjunto de dados de referência (F03-4), sem ser nulo.

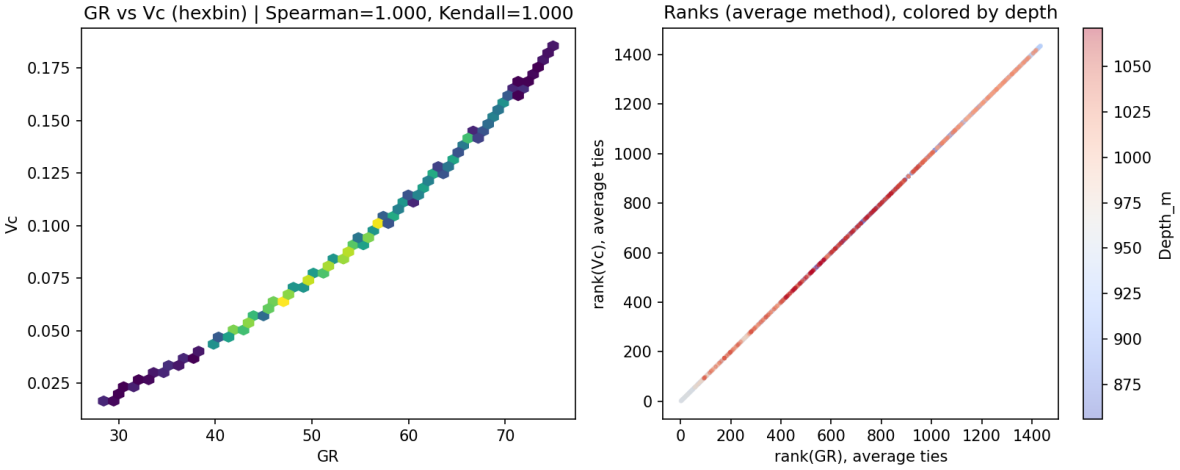

Figura 7: GR versus V_c (hexbin) e postos médios com cores por profundidade. Spearman e Kendall próximos de um indicam monotonia quase perfeita no conjunto de dados de referência (F03-4).

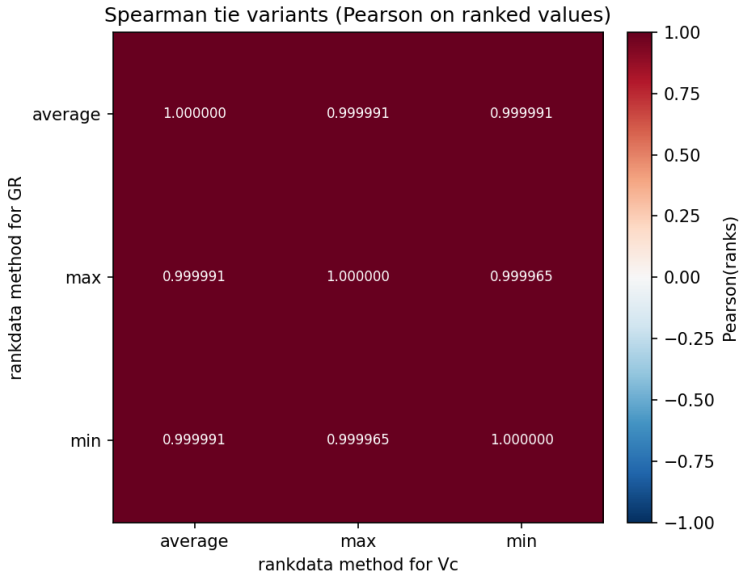

Figura 8: Mapa de calor da matriz da Tabela 7: sensibilidade da correlação de Pearson aplicada a pares de postos, com coeficientes anotados em cada célula (seis casas decimais).

Preditor	MI com porosidade (nats, arred.)
AC	5,30
ρ_b	5,43
AI	5,28
V_p	5,30
GR	0,52
V_c	0,51

Tabela 8: MI estimada no conjunto de treino (bloco raso, mesma partição que as Figuras 9–10). Valores arredondados; ver limitações na Secção 5.

A Figura 11 sintetiza a importância por permutação (25 repetições no teste profundo). A Tabela 9 traduz a figura em números: a queda média de R^2 ao baralhar AC é da ordem de 1,30, com desvio-padrão de 0,06, enquanto ρ_b aparece distante, mas ainda positiva ($\approx$ 0,05). AI e V_p têm quedas médias uma ordem de grandeza menores; V_p fica na casa de 10^{-5}, compatível com ausência de contribuição marginal detectável à escala do ruído de permutação. GR exibe média ligeiramente negativa ($\approx -9 \times 10^{-4}$), compatível com flutuação estatística em torno de zero quando o preditor é redundante; V_c registra queda média nula à resolução numérica utilizada na tabela, coerente com o acoplamento quase determinístico a GR já documentado.

Em presença de colinearidade forte, a importância por permutação mede contribuição **marginal** condicionada ao restante dos preditores e, por construção, tende a **subestimar** variáveis cuja informação já foi absorvida por colunas correlacionadas; quedas quase nulas em AI e V_p não equivalem a ausência física de conteúdo informativo, mas sim a redundância preditiva face a AC e ρ_b neste ajuste.

Preditor	Queda média de R^2	Desvio-padrão
AC	1,298	0,064
ρ_b	0,050	0,005
AI	0,0056	0,0010
V_p	$2{,}9 \times 10^{-5}$	$3{,}4 \times 10^{-6}$
GR	$-9{,}1 \times 10^{-4}$	$3{,}3 \times 10^{-4}$
V_c	0,000	0,000

Tabela 9: Importância por permutação no teste profundo (25 repetições). Registou-se, em paralelo à tabela, um indicador binário que assinala preditores cuja queda média de R^2 não é positiva, para facilitar a leitura de redundância ou ruído à escala do procedimento.

A Figura 12, no mesmo modelo GBDT e no conjunto de dados de referência (F03-4), mostra que AC emerge como o principal **carregador de informação preditiva marginal** na base explicada: a nuvem de SHAP para AC ocupa faixa horizontal visivelmente mais larga do que as de AI, V_p e ρ_b, sinal de que pequenas variações de AC se traduzem em variações grandes no valor de Shapley ao longo das observações do teste. Isto não atribui a AC o papel de "variável certa" em sentido absoluto, apenas descreve o modelo ajustado neste protocolo. AI e V_p aparecem como faixas estreitas centradas perto de zero, coerente com a redundância frente a AC e densidade. ρ_b mostra dispersão intermediária, refletindo o papel secundário mas não nulo visto na permutação. GR e V_c mantém dispersão modesta e parcialmente sobreposta, alinhada à MI baixa e à quase colinearidade entre si: o SHAP

deve ser lido como explicação *local* do ajuste, não como atribuição causal física.

7 Discussão

A estabilidade das métricas na Tabela 1, percorrida em paralelo com as ablações ilustradas nas Figuras 3–5, indica que, **no conjunto de dados de referência (F03-4)** e sob o protocolo treino/teste em profundidade, V_p e a impedância não acrescentam **ganho preditivo marginal detectável** quando AC e ρ_b já estão disponíveis com a qualidade relativa destas curvas. Não se trata de desvalorizar medidas físicas centrais: o experimento não implica irrelevância física de V_p ou de AI, mas sim ausência de contribuição preditiva marginal detectável neste contexto, dado o forte acoplamento dessas grandezas com AC e densidade.

A Secção 6 fornece a evidência multivariada que sustenta esta leitura: correlações quase unitárias no bloco elástico (Figuras 9 e 10), VIF extremos na Tabela 4, MI ordenada como na Tabela 8, quedas de R^2 por permutação como na Tabela 9 e na Figura 11, e resumo SHAP (Figura 12) coerente com essa hierarquia. Em conjunto, estas linhas de evidência fecham o ciclo lógico entre a pergunta formulada na Secção 3 e o desenho metodológico da Figura 1.

A subsecção 6.4 aprofunda o par GR–V_c sob a ótica de empates nos postos e de desempates extremos. As Tabelas 5–7 e as Figuras 7 e 8 mostram estrutura de empates idêntica entre colunas, Spearman e Kendall próximos de um e correlação parcial ainda elevada após controle linear pela profundidade ou pelo bloco elástico, o que reforça que, neste conjunto de dados de referência (F03-4), GR e V_c não funcionam como preditores litológicos independentes no espaço de entrada.

O contraste com a Figura 6 e a última linha da Tabela 1 mostra que o nível de R^2 não é propriedade universal do modelo: depende do conjunto de dados de referência (F03-4). Daí a cautela ao extrapolar conclusões entre colunas distintas sem protocolo de exclusão mútua no treino.

Contraste entre conjunto de dados de referência (F03-4) e conjunto de dados de validação (F06-1). No conjunto de dados de referência (F03-4), após remoção de linhas incompletas, restam $n = 1435$ profundidades entre 856 e 1071 m, com porosidade média 0,278 e desvio-padrão 0,014. No conjunto de dados de validação (F06-1), $n = 576$ entre 1084 e 1170 m, com porosidade média 0,267 e desvio 0,017. A janela vertical é distinta e o segundo conjunto é menor; a porosidade apresenta dispersão relativa ligeiramente maior no F06-1. Estes fatos não explicam por si sós toda a queda de R^2 na Tabela 1, mas mostram que o teste profundo (20%) corresponde a litologias, profundidades e tamanhos amostrais diferentes, pelo que o R^2 deixa de ser comparável como se fosse repetição do mesmo experimento. Complementou-se essa comparação com o bootstrap pareado da Secção 4.3.1 (Tabela 2): os intervalos aproximados a 95% para R^2 **não se sobrepêm** entre F03-4 e F06-1 (limite superior 0,9679 versus limite inferior 0,9829), o que sustenta que a diferença pontual entre 0,988 e 0,945 não se explica apenas por flutuação de amostragem *dentro* de cada coluna sob esta reamostragem. O aviso metodológico permanece: estes intervalos não substituem validação por exclusão de poço.

Limite principal. O protocolo núcleo (partição raso/profundo por coluna) caracteriza **robustez interna** ao conjunto de dados e ao modelo ajustado naquela coluna. A Tabela 3

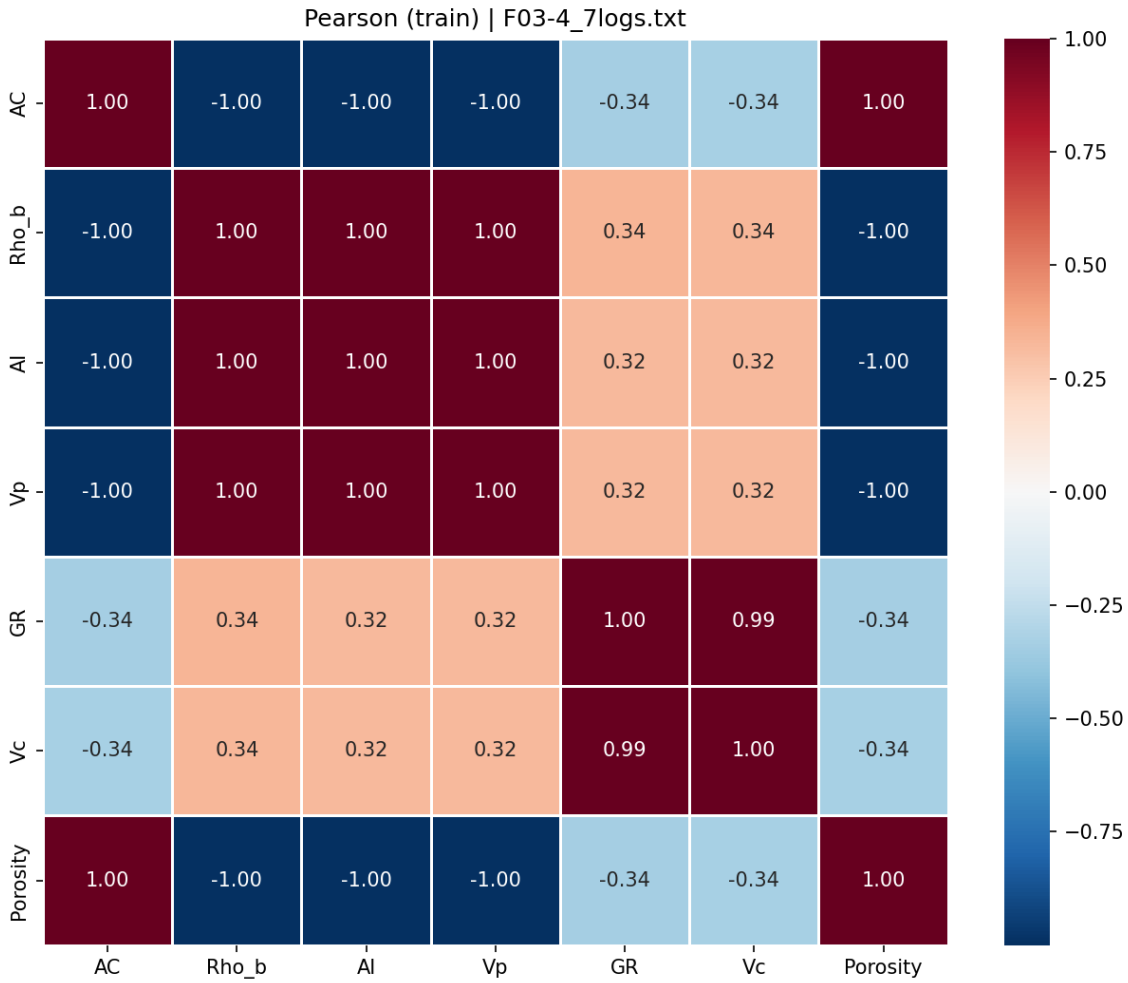

Figura 9: Correlações de Pearson entre preditores e porosidade (conjunto de dados de referência (F03-4)).

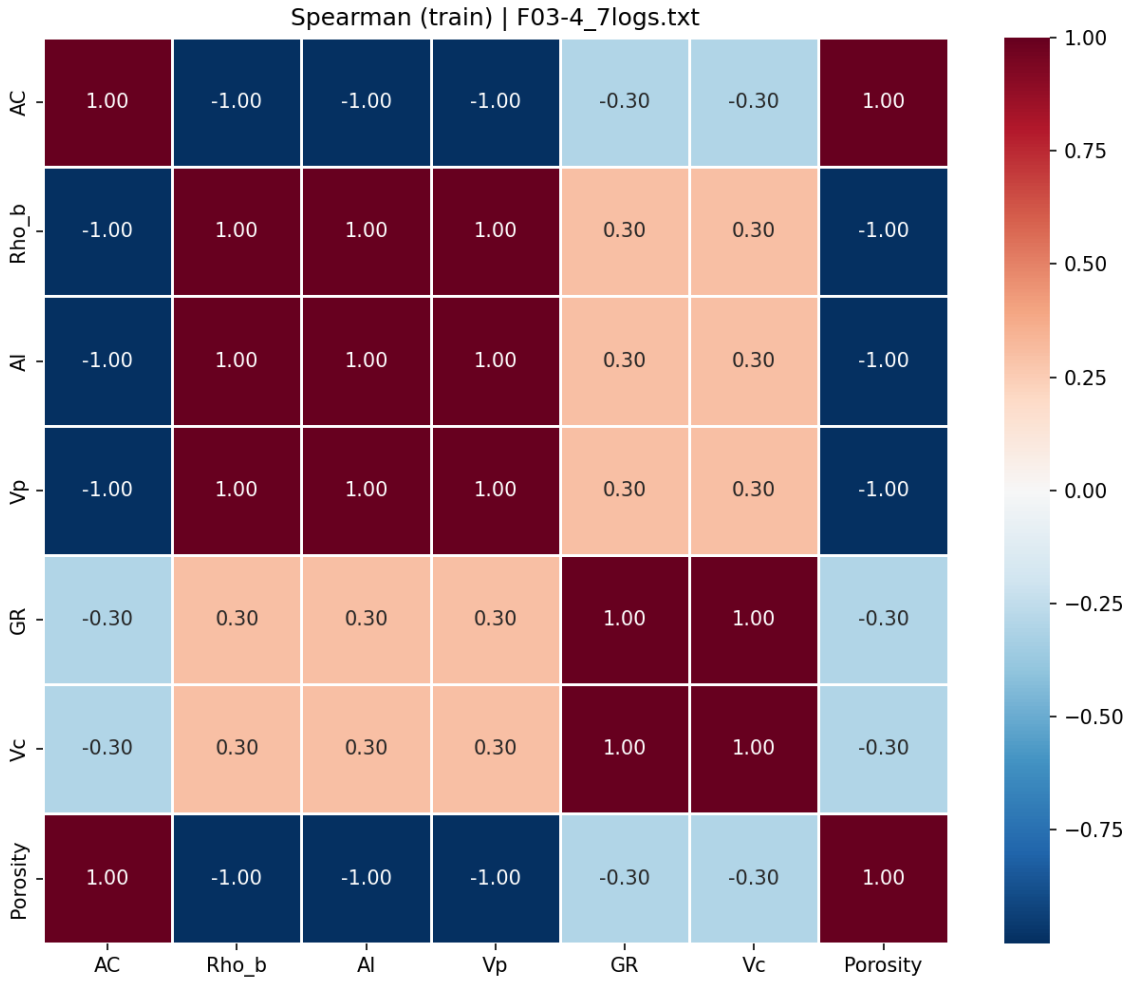

Figura 10: Correlações de Spearman (conjunto de dados de referência (F03-4)).

acrescenta, sobre quatro conjuntos de dados 7logs, evidência de encaixe elevado no poço retido em cada exclusão, compatível com transferência favorável nesse conjunto finito, porém **não** uniforme entre linhas nem substituto de domínio geológico alargado. O teste profundo permanece, por construção, intra-coluna; a leitura das ablações e do diagnóstico multivariado nas figuras centrais deve distinguir-se da extrapolação além do material tabular analisado ou além dos quatro conjuntos de dados percorridos no LOO.

8 Conclusões

No conjunto de dados de referência (F03-4), o modelo atinge R^2 elevado no teste profundo e mantém esse desempenho ao remover V_p ou impedância, o que é explicado, não contradito, pela colinearidade forte documentada nas Figuras 9 e 10 e pelos VIF da Tabela 4. A MI (Tabela 8) e as quedas de R^2 por permutação (Tabela 9 e Figura 11), juntamente com o SHAP (Figura 12), indicam que, **no modelo ajustado e neste conjunto de dados de referência (F03-4)**, AC emerge como o principal carregador de informação preditiva marginal, enquanto a maior parte da variância explicada no teste flui por um eixo elástico estreito no qual AI e V_p ficam preditivamente redundantes face a AC e ρ_b, sem afastar a sua relevância física em outros contextos ou com outras qualidades de aquisição.

O conjunto de dados de validação (F06-1)lembra que a generalização espacial ou entre contextos exige desenho experimental próprio; o presente ensaio não o substitui. Os IC de bootstrap no teste (Tabela 2) reforçam que o contraste de R^2 entre o conjunto de dados de referência (F03-4) e o conjunto de dados de validação (F06-1) não é compatível com intervalos sobrepostos sob a reamostragem adotada, sem por isso afastar a necessidade de protocolos entre poços. A revisão de dependência entre GR e V_c sob postos e empates (Secção 6.4) confirma quase redundância formal entre esses preditores no conjunto de dados de referência (F03-4).

O protocolo principal no conjunto de dados de referência (F03-4) caracteriza robustez interna à coluna; a Tabela 3 acrescenta validação LOO entre quatro conjuntos de dados, com encaixe elevado em cada poço retido e heterogeneidade moderada (F02-1 mais exigente que os demais). Como próximos passos, **recomenda-se**: (i) alargar validação entre poços para mais colunas ou bases independentes quando dados estiverem disponíveis, mantendo exclusão mútua no treino; (ii) repetir o mesmo protocolo de diagnóstico em múltiplos conjuntos de dados, para verificar estabilidade da leitura de redundância; (iii) quando possível, substituir ou complementar a porosidade-alvo por referência menos acoplada às curvas elásticas usadas como entrada.

As conclusões sobre ablações, VIF, MI e SHAP no conjunto de dados de referência (F03-4)constituem evidência **intra-coluna** naquele protocolo em profundidade. A síntese LOO aplica-se aos quatro conjuntos de dados indicados e não se estende, sem novo desenho, a outros poços, profundidades ou esquemas de curvas.

Referências

Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001. doi: 10.1214/aos/1013203451.

Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30*, pages 3149–3157, 2017.

Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017.

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

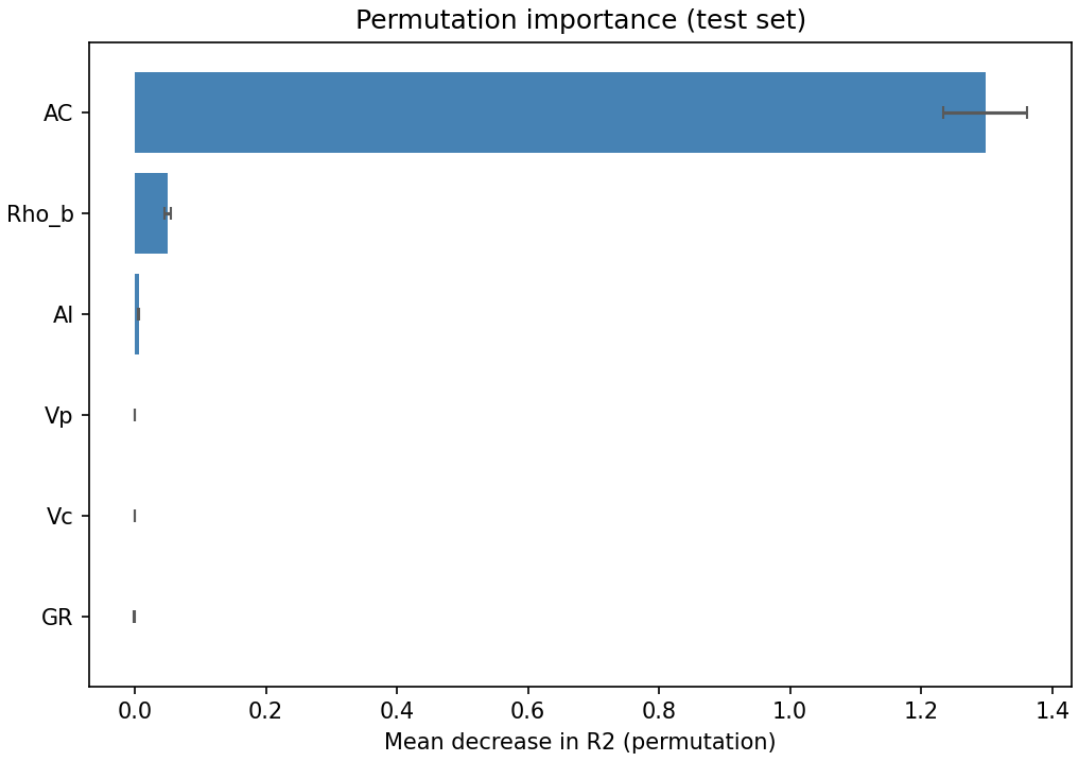

Figura 11: Importância por permutação: queda média de R^2 no teste ao baralhar cada preditor.

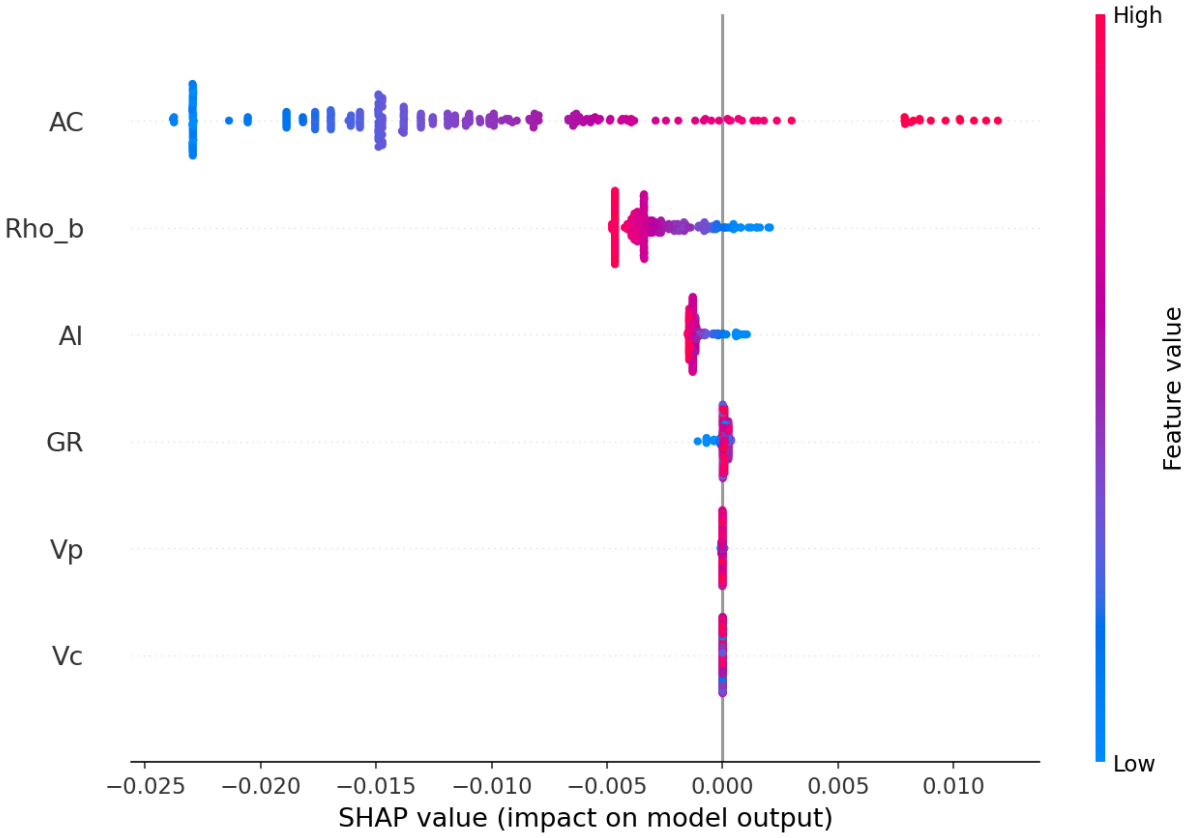

Figura 12: Resumo SHAP (*SHapley Additive exPlanations*) no conjunto de teste profundo (287 observações).